



Identifikation relevanter Zusammenhänge in Daten mit maschinellem Lernen

12

Joshua Hammesfahr und Martin Spott

Inhaltsverzeichnis

12.1	Einleitung	202
12.2	Fachliche Problemstellung	203
12.3	Ansätze zur Reduzierung von Regelmengen	205
12.3.1	Association Rule Discovery	206
12.3.2	Subgroup Discovery	208
12.4	Gütebestimmung von reduzierten Regelmengen	210
12.5	Kombinationssystematik	211
12.6	Ergebnisse	213
12.7	Zusammenfassung	216
	Literatur	216

Zusammenfassung

Im produzierenden Gewerbe wie der Autoindustrie und in Dienstleistungsunternehmen mit großer Infrastruktur, z. B. im Bereich der Telekommunikation, muss die Anzahl von Fehlern in den Produkten so klein wie möglich gehalten werden, um Kunden nicht zu verärgern und Kosten für Wartung und Reparatur zu minimieren. Maschinelle Lernmodelle wie Subgroup Discovery und Assoziationsregeln

M. Spott (✉)
HTW Berlin, Berlin, Deutschland
E-Mail: spott@htw-berlin.de

J. Hammesfahr
Walldorf, Deutschland
E-Mail: j.hammesfahr@gmx.de

ermöglichen es, Zusammenhänge zwischen Produktkonfigurationen und Fehlern zu finden. Allerdings sind die Ergebnisse typischerweise zu umfangreich, um sie in Ansätze für die Fehlerreduktion umsetzen zu können. Dieses Kapitel stellt eine neue Systematik vor, anhand derer die Anzahl der gefundenen Zusammenhänge drastisch reduziert werden kann, ohne wesentliche Informationen zu verlieren.

Schlüsselwörter

Assoziationsregeln · Subgroup Discovery · Redundanz · Selektion

12.1 Einleitung

Im produzierenden Gewerbe wie der Automobilindustrie und in Dienstleistungsunternehmen mit großer Infrastruktur, z. B. im Bereich der Telekommunikation, muss die Anzahl von Fehlern und Problemen in den Produkten so klein wie möglich gehalten werden, um Kunden nicht zu verärgern und Kosten für Wartung und Reparatur zu minimieren.

Daten können hierbei benutzt werden, um relevante Zusammenhänge zwischen Konfigurationen von Produkten oder einer Infrastruktur und Fehlern zu finden. Aus diesen Zusammenhängen können Experten Ansätze für eine Fehlerreduktion bilden.

Zur Identifikation solcher Zusammenhänge können z. B. Verfahren aus dem Bereich Subgroup Discovery oder Lernverfahren für Assoziationsregeln benutzt werden. Leider generieren diese Verfahren zunächst eine enorme Anzahl an potenziell interessanten Zusammenhängen – deutlich zu viele, um sie Experten für eine weitere Analyse der Fehler vorlegen zu können.

Dieses Kapitel beschäftigt sich mit der Fragestellung, wie die Anzahl von Zusammenhängen auf eine handhabbare Größe reduziert werden kann, ohne interessante Zusammenhänge zu verlieren. Als Beispiel wird eine Problemstellung aus der Fahrzeugindustrie vorgestellt, in der interessante Zusammenhänge zwischen Fahrzeugkonfigurationen und Fehlern hergestellt werden sollen.

Zunächst werden die fachliche Problemstellung und die zugehörige Datenbasis erläutert. Anschließend wird ein Überblick über bekannte Reduktionsverfahren von Assoziationsregeln gegeben. Um die Qualität von Reduktionsverfahren zu beurteilen, werden ausgehend von bekannten Qualitätsmaßen Evaluationsgrößen bestimmt, durch welche Aspekte wie die Menge der Zusammenhänge, deren Interessantheit und Abdeckung der Datenbasis quantifiziert werden. Diese ermöglichen für die nachfolgende Bearbeitung die Vergleichbarkeit verschiedener Regelmengen.

Abschließend wird eine neue Kombinationssystematik von fünf Schritten vorgestellt, welche es durch die Konfiguration und Anwendung ausgewählter Reduktionsverfahren ermöglicht, zu einem hinsichtlich der Qualitätsmaße gut ausbalancierten Ergebnis zu kommen.

12.2 Fachliche Problemstellung

Die den Betrachtungen zugrunde liegende Datenbasis liegt in der fachlichen Domäne eines fiktiven Fahrzeugherstellers. Die Datenbasis wurde aus realen, betrieblichen Daten in einem anderen Industriesektor erzeugt, indem aus Gründen der Vertraulichkeit zur Anonymisierung die Begrifflichkeiten umbenannt wurden, ohne die statistische Struktur der Zusammenhänge zu verändern.

Kundenzufriedenheit ist für den fiktiven Fahrzeughersteller ein entscheidender Erfolgsfaktor, um langfristig wettbewerbsfähig zu sein. Ein Faktor, welcher die Kundenzufriedenheit maßgeblich beeinflusst, stellt die Qualität der produzierten Fahrzeuge dar. Diese wiederum kann durch den relativen Anteil der Fehler der jeweils produzierten Fahrzeuge (FAULT_RATE) für verschiedene Arten von Fehlern (FAULT_TYPE) gemessen werden. Zur Identifizierung der Ursachen sammelt der Fahrzeughersteller für jedes ausgelieferte Fahrzeug neben der Information, ob ein Fehler aufgetreten ist und welchen Fehlertyp dieser hatte, die Merkmale, ob sich das Fahrzeug noch im Gewährleistungszeitraum befindet (AGE), über welchen Vertriebsweg dieses verkauft wurde (DEALERSHIP), welchem Kundentyp der jeweilige Kunde angehört (CUSTOMER_TYPE), das Zulassungsland (COUNTRY), die Art des Zulassungsgebietes (GEO_TYPE), das Fahrzeugmodell (MODEL) und ob es kundenspezifische Anpassungen gab (USER_CUSTOMIZED). Der Fahrzeughersteller aggregiert die gesammelten Daten so, dass er für alle Kombinationen und Aggregationsstufen der Merkmale einen Datensatz hat, in dem spezifiziert ist, wie viele Fahrzeuge von der Merkmalskombination insgesamt betroffen sind (CAR_COUNT) und wie viele von diesen einen spezifizierten Fehlertyp aufweisen (FAULT_COUNT), sowie die sich ergebende Fehlerrate. Ein Ausschnitt der resultierenden Daten wird in Abb. 12.1 gezeigt.

LHS	RHS	CAR_COUNT	FAULT_COUNT	FAULT_RATE
{AGE=InWarranty,DEALERSHIP=Franchise,CUSTOMER_TYPE=Private}	{FAULT_TYPE=AirConditioning}	269161	101	3.752401e-04
{AGE=InWarranty,DEALERSHIP=Franchise,USER_CUSTOMISED=N}	{FAULT_TYPE=AirConditioning}	176555	144	8.156099e-04
{AGE=InWarranty,USER_CUSTOMISED=N,GEO_TYPE=Suburban}	{FAULT_TYPE=AirConditioning}	247800	140	5.649718e-04
{AGE=InWarranty,CUSTOMER_TYPE=Private,USER_CUSTOMISED=N}	{FAULT_TYPE=AirConditioning}	226915	271	1.194280e-03
{AGE=InWarranty,MODEL=Opa,CUSTOMER_TYPE=Private}	{FAULT_TYPE=AirConditioning}	181532	270	1.487341e-03
{AGE=InWarranty,MODEL=Opa,USER_CUSTOMISED=N}	{FAULT_TYPE=AirConditioning}	219396	366	1.668216e-03
{MODEL=Opa,USER_CUSTOMISED=N,COUNTRY=France}	{FAULT_TYPE=AirConditioning}	690471	149	2.157947e-04
{AGE=OutOfWarranty,MODEL=Opa,COUNTRY=France}	{FAULT_TYPE=AirConditioning}	672065	121	1.800421e-04
{CUSTOMER_TYPE=Private,USER_CUSTOMISED=N,COUNTRY=France}	{FAULT_TYPE=AirConditioning}	973305	102	1.047976e-04
{AGE=OutOfWarranty,USER_CUSTOMISED=N,COUNTRY=France}	{FAULT_TYPE=AirConditioning}	2173595	123	5.658828e-05
{AGE=InWarranty,DEALERSHIP=Re-Import,DEALERSHIP=Re-Import}	{FAULT_TYPE=AirConditioning}	80561	172	2.135028e-03
{AGE=InWarranty,DEALERSHIP=Re-Import,CUSTOMER_TYPE=Private}	{FAULT_TYPE=AirConditioning}	102286	125	1.222064e-03
{AGE=InWarranty,DEALERSHIP=Re-Import,USER_CUSTOMISED=N}	{FAULT_TYPE=AirConditioning}	120766	178	1.473925e-03
{AGE=InWarranty,MODEL=Opa,DEALERSHIP=Franchise}	{FAULT_TYPE=AirConditioning}	128771	144	1.118264e-03
{AGE=InWarranty,MODEL=Opa,GEO_TYPE=Suburban}	{FAULT_TYPE=AirConditioning}	75445	137	1.815892e-03

Abb. 12.1 Ausschnitt der ausgehenden Regelmenge

Für die jeweiligen Merkmale bestehen die nachfolgenden Werteausprägungen:

- AGE $\in$ {In Warranty, Out of Warranty, *}
- DEALERSHIP $\in$ {Franchise, Re-Import, Branch, Used Car Dealer, *}
- CUSTOMER_TYPE $\in$ {Other, Private, Corporate, *}
- COUNTRY $\in$ {Portugal, Germany, France, Austria, Switzerland, Belgium, Holland, United Kingdom, Spain, Italy, Luxemburg, *}
- GEO_TYPE $\in$ {Suburban, Urban, Village, Super Rural, Rural, Very Rural, Super Urban, Small Town, *missing*, *}
- MODEL $\in$ {Eleganz, Quantum, Lamura, Hopper, Opal, Ultima, *}
- USER_CUSTOMIZED $\in$ {N, Y, Unknown, *}
- FAULT_TYPE $\in$ {*missing*, Air Conditioning, Break Fluid, Break Pad, Clutch, Engine Control, Exhaust, Fuel Injectors, Gearbox, Generator, Spark Plugs, Suspension, Turbo Charger, Wheel Alignment, Windscreen}

Das Zeichen * beschreibt in diesem Kontext die Aggregation aller vorkommenden Ausprägungen eines Merkmals und ist bei allen Merkmalen außer dem Fehlertyp den möglichen Werteausprägungen hinzugefügt, da sich eine im Kontext interessante Regel immer auf einen spezifischen Fehlertyp bezieht. Mit diesen möglichen Werteausprägungen ergeben sich 3.024.000 Kombinationen ($3 \times 5 \times 4 \times 2 \times 10 \times 7 \times 4 \times 15$), von denen 165.720 in der Datenbasis vorkommen. Aus diesen Kombinationen von potenziellen Einflussfaktoren gilt es nun interessante Zusammenhänge abzuleiten, welche für eine gezielte Fehlerreduktion verwendet werden können.

Wegen der enorm großen Anzahl von Zusammenhängen kann die Liste in Abb. 12.1 unmöglich durchgearbeitet werden. Da Zusammenhänge mit einer hohen FAULT_RATE oder hohem FAULT_COUNT grundsätzlich interessante Kandidaten für eine Initiative zur Fehlerreduktion sind, könnte man nach diesen Maßen sortieren. Selbst dann sind die Permutationen der Merkmalswerte auf der linken Seite aber zu zahlreich und verwirrend, um auch nur ansatzweise einen Überblick gewinnen zu können.

Eine alternative Herangehensweise zur Identifizierung interessanter Zusammenhänge könnte in einer gezielten visuellen Exploration der Datenbasis bestehen. Exemplarisch wird dies in Abb. 12.2 für die drei Fahrzeugmodelle Hopper, Quantum und Ultima aufgezeigt. Für jedes der drei Modelle sowie über alle Modelle (*) wird die Verteilung der Fehlerrate als Boxplot angezeigt sowie zusätzlich die Fehlerraten einzelner Fehlertypen. Zunächst ist hier in den Boxplots klar ersichtlich, dass das Modell Hopper größere Fehlerraten aufweist als die anderen Modelle. Des Weiteren sind für das Modell Hopper beispielsweise die Fehlertypen Break Fluid und Engine Control neben dem Fehlertyp Gearbox sehr häufig, während es keine Probleme mit dem Fehlertyp Turbo Charger zu geben scheint. Letzteres wird daran liegen, dass in diesem Modell kein Turbo verbaut ist. Weiters sind für das Modell Quantum die beiden häufigsten Fehlertypen Break Pad




Abb. 12.2 Exemplarische visuelle Exploration ausgewählter Fahrzeugtypen

und Fuel Injectors, und die in der Gesamtheit häufigsten Fehlertypen Gearbox und Turbo Charger sind tendenziell von geringerer Bedeutung.

Erscheint dieses Vorgehen für einzelne Zusammenhänge zunächst angemessen, so können wir doch auf diese Weise keine ganzheitliche Sicht auf alle Zusammenhänge gewinnen. Die Zusammenhänge mit den anderen sechs Merkmalen werden ignoriert und können auch nicht visuell eingebunden werden. Wenn man sich aber auf ein oder zwei Merkmale beschränken muss, stellt sich die Frage, auf welche. Insgesamt ist eine ganzheitliche Exploration der Zusammenhänge auf diese Weise offensichtlich nicht durchführbar, und wichtige Zusammenhänge würden dabei sicher übersehen werden.

Um diese Probleme zu lösen, bedarf es einer möglichst knappen, übersichtlichen und vollständigen Zusammenfassung der interessantesten Informationen der Datenbasis. Diese könnten Experten wie oben beschrieben über Listen oder spezielle interaktive Visualisierungen analysieren.

12.3 Ansätze zur Reduzierung von Regelmengen

Mit der Fragestellung, wie auf Grundlage einer gegebenen Datenbasis interessante Regeln abgeleitet werden können, beschäftigt sich das Forschungsgebiet des Rule Learning [1]. In diesem Forschungsgebiet befasst sich das Teilgebiet der Descriptive Rule Discovery mit der Fragestellung, wie individuelle interessante Muster in Daten

extrahiert werden können. In der Literatur sind hierbei vor allem die Aufgabengebiete der Association Rule Discovery und der Subgroup Discovery von Bedeutung.

12.3.1 Association Rule Discovery

Die Association Rule Discovery beschäftigt sich mit der Generierung von Assoziationsregeln in einer Datenbasis, welche im Jahr 1993 zunächst im Anwendungskontext einer Warenkorbanalyse vorgestellt wurde [2]. Eine Assoziationsregel beschreibt dabei eine Wenn-Dann-Beziehung zwischen zwei Mustern, die in den Transaktionen einer Datenbasis vorkommen, wie z. B.: „Wenn ein Fahrzeug von einem Privatkunden in Deutschland gekauft wurde, dann tritt ein Fehler mit der Bremsflüssigkeit auf“ bzw. formal $\{\text{Private, Germany}\} \rightarrow \{\text{Break Fluid}\}$. Wichtige Beschreibungsgrößen solcher Assoziationsregeln sind der Support und die Konfidenz. Der Support gibt an, wie häufig beide Muster zusammen in der Datenbasis vorkommen, z. B. „Bei 500 Fahrzeugen von Privatkunden in Deutschland tritt ein Fehler wegen der Bremsflüssigkeit auf“ bzw. formal $\text{support}(\{\text{Private, Germany}\} \rightarrow \{\text{Break Fluid}\}) = 500$. Alternativ wird häufig auch die relative Häufigkeit als Support benutzt. Die Konfidenz beschreibt die Wahrscheinlichkeit, dass die Konsequenz einer Assoziationsregel in einer Transaktion auftritt, wenn die Bedingung aufgetreten ist, z. B. „Bei 3 % aller Fahrzeuge von Privatkunden in Deutschland trat ein Fehler mit der Bremsflüssigkeit auf“ bzw. $\text{confidence}(\{\text{Private, Germany}\} \rightarrow \{\text{Break Fluid}\}) = 3 \%$.

Die Generierung von Assoziationsregeln läuft dabei typischerweise in zwei Schritten ab [1]. Zunächst werden alle in den Transaktionen der Datenbasis vorkommenden Muster generiert, welche einen Mindestsupport erfüllen (Frequent Itemsets). Anschließend werden aus diesen Frequent Itemsets die Assoziationsregeln abgeleitet, indem die jeweiligen Muster in genau zwei Teilmengen aufgeteilt werden. So werden z. B. aus dem Muster $\{\text{Private, Germany, Break Fluid}\}$ die Assoziationsregeln $\{\text{Private, Germany}\} \rightarrow \{\text{Break Fluid}\}$, $\{\text{Private, Break Fluid}\} \rightarrow \{\text{Germany}\}$ und $\{\text{Break Fluid, Germany}\} \rightarrow \{\text{Private}\}$ abgeleitet. In unserem Anwendungsfall können wir uns auf Regeln beschränken, welche einen Fehlertyp als Konsequenz enthalten.

Wie in Abschn. 12.2 ergibt sich auch hier die Problematik, dass eine enorme Anzahl an Regeln generiert wird, von denen möglichst nur die interessantesten beibehalten werden sollen. Zur Lösung dieser Problemstellung findet sich in der Literatur eine Reihe verschiedener Ansätze, von denen beschränkungsbasierte und kompressionsbasierte Verfahren für die betrachtete Problemstellung als nützlich identifiziert wurden [3].

Der Ansatz beschränkungsbasierter Verfahren zur Reduktion einer Regelmenge besteht darin, dass anhand von Beschreibungsgrößen die absolute oder relative Bedeutung einer Regel bewertet werden kann. Eine Reduktion der Regelmenge erfolgt dadurch, dass unwichtige Regeln gefiltert werden. In einer einfachen Form kann diese Filterung durch Schwellenwerte für die Konfidenz und den Support der Regeln erfolgen. Eine Erweiterung dieser Idee besteht darin, die Schwellenwerte einzelner Regeln abhängig von weiteren Größen zu machen. So wird beispielsweise in [4] anhand der

Anzahl der Elemente einer Regel ein unterschiedlicher Mindestsupport herangezogen, oder in [5] erfolgt die Bestimmung eines Mindestsupports anhand des Supports einzelner Elemente einer Regel in der Datenbasis.

Ein weiterer beschränkungsbasierter Ansatz findet sich mit dem Minimal Improvement [6]. Die zur Beschränkung verwendete Größe beschreibt dabei die minimale Differenz zwischen der Konfidenz einer Regel und der aller Teilmengen dieser Regel bzw. aller Regeln mit der gleichen Konsequenz, bei denen die Bedingung eine Teilmenge der Bedingung der Regel ist. Ein positiver Schwellenwert als Minimal Improvement bedeutet dabei, dass eine spezifischere Regel bezüglich ihrer Konfidenz besser sein muss als jede Generalisierung selbiger. So müsste z. B. die Konfidenz der Regel {Private, Germany} $\rightarrow$ {Break Fluid} mindestens um den Schwellenwert größer sein als die von {Germany} $\rightarrow$ {Break Fluid}, um sie als spezifischere Regel zu behalten. Anderenfalls würden wir sie als redundante Regel entfernen, denn die Zusatzinformation Private vergrößert offenbar die Wahrscheinlichkeit des Fehlers nicht oder nur unwesentlich und ist damit nicht relevant.

Kompressionsbasierte Verfahren stellen die zweite Gruppe von Reduktionsansätzen im Kontext von Assoziationsregeln dar. Die grundlegende Idee dieser Verfahren besteht darin, dass verschiedene Regeln die gleichen oder nahezu die gleichen Informationen beschreiben und es aus diesem Grund reicht, einen Repräsentanten in einer Menge ähnlicher Regeln beizubehalten. Bei diesen Verfahren wird weiters unterschieden, ob der gesamte Informationsgehalt aller ursprünglichen Regeln erhalten bleibt und sich diese damit rekonstruieren lassen (verlustfreie Kompression) oder im Zuge der Kompression Informationen verloren gehen, welche sich nicht rekonstruieren lassen (verlustbehaftete Kompression) [3]. Ein Ansatz, bei dem eine verlustfreie Kompression erreicht wird, ist der der Closed Itemsets [7]. Bei diesem werden zu jeder Regel alle Teilmengen dieser mit dem gleichen Support gefiltert, da diese redundant sind. Wenn beispielsweise bei 500 Fahrzeugen von Privatkunden ein Fehler wegen der Bremsflüssigkeit aufgetreten ist und jedes dieser Fahrzeuge in Deutschland zugelassen wurde, dann werden alle Information bereits durch das spezifischere Muster {Private, Germany, Break Fluid} erfasst, sodass das allgemeinere Muster {Private, Break Fluid} entfernt werden kann.

Ein verlustbehafteter Ansatz, welcher dem der Closed Itemsets ähnlich ist, ist eine Variante von Condensed Itemsets [8]. Die Reduktionsidee hier ist eine ähnliche wie bei Closed Itemsets, wobei es ausreicht, wenn ein Muster nahezu die gleichen Informationen in einem tolerierten Annäherungsbereich abdeckt. So könnte beispielsweise eine Toleranz im Support von 2 spezifiziert werden, sodass das zuletzt genannte generelle Muster auch gefiltert werden würde, wenn der Support des spezifischeren bei 498 statt 500 liegt.

Ein weiterer verlustfreier Ansatz, welcher im Bearbeitungskontext als relevant identifiziert wurde, ist der der Non-Derivable Itemsets [9]. Die Idee des Ansatzes besteht darin, dass sich der Wertebereich des Supports eines Musters durch den Support der Teilmengen einschränken lässt und ein Muster entfernt werden kann, wenn dessen Support durch diese Einschränkungen bestimmt werden kann. In [10] wird dieser Ansatz mit dem der Closed Itemsets kombiniert, wodurch sich Closed Non-Derivable Itemsets als erweiterter Ansatz zur Erreichung einer verlustfreien Kompression ergibt.

12.3.2 Subgroup Discovery

Das Forschungsgebiet der Subgroup Discovery beschäftigt sich mit der Ableitung der interessantesten Zusammenhänge in Bezug auf eine festgelegte Eigenschaft der Individuen einer Datenbasis [11]. Im Kontext der vorliegenden Datenbasis ist dies beispielsweise die Fragestellung, ob ein spezifischer Fehler bei einem Fahrzeug aufgetreten ist. Von der Association Rule Discovery lässt sich die Subgroup Discovery insofern abgrenzen, als dass bei dieser zielgerichtet nur interessante Zusammenhänge in Bezug auf eine festgelegte Eigenschaft generiert werden, während bei der Association Rule Discovery grundsätzlich Regeln ohne vorgegebene Zieleigenschaft erzeugt werden [1]. Diese Unterscheidung ist jedoch im Kontext der fachlichen Problemstellung weniger relevant und wird aus diesem Grund nicht weiter betrachtet.

Im Zuge der Subgroup Discovery finden sich bei der Generierung der interessanten Zusammenhänge ähnliche Ansätze wie bei der Reduktion von Assoziationsregeln z. B. in Form von Pruning-Verfahren, jedoch gibt es mit dem flexibleren Einsatz von Qualitätsfunktionen und von Selektionsverfahren zwei relevante Ansätze, welche so im Rahmen der Association Rule Discovery weniger präsent sind. Eine Qualitätsfunktion ordnet einem Muster eine Qualitätskennzahl als quantitative Beschreibungsgröße für dessen Interessantheit zu [12]. Durch diese können Muster bezüglich ihrer Interessantheit miteinander verglichen werden. In der Literatur findet sich eine Vielzahl verschiedener Messgrößen, es findet sich im Kontext der Subgroup Discovery jedoch keine einheitlich verwendete Qualitätsfunktion [13]. In [13] wird hierbei eine Reihe gängiger Qualitätsfunktionen aufgeführt. Dabei ist es unter anderem relevant, ob es sich bei der im Zuge der Subgroup Discovery ausgewählten Eigenschaft um eine binäre, nominale oder numerische Zielvariable handelt. Im gegebenen Anwendungsfall wird das Auftreten eines spezifischen Fehlers für die Regeln jeweils als eine binäre Zielgröße betrachtet. Ein typischer Aufbau von Qualitätsfunktionen von binären Zielgrößen kann wie folgt dargestellt werden, wobei die Notation der in [12] vorgestellten Formel zur Vereinfachung auf den Support und die Konfidenz einer Assoziationsregel $A \rightarrow B$ übertragen wird:

$$q^a(A \rightarrow B) = \text{support}(A)^a \cdot (\text{confidence}(A \rightarrow B) - \text{confidence}(\emptyset \rightarrow B)) \text{ mit } a \in [0, 1]$$

Für das obige Beispiel $\{\text{Private, Germany}\} \rightarrow \{\text{Break Fluid}\}$ bedeutet dies, dass die Qualität der Regel davon abhängig ist, wie viele private Fahrzeuge in Deutschland in der Datenbasis sind und wie hoch die Wahrscheinlichkeit ist, dass ein Fehler mit der Bremsflüssigkeit unter diesen Bedingungen auftritt im Vergleich zu der Wahrscheinlichkeit des Fehlers ohne eine Bedingung. Im Kontext der Bearbeitung wurden die fünf Qualitätsfunktionen Weighted Relative Accuracy, Lift, Binomialtest, Chi-Squared und Zhang ausgewählt, da diese für die Problemstellung als geeignet identifiziert wurden [12, 14, 15].

Um eine handhabbare Menge an interessanten Mustern zu filtern, finden sich verschiedene Selektionsstrategien. Eine einfache Form einer solchen Selektionsstrategie stellt die Top-k-Selektion dar, bei der die besten k-Muster anhand einer ausgewählten Qualitätskennzahl ausgewählt werden. Ein zentrales Problem besteht bei diesem Verfahren darin,

dass die ausgewählten Regeln viel Redundanz aufweisen und durch redundante Muster potenziell interessante Muster verdrängt werden. In [16] wird in dem Kontext zwischen verschiedenen Arten von Redundanz unterschieden, und es werden darauf basierend verschiedene Selektionsstrategien vorgestellt. Diese werden in beschreibungsbasierte und abdeckungsbasierte Selektionsstrategien eingeteilt. Beschreibungsbasiert bedeutet in diesem Kontext, dass die Selektion eines Musters aufgrund der Beschreibung der einzelnen Elemente erfolgt. Die Zielsetzung besteht darin, dass die Häufigkeit einzelner Elemente möglichst nicht größer als ein spezifizierter Schwellenwert in der selektierten Regelmenge sein soll, da dies als Redundanz aufgefasst wird. Anhand des verwendeten Beispiels soll z. B. bei der Selektion der Regeln darauf geachtet werden, dass das Zulassungsland Deutschland nicht häufiger als dreimal vorkommt. Die in [16] vorgestellte Variable Description Based Selection, welche für die Problemstellung als interessant identifiziert wurde, läuft dabei so ab, dass einzelne Regeln schrittweise nach ihrer Qualität aus der ausgehenden Regelmenge selektiert werden. Nach jeder Selektion wird anschließend geprüft, ob es Elemente gibt, deren Häufigkeit in der selektierten Regelmenge einen Schwellenwert erreicht hat. Ist dies der Fall, werden alle übrigen Regeln mit diesem Element in der ausgehenden Regelmenge gefiltert.

Abdeckungsbasiert bedeutet, dass die Selektion der Muster danach erfolgt, dass eine Information der Datenbasis möglichst nicht durch mehrere Muster beschrieben wird. Für die betrachtete Datenbasis bedeutet dies, dass ein Fahrzeug möglichst nicht durch mehrere Regeln beschrieben wird. Um dies zu realisieren besteht die Grundidee verschiedener Verfahren darin, die Häufigkeit, wie oft eine Information bereits durch selektierte Regeln erfasst wird, in einen Gewichtungsfaktor zu integrieren, welcher in die Berechnung der Qualitätskennzahl einfließt, nach der Regeln selektiert werden. Die Selektion von Regeln erfolgt dabei in Einzelschritten, und nach jeder Selektion werden die Qualitätskennzahlen der Regeln angepasst. Für Bearbeitung wurden Ideen der Verfahren Fixed- und Variable Size Cover-Based Selection [16] sowie der Weighted Relative Accuracy (with Example Weights) [17] in einer implementierten Funktion zusammengefasst [18]. Dabei wurde der Grundalgorithmus der Fixed- und Variable Size Cover-Based Selection übernommen. Dieser wird wie folgt erweitert: für jeden Datensatz in der Datenbasis messen wir die Häufigkeit der Abdeckung durch Muster und entfernen diejenigen Datensätze für die Berechnung der Qualitätskennzahlen, dessen Abdeckungshäufigkeit größer als ein gewählter Schwellenwert ist. Des Weiteren wird das Abbruchkriterium für die Regelselektion dahingehend angepasst, dass so lange Regeln selektiert werden, wie Datensätze in der zugrunde liegenden Datenbasis enthalten sind.

Ein weiteres Verfahren, welches im Kontext der Subgroup Discovery besteht und abdeckungsbasierte Redundanz adressiert, stellt die Subgroup Suppression dar [17]. Bei dieser besteht die Grundidee darin, dass eine Regel R_1 durch eine andere Regel R_2 unterdrückt werden kann, wenn die Qualitätskennzahl dieser kleiner ist als das Produkt der Ähnlichkeit der beiden Regeln und der Qualitätskennzahl der anderen Regel. Die Ähnlichkeit wird dabei vorrangig durch den relativen Anteil der Datensätze, die durch R_1 und R_2 abgedeckt werden, an den Datensätzen, die nur durch R_2 abgedeckt werden, bestimmt. Wird eine Regel durch eine andere Regel unterdrückt, kann diese entfernt werden. Wenn

beispielsweise 95 % der Fahrzeuge in Deutschland von Privatkunden wären, würden die 95 % bei dem direkten Vergleich zwischen den Regeln R1: {Germany} $\rightarrow$ {Break Fluid} und R2: {Private} $\rightarrow$ {Break Fluid} in die Betrachtung einfließen, ob R1 durch R2 unterdrückt wird.

12.4 Gütebestimmung von reduzierten Regelmengen

Um eine Reduktion einer Regelmenge in Bezug auf die ausgehende Zielsetzung bewerten zu können, bedarf es geeigneter Messgrößen. Zunächst wurden aus diesem Grund auf Grundlage bestehender Bewertungsmaßstäbe für eine Menge von Regeln qualitative Eigenschaften, die im fachlichen Kontext relevant sind, erarbeitet. Anschließend werden für diese qualitativen Eigenschaften quantitative Messgrößen bestimmt.

In der Literatur findet sich eine Reihe qualitativer Eigenschaften zur Bewertung von Mustern. So werden in [13] die vier Zielbereiche Komplexität, Generalität, Genauigkeit und Interessantheit genannt, um verschiedene Kennzahlen im Rahmen der Subgroup Discovery zu gruppieren. In [19] werden verschiedene subjektive Messgrößen zur Bewertung von Interessantheit aufgeführt, wobei unter anderem Redundanz, Neuheit, Unerwartbarkeit, Nützlichkeit und Aktionsfähigkeit genannt werden. In [16] und [17] werden verschiedene Varianten von Subgroup Discovery miteinander verglichen, wobei im Rahmen der Vergleiche Messgrößen verwendet werden, welche sich den bestehenden qualitativen Gruppen zuordnen lassen. Im Rahmen der Bearbeitung wurden auf dieser Grundlage die nachfolgenden vier qualitativen Eigenschaften ermittelt.

a. Ganzheitlichkeit

Die Notwendigkeit der Ganzheitlichkeit resultiert aus der Idee, dass eine reduzierte Version der Datenbasis möglichst keine relevanten Informationen der Ausgangsdatenbasis verlieren sollte. Für das fachliche Szenario bedeutet dies, dass möglichst alle Fahrzeuge, bei denen ein Fehler aufgetreten ist, durch Regeln abgebildet werden sollen. Als zentrale Kennzahl für diese Eigenschaft wird der prozentuale Anteil aller Fahrzeuge mit einem Fehler, die durch eine Regel erfasst werden, gemessen an allen Fahrzeugen mit einem Fehler herangezogen. Diese Kennzahl entspricht dem in [17] vorgestellten Overall Support.

b. Komplexität

Je komplexer eine Regelmenge wird, desto schwieriger wird es für einen Experten, diese zu analysieren und geeigneten Nutzen aus dieser zu ziehen. Als einfache Messgröße der Komplexität wird die Anzahl der Regeln herangezogen.

c. Interessantheit

Die Messung der Interessantheit erfolgt anhand der durchschnittlichen Werte der jeweiligen Qualitätskennzahlen einer Regel. Um die Tendenz anhand einer einfachen Kennzahl abzuleiten, wurden die fünf ausgewählten Qualitätsfunktionen mithilfe einer Rang-Funktion aggregiert [18]. Dabei wird für jede Qualitätskennzahl einer

Regel der Rang der 165.720 Regeln bestimmt, und anschließend wird der Durchschnitt des besten und des schlechtesten Ranges gebildet. Eine hypothetische optimale Regel, die in allen Qualitätskennzahlen die Beste ist, hätte folglich einen Wert von 165.720, eine durchschnittliche Regel etwa die Hälfte. Durch diese Aggregation soll vermieden werden, dass sich ähnliche Qualitätsfunktionen gegenseitig bekräftigen, während die Bedeutung individueller Qualitätsfunktionen eher gemindert wird. Die Kennzahl entspricht dem Durchschnitt dieses aggregierten Ranges über alle verbleibenden Regeln.

d. **Redundanzfreiheit**

Aus der Beschreibung des Nutzens ergibt sich die Notwendigkeit der Redundanzfreiheit, da viele redundante Regeln als Ganzes relativ zur Regelmenge wenig neue Informationen enthalten. Als Kennzahl für die Redundanz wird hierbei die durchschnittliche Abdeckung eines Datensatzes durch eine Regel herangezogen. Ein Wert von drei bedeutet beispielsweise, dass jedes Fahrzeug, welches durch mindestens eine Regel erfasst wird, durchschnittlich von drei Regeln abgedeckt wird. Diese Größe entspricht dabei dem in [16] eingeführten Expected Cover Count.

12.5 Kombinationssystematik

Nachfolgend wird eine neue Kombinationssystematik von fünf Schritten vorgestellt, mittels derer die Regelmenge schrittweise reduziert wird, sodass sich eine möglichst kleine Menge der interessantesten Regeln mit möglichst wenig Redundanz ergibt.

Die Grundidee dieser Systematisierung ist in Abb. 12.3 dargestellt. Die blauen Kreise stellen jeweils die Menge der Transaktionen (im Beispiel die einzelnen Fahrzeuge) dar, welche durch eine Regel erfasst werden.

Beim direkten Vergleich von zwei Regeln können diese Mengen in einer von drei Beziehungen stehen:

1. Es besteht eine Teilmengenbeziehung
2. Es besteht keine Teilmengenbeziehung, es gibt jedoch eine Schnittmenge
3. Es gibt keine Schnittmenge




Abb. 12.3 Mögliche Beziehungen zwischen zwei Regeln

Die Idee der Systematisierung besteht darin, dass sich die Beziehungsart 1 tendenziell einfach und eindeutig über Redundanzanalysen komprimieren lässt, während bei Beziehungsart 2 eine Entscheidung getroffen werden muss, wie die Überschneidung der abgedeckten Mengen zweier Regeln bewertet wird. Bei Beziehungsart 3 gibt es keine Redundanz mehr, es bleibt folglich nur noch die Möglichkeit, den Suchraum mithilfe von Filtern zu reduzieren, denen eine Größe der Interessanztheit von Regeln zugrunde liegt. Die Reihenfolge, in der die ausgewählten Verfahren angewendet werden, kann sich mit dieser grundlegenden Idee an der Beziehungsart orientieren, welche ein jeweiliges Reduktionsmodul adressiert. Aus dieser Einordnung werden fünf Schritte abgeleitet, welche im Folgenden vorgestellt werden.

1. Entfernung reiner Redundanz

Bei der Entfernung reiner Redundanz werden Regeln entfernt, welche in einer Teilmengenbeziehung zu anderen Regeln stehen und deren Informationsgehalt sich vollständig aus den Regeln ableiten lässt. Diesem Schritt wird das verlustfreie Kompressionsverfahren der Closed Non-Derivable Itemsets zugeordnet.

2. Approximation ähnlicher Regeln mit einer Teilmengenbeziehung

Im Zuge der Approximation ähnlicher Regeln werden Regeln entfernt, welche in einer Teilmengenbeziehung zu anderen Regeln stehen, deren Informationsgehalt jedoch größtenteils und/oder relevanter durch andere Regeln erfasst wird. Zunächst wird dabei eine Filterung mittels einer Beschränkung durch Positive Improvement durchgeführt, da die Forderung, dass eine spezifischere Regel genauer sein muss, grundsätzlich gültig erscheint. Anschließend wird eine Komprimierung ähnlicher Regeln durchgeführt. Hier wird versucht, viele Regeln mit ähnlicher Konfidenz, die sich nur in der Wertausprägung eines Merkmals unterscheiden, durch eine negierte Darstellung zusammenzufassen (Negative Replacement) [18]. Ein Anwendungsfall im fachlichen Szenario könnte beispielsweise dann vorliegen, wenn die Fehlerrate der Bremsflüssigkeit bei allen Fahrzeugenmodellen außer dem Modell Opal ähnlich ist. Dann würden diese zur Negierung des Modells Opal zusammengefasst werden. Die Bestimmung, ob die Fehlerrate einer Regel ähnlich zu anderen ist, erfolgt im Rahmen der Implementierung anhand der Prüfung, ob die aggregierte Fehlerrate aller betrachteten Regeln im Konfidenzintervall der jeweiligen Regel liegt. Abschließend werden durch eine Realisierung der in Abschn. 12.3.1 beschriebenen Variante der Condensed Itemsets ähnliche Regeln durch einen Repräsentanten zusammengefasst.

3. Approximation ähnlicher Regeln mit einer dominanten Schnittmenge

Für die Entfernung von Redundanz, welche sich durch die Überschneidung verschiedener Regeln ergibt, erscheint vorrangig das Verfahren der Subgroup Suppression geeignet. Da an dieser Stelle eine möglichst starke Reduktion der Regelmenge noch keine Zielsetzung ist und die in Abschn. 12.3.2 genannten fünf verschiedene Qualitätskennzahlen betrachtet werden, wird die übrige Regelmenge durch die Zusammenführung der verschiedenen Resultate der Subgroup Suppression mit jeweils einer der ausgewählten Kennzahlen bestimmt.

4. Anwendung von Beschränkungen

Nachdem die verschiedenen Formen von Redundanz schrittweise entfernt wurden, wird die verbleibende Regelmenge durch den Einsatz von Beschränkungen gefiltert. Dabei werden zunächst ein Mindestsupport und eine Mindestkonfidenz spezifiziert, da sich die Bedeutung dieser Größen relativ einfach auf die gegebene Anwendung übertragen lässt und sich aus diesem somit geeignete Schwellenwerte ergeben können. Dabei wurden 100 Fahrzeuge mit Fehlern als Mindestsupport spezifiziert. Des Weiteren wurde für die Mindestkonfidenz der Median der Konfidenz innerhalb der ausgehenden Regelmenge ausgewählt. Nach der Anwendung einer Filterung durch einen Mindestsupport und eine Mindestkonfidenz wird nach der relativen Verbesserung der Konfidenz verbleibender Regeln im Vergleich zu denen begrenzt, die mit diesen in einer Teilmengenbeziehung stehen. Es wird somit eine Anpassung der Beschränkung Minimal Improvement angewendet, bei der bereits gefilterte Regeln nicht mehr in die minimale Veränderung der Konfidenz einbezogen werden.

5. Selektion einer interessanten Regelmenge

Abschließend wird eine der in Abschn. 12.3.2 beschriebenen Selektionsstrategien angewendet, durch die die übrigen Regeln so selektiert werden, dass ein möglichst diverser und ganzheitlicher Ausschnitt dieser verbleibt.

12.6 Ergebnisse

Nachdem die ausgewählten Verfahren in der Programmiersprache R implementiert wurden, wurde die ausgehende Regelmenge schrittweise anhand der zuvor vorgestellten Systematik reduziert. Dabei erfolgte eine geeignete Parametrisierung bei Verfahren, bei welchen dies notwendig ist (z. B. in Form eines Schwellenwertes) anhand der betrachteten Kennzahlen [18]. In Tab. 12.1 ist die Entwicklung der in Abschn. 12.4 vorgestellten zentralen Kennzahlen für die Betrachtung aufgeführt.

Bezogen auf diese Veränderung wird in Abb. 12.4 die relative Veränderung dieser Größen aufgeführt, wobei die Vorzeichen für die jeweilige Qualitätskennzahl so angepasst wurden, dass eine positive Veränderung als positiv zu bewerten ist, während eine negative Veränderung als negativ zu bewerten ist. Aus der Abbildung kann abgeleitet werden, dass sich die Bewertung der ausgehenden Regeln anhand der Evaluationsgrößen insgesamt schrittweise verbessert hat. Die Schritte 2.3 (Condensed Itemsets) und Schritt 3 (Subgroup Suppression) führten zu einer Verschlechterung der Ganzheitlichkeit um ca. 0,5 %, welche jedoch im Anbetracht der Entwicklung der anderen Evaluationsgrößen zu vernachlässigen ist. Auffällig ist die Entwicklung der Schritte 2.2 (Negative Replacement), 4.1 (Mindestsupport & Mindestkonfidenz) und 5.2 (Variable-Description Based Selection). Bei Schritt 4.1 ist die deutliche Veränderung der Ganzheitlichkeit auf den verwendeten Schwellenwert für die Mindestkonfidenz zurückzuführen. Aus der Reduktion um 76,78 % kann dabei abgeleitet werden, dass die betroffenen Fahrzeuge in keiner Regel vorkommen, deren Fehlerrate hoch genug

Tab. 12.1 Entwicklung der absoluten Qualitätskennzahlen [18]

	Anzahl Regeln	Redundanz	Interessantheit	Ganzheitlichkeit
Ausgangsdatenbasis	165720	127	84093	100,00 %
Schritt 1				
Closed Non-Derivable Itemsets	40516	64,54	92805	100,00 %
Schritt 2				
2.1 – Positive Improvement	7282	17,2	118480	100,00 %
2.2 – Negative Replacement	7085	17,22	118369	100,00 %
2.3 – Condensed Itemsets	6519	14,29	118514	99,97 %
Schritt 3				
Subgroup Suppression	4259	7,5	124333	99,53 %
Schritt 4				
4.1 – Mindestsupport & Mindestkonfidenz	509	7,02	131589	23,11 %
4.2 – Minimal Improvement	140	3,43	137100	23,11 %
Schritt 5				
5.1 – Gewichtete Selektion	81	2,72	139024	23,11 %
5.2 – Variable-Description Based Selection	24	1,74	128626	21,63 %




Abb. 12.4 Relative Veränderung der Evaluationsgrößen entlang der Schritte

ist, als dass diese den Schwellenwert überschreitet. Die geringe relative Veränderung der Evaluationsgrößen in Schritt 2.2 ist darauf zurückzuführen, dass sich in der vorliegenden Datenbasis nur wenige Regeln mithilfe dieses Verfahrens zusammenfassen

lassen. Da die dem Verfahren zugrunde liegende Idee dennoch sinnvoll erscheint und insgesamt keine negative Entwicklung der Evaluationsgrößen hervorruft, wird dieses beibehalten. In einer folgenden Bearbeitung könnte der Nutzen dieses Verfahrens anhand verschiedener anderer Datensätze evaluiert oder angepasst werden. Die Verschlechterung der Interessantheit und Ganzheitlichkeit um ca. 6 % in Schritt 5.2. (Variable-Description Based Selection) ist auf die Selektionsstrategie als solche zurückzuführen. So zielt diese vorrangig darauf ab, möglichst wenige Regeln mit möglichst wenig Redundanz zu selektieren, wobei in Anbetracht der deutlichen Reduktion der Regelmenge und Redundanz die Nützlichkeit im konkreten Anwendungsfall abzuwägen ist.

Es ergeben sich zwei reduzierte Regelmengen, die sich bezüglich der Evaluationsgrößen als gut bewerten lassen. Insbesondere ist die resultierende Anzahl der Regeln mit 81 und 24 auch für eine folgende manuelle Auswertung durch Experten leicht handhabbar. Die Entscheidung für eine der beiden Selektionsstrategien erscheint abhängig von weiteren fachlichen Rahmenbedingungen. Während die Regelmenge nach Anwendung der gewichteten Selektion bezüglich der Ganzheitlichkeit und Interessantheit etwas besser ist, findet sich in der aus der Anwendung der Variable-Description Based Selection resultierenden Regelmenge weniger Redundanz, und die Anzahl der Regeln ist noch einmal deutlich geringer. Im Zweifelsfall können aber beide erzeugt und in Kombination ausgewertet werden.

Ein Ausschnitt der resultierenden Regelmenge nach Anwendung der gewichteten Selektion ist in Abb. 12.5 dargestellt. Im direkten Vergleich zu dem in Abschn. 12.2 dargestellten Ausschnitt der Ausgangsmenge lässt sich erkennen, dass sich einzelne Regeln deutlich voneinander unterscheiden und somit eine gezielte Betrachtung relevanter Faktoren, die die Fehlerrate der Fahrzeuge beeinflussen, ermöglicht wird.

rules	CAR_COUNT	FAULT_COUNT	FAULT_RATE
(AGE=OutofWarranty)=>(FAULT_TYPE=EngineControl)	23715400	765	3.225752e-05
(MODEL=Opal,CUSTOMER_TYPE=Private,USER_CUSTOMISED=N)=>(FAULT_TYPE=Suspension)	6457704	379	5.868959e-05
(DEALERSHIP=Franchise)=>(FAULT_TYPE=FuelInjectors)	11287396	804	7.122989e-05
(DEALERSHIP=Franchise,CUSTOMER_TYPE=Private)=>(FAULT_TYPE=WheelAlignment)	9485838	970	1.022577e-04
(DEALERSHIP=Franchise,COUNTRY=Austria)=>(FAULT_TYPE=WheelAlignment)	1264705	131	1.035815e-04
(DEALERSHIP=Franchise,COUNTRY=Spain)=>(FAULT_TYPE=WheelAlignment)	1405658	148	1.052888e-04
(USER_CUSTOMISED=N)=>(FAULT_TYPE=Exhaust)	21236189	3746	1.763970e-04
(USER_CUSTOMISED=Unknown)=>(FAULT_TYPE=Generator)	2859983	603	2.108404e-04
(MODEL=Opal,USER_CUSTOMISED=N)=>(FAULT_TYPE=AirConditioning)	7652570	1623	2.120856e-04
(AGE=OutofWarranty)=>(FAULT_TYPE=BreakPad)	23715404	5103	2.151766e-04
(MODEL=Ultima)=>(FAULT_TYPE=EngineControl)	2632268	578	2.195825e-04
(AGE=OutofWarranty)=>(FAULT_TYPE=SparkPlugs)	23715401	5305	2.236943e-04
(MODEL=Ultima)=>(FAULT_TYPE=Generator)	2632268	600	2.279403e-04
(USER_CUSTOMISED=Unknown)=>(FAULT_TYPE=EngineControl)	2859983	773	2.702813e-04
(USER_CUSTOMISED=Y)=>(FAULT_TYPE=Generator)	398179	110	2.762577e-04

Abb. 12.5 Ausschnitt aus der resultierenden Regelmenge nach Anwendung der gewichteten Selektion

12.7 Zusammenfassung

Die Zielsetzung des Vorhabens bestand darin, interessante Zusammenhänge zwischen Produktkonfigurationen und Fehlern der Produkte zu finden. Dabei sollte die Anzahl der Zusammenhänge auf ein handhabbares Maß reduziert werden, ohne dass potenziell interessante Informationen verloren gehen. Um das Ziel zu erreichen, wurden Ansätze aus den Bereichen Assoziationsregeln und Subgroup Discovery mit einer neuen Systematik kombiniert.

Als Ergebnis konnten die initial 165.720 Zusammenhänge auf zwei mögliche Regelmengen mit 81 und 24 Regeln reduziert werden. In beiden Fällen war das Ziel, mit möglichst wenig Regeln möglichst alle interessanten Zusammenhänge zu erfassen und dabei innerhalb der Regelmenge möglichst wenig Redundanz zu belassen. Aufgrund dieser kleinen Anzahlen von Regeln ist es nun möglich, die Zusammenhänge sequenziell durchzugehen und dabei von Experten fachlich bewerten zu lassen, ob daraus Erkenntnisse für eine Verbesserung der Produktqualität gewonnen werden können.

Eine nennenswerte Limitation der Arbeit ist, dass die optimale Bewertung der Interessanztheit von Regeln für einen Datensatz ohne weitere Kontextinformationen nur bedingt möglich ist. So existiert eine Vielzahl verschiedener Qualitätskennzahlen, welche sich zum Teil stark unterscheiden. Von diesen wurden im Zuge der Arbeit fünf selektiert. Dabei wurde versucht, die Reduzierung der Zusammenhänge so zu steuern, dass die besten Regeln für alle Qualitätskennzahlen übrigbleiben. Durch eine Evaluation der Systematik auf anderen Datensätzen kann zukünftig versucht werden, weitere Kriterien für die Wahl und Parametrisierung der Qualitätskennzahlen zu gewinnen.

Des Weiteren beschränkt sich diese Untersuchung bewusst auf eine Datenbasis mit quantitativen Merkmalen. Erweiterungen hinsichtlich numerischer Merkmale wie z. B. dem Alter eines Fahrzeugs in Jahren sind jedoch denkbar.

Für eine optimale Komprimierung von Zusammenhängen müsste Kontextwissen von Experten eingebracht werden, was diesen typischerweise schwer zu entlocken und ebenso schwierig zu formalisieren ist, um es in einem automatisierten Reduktionsprozess einsetzen zu können. Als sinnvollen Ausweg sehen wir interaktive Visualisierungen (Visual Analytics) an, in denen Experten bei der Selektion von Merkmalen, deren Ausprägungen oder von Zusammenhängen ihr Domänenwissen benutzen, um entweder den Reduktionsprozess zu steuern oder das Ergebnis zu explorieren. Der Vorteil ist, dass die Experten so nicht explizit und möglichst vollständig ihr Wissen formulieren müssen, sondern stattdessen von Ergebnissen des maschinellen Lernens inspiriert werden.

Literatur

1. Fürnkranz J, Kliegr T (2015) A brief overview of rule learning. In: Bassiliades N, Gottlob G, Sadri F, Paschke A, Roman D (Eds) Rule technologies: foundations, tools, and applications. Proceedings of the 9th International Symposium (RuleML-15), Springer, Berlin, S 54–69

2. Agrawal R, Imielinski T, Swami A (1993) Mining association rules between sets of items in large databases. In: Proceedings of the 1993 ACM SIGMOD international conference on Management of data (SIGMOD '93). Association for Computing Machinery, New York, S 207–216
3. Han J, Cheng H, Xin D, Yan X (2006) Frequent pattern mining: current status and future directions. *Data Min Knowl Disc* 15:55–86
4. Yun U, Leggett J (2005) WLPMiner: Weighted frequent pattern mining with length-decreasing support constraints. In: Ho TuB, Cheung D, Liu H (Hrsg) *Advances in knowledge discovery and data mining (PAKDD 2005)*. Springer, Berlin, S 555–567
5. Liu B, Hsu W, Ma Y (1999) Mining association rules with multiple minimum supports. In: Proceedings of the Fifth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '99), Association for Computing Machinery, New York, S 337–341
6. Bayardo R J, Agrawal R, Gunopulos D (1999) Constraint-based rule mining in large, dense databases. In: Proceedings 15th International Conference on Data Engineering (Cat. No.99CB36337), Sydney, S 188–197
7. Pasquier N, Bastide Y, Taouil R, Lakhal L (1999) Discovering Frequent Closed Itemsets for Association Rules. In: Proceedings of the 7th International Conference on Database Theory (ICDT '99), Springer, Berlin, S 398–416
8. Pei J, Dong G, Zou W, Han J (2004) Mining condensed frequent-pattern bases. *Knowledge Information Systems* 6:570–594
9. Calders T, Goethals B (2002) Mining all non-derivable frequent itemsets. In: Elomaa T, Mannila H, Toivonen H (Hrsg) *Principles of data mining and knowledge discovery*. Springer, Berlin, S 74–86
10. Muhonen J, Toivonen H (2006) Closed non-derivable itemsets. In: Fürnkranz J, Scheffer T, Spiliopoulou M (Hrsg) *Knowledge discovery in databases (PKDD 2006)*. Springer, Berlin, S 601–608
11. Wrobel S (1997) An Algorithm for Multi-Relational Discovery of Subgroups. In: Proceedings of the First European Symposium on Principles of Data Mining and Knowledge Discovery (PKDD '97), Springer, Berlin, S 78–87
12. Atzmueller M (2015) Subgroup Discovery – Advanced Review. *WIREs: Data Mining and Knowledge Discovery* 5(1):35–49
13. Herrera F, Carmona CJ, Gonzalez P, Del Jesus MJ (2011) An overview on subgroup discovery: foundations and applications. *Knowl Inf Syst* 29:495–525
14. Atzmueller M, Lemmerich F (2009) Fast subgroup discovery for continuous target concepts. In: Rauch J, Raś ZW, Berka P, Elomaa T (Hrsg) *Foundations of intelligent systems*. Springer, Berlin, S 35–44
15. Zhang T (2000) Association rules. In: Terano T, Liu H, Chen A L P (Editors) *Knowledge discovery and data mining. Current issues and new applications*. Springer, Berlin, S 245–256
16. Leeuwen M, Knobbe A (2012) Diverse subgroup set discovery. *Data Min Knowl Disc* 25:208–242
17. Kavsek B, Lavrac N (2006) APRIORI-SD: Adapting Association Rule Learning to Subgroup Discovery. *Applied Artificial Intelligence* 20(7):543–583
18. Hammesfahr J (2020) Subspace Exploration: Identifikation relevanter Zusammenhänge in Suchräumen. Master-Thesis. Hochschule für Technik und Wirtschaft Berlin, Berlin
19. Lavrac N, Cestnik B, Gamberger D, Flach P (2004) Decision support through subgroup discovery: three case studies and the lessons learned: Special Issue: Data Mining Lessons Learned. *Machine Learning* 57, S 115–143

Joshua Hammesfahr studierte Wirtschaftsinformatik in Kooperation mit dem Unternehmen SAP SE, zunächst im Rahmen eines dualen Studiums an der DHBW Ravensburg, anschließend im Zuge eines Masterandenprogrammes an der HTW Berlin. Während dieser Zeit sammelte er viel Erfahrung in diversen theoretischen Forschungsgebieten sowie praktischen Anwendungsszenarien der Wirtschaftsinformatik. Schwerpunktmäßig war er dabei im Bereich der Applikationsentwicklung sowie der technischen Beratung für Cloudanwendungen in der Logistik tätig. Seit dem Abschluss seines Studiums mit einer Masterarbeit im Bereich künstlicher Intelligenz (2020) arbeitet er in der Qualitätssicherung für die Entwicklung der Datenbank SAP HANA.

Prof. Dr. Martin Spott studierte Technomathematik (Mathematik mit Nebenfächern Informatik und Elektrotechnik) an der Universität Karlsruhe (KIT) und promovierte dort an der Fakultät für Informatik bei Prof. Dr. Gerhard Goos im Bereich Künstlicher Intelligenz. Im Anschluss wechselte er in die Forschungsabteilung der British Telecommunications plc (BT) im englischen Ipswich, wo er über 15 Jahre in maschinellem Lernen geforscht und Erkenntnisse auf praktische Probleme angewandt hat. Sehr früh schon hat er an der Automatisierung von maschinellem Lernen gearbeitet und sich folgend mit der Frage beschäftigt, wie Mensch und Maschine in Kollaboration datenanalytische Probleme lösen können. Explainable AI, Visual Analytics und Human Computer Interaction gehen dabei Hand in Hand. Als Chief Analytics Researcher bei BT hat er eng mit Gruppen an der Cambridge University, UK, sowie am MIT CSAIL, Cambridge, MA (Visiting Researcher) zusammengearbeitet, bevor er 2016 als Professor für Data Science an die HTW Berlin wechselte.