

Inhaltsverzeichnis

1	Einleitung	1
1.1	Problemstellung	1
1.2	Zielsetzung	1
1.3	Forschungsfragen	1
1.4	Aufbau der Arbeit	1
2	Theoretische Grundlagen und Stand der Technik	3
2.1	Explorative Datenanalyse (EDA)	3
2.2	Large Language Models (LLMs)	5
2.3	LLMs in der Datenanalyse	6
2.4	Zuverlässigkeit und Grenzen LLM-gestützter Analyse	8
3	Methodik	11
3.1	Forschungsdesign	11
3.2	Untersuchungsansatz	11
3.3	Beschreibung des Analyse-Setups	12
3.4	Evaluationskriterien	12
3.5	Datengrundlage	12
	Literaturverzeichnis	13

Abbildungsverzeichnis

Tabellenverzeichnis

1 Einleitung

1.1 Problemstellung

1.2 Zielsetzung

1.3 Forschungsfragen

/todoUntersucht wird in der Arbeit die Datenkonsistenz und Zuverlässigkeit in der LLM-gestützten explorativen Datenanalyse.

FF1 Inwieweit basieren LLM-gestützte Explorative Datenanalyse (EDA)-Ergebnisse auf den bereitgestellten Daten und nicht auf vortrainiertem Wissen der Modelle?

FF2 Wie genau stimmen die Ausgaben von Large Language Models (LLMs) mit manuell berechneten Referenzwerten überein und welche Abweichungen treten auf?

FF3 Welchen Einfluss hat die iterative Mensch-LLM-Interaktion auf die Konsistenz und Qualität der Analyseergebnisse?

FF4 Über welches methodische Vorgehen zur explorativen Datenanalyse verfügen LLMs?

1.4 Aufbau der Arbeit

2 Theoretische Grundlagen und Stand der Technik

2.1 Explorative Datenanalyse (EDA)

Der Begriff der explorativen Datenanalyse geht auf Tukey (1977) zurück, der damit einen Analyseansatz prägte, bei dem Daten zunächst offen und grafisch gestützt untersucht werden, um Muster und Auffälligkeiten zu erkennen und Hypothesen zu gewinnen, statt vorab festgelegte Annahmen konfirmatorisch zu prüfen. Heute wird die EDA als ein iterativer Analyseprozess verstanden, in dessen Verlauf ein Datensatz systematisch untersucht wird, um Strukturen zu erkennen, Anomalien wie Ausreißer aufzudecken sowie erste Hypothesen zu generieren und vorläufig zu bewerten (Langer & Meisen, 2019). Im Rahmen dieser Methodik kommen primär deskriptive Statistiken und visuelle Werkzeuge zum Einsatz, um aussagekräftige Hinweise aus den Daten zu gewinnen (Rahmany et al., 2020).

Ein zentrales Merkmal der EDA ist ihr iterativer Charakter. Sie stellt keinen einmaligen, abgeschlossenen Prozess dar, sondern umfasst mehrere aufeinander aufbauende Analyseschritte, bis ein hinreichendes Verständnis der Daten erreicht ist (Rahmany et al., 2020). Da dieser Prozess nicht rein automatisiert abläuft, hängt die Qualität der Ergebnisse maßgeblich von der Fähigkeit des Analysten ab, die richtigen Fragen zu stellen und eine geeignete Analyseinteraktion durchzuführen, um die Daten sinnvoll zu interpretieren (Langer & Meisen, 2019).

Zur strukturierten Durchführung beschreiben Rahmany et al. (2020) sechs aufeinander aufbauende Schritte. Der Prozess beginnt mit der formalen Erfassung, bei der die vorhandenen Variablen nach Datentyp und Bedeutung erfasst und klassifiziert werden. Ob eine Variable nominal, ordinal, diskret oder stetig skaliert ist, bestimmt unmittelbar, welche statistischen Verfahren auf sie anwendbar sind. Darauf aufbauend erfolgt die univariate Analyse, in der jede Variable einzeln hinsichtlich zentraler Tendenz und Streuung untersucht wird, um die Form der Verteilung zu erfassen und auffällige Muster frühzeitig zu erkennen. Im dritten Schritt werden Zusammenhänge zwischen den Attributen untersucht, insbesondere Korrelationen, Kovarianzen und Streudiagramme.

Darauf folgt die Identifikation auffälliger Muster wie fehlender oder ungewöhnlicher Werte, die vor der weiteren Analyse behandelt werden müssen, um die Ergebnisse nicht zu verzerren. Im fünften Schritt werden Ausreißer erkannt, also Datenpunkte, die deutlich von der übrigen Verteilung abweichen; sie können die Schlussfolgerungen einer Analyse beeinflussen und zu ungenauen Befunden führen. Abschließend umfasst das Feature Engineering die Aufbereitung der Rohdaten für weiterführende Verfahren, etwa für den Einsatz in Modellen des maschinellen Lernens (Rahmany et al., 2020).

Unabhängig von der genauen Prozessphase lassen sich die in der EDA eingesetzten Techniken nach Rahmany et al. (2020) grundsätzlich in zwei Kategorien unterteilen: deskriptive Statistiken zur quantitativen Beschreibung der Daten sowie grafische Methoden zur visuellen Exploration (Rahmany et al., 2020).

Deskriptive Statistiken dienen der Zusammenfassung qualitativer wie quantitativer Daten und zugleich der Prüfung, ob die Daten für weiterführende Analysen geeignet sind. Nach der Anzahl der betrachteten Variablen wird dabei zwischen univariater, bivariater und multivariater Analyse unterschieden: Die univariate Analyse betrachtet ausschließlich eine einzelne Variable, die bivariate den Zusammenhang zweier Variablen, während die multivariate Analyse mehrere Variablen und deren Beziehungen zugleich einbezieht und dadurch deutlich aufwendiger ist. Hinsichtlich der verwendeten Maße wird zwischen zentraler Tendenz und Streuung unterschieden. Zu den Maßen der zentralen Tendenz zählen Mittelwert, Median und Modus, wobei der Median den mittleren Wert einer der Größe nach geordneten Datenreihe bezeichnet und dem zweiten Quartil entspricht. Streuungsmaße wie Varianz, Spannweite und Standardabweichung beschreiben demgegenüber, wie weit die Werte um diesen Mittelpunkt verteilt sind.

Die grafischen Methoden dienen der visuellen Aufbereitung der Daten mit dem Ziel, handlungsrelevante Erkenntnisse zu gewinnen. Die Wahl der Darstellung richtet sich dabei nach dem Datentyp; Histogramme und Boxplots kommen etwa sowohl für univariate als auch für bivariate Daten zum Einsatz (Rahmany et al., 2020).

Zur Identifikation von Ausreißern schlägt Tukey (1977) eine Faustregel vor, die auf dem Abstand zwischen den Quartilen beruht. Ausgehend vom Interquartilsabstand wird ein Schritt als das 1,5-fache dieses Abstands definiert. Werte, die mehr als einen Schritt außerhalb der Quartile liegen, gelten als auffällig. Dieses Kriterium bildet die Grundlage der bis heute gebräuchlichen 1,5-fachen Interquartilsregel und ist zugleich das Konstruktionsprinzip des Box-Plots, bei dem die Box von Quartil zu Quartil reicht und durch den Median geteilt wird (Tukey, 1977).

Die bloße Anwendungen dieser Techniken macht jedoch keine gehaltvolle Analyse aus. Koesten et al. (2021) untersuchen, wie Personen vorgehen, wenn sie einen Datensatz verstehen wollen und beobachten dabei Aktivitäten, die über das Berechnen von Kenn-

zahlen hinausreichen. Auf einer ersten Ebene setzen sich die Untersuchten vertieft mit dem Inhalt der Daten auseinander, indem sie Beziehungen zwischen Variablen herstellen, einzelne Werte exemplarisch heranziehen, die Datenqualität einschätzen und Unsicherheiten hinterfragen, etwa die Bedeutung fehlender Werte oder unerklärter Abkürzungen. Auf einer weiteren Ebene ordnen sie die Daten in ihren Entstehungs- und Anwendungskontext ein, indem sie deren Granularität, den ursprünglichen Erhebungszweck sowie die Repräsentativität für die zugrunde liegende Grundgesamtheit hinterfragen (Koesten et al., 2021).

Daraus lässt sich ableiten, dass die Güter einer explorativen Analyse nicht allein an der Korrektheit der berechneten Werten zu bemessen ist. Eine Aussage kann rechnerisch zutreffen und gleichwohl analytisch dürftig bleiben, wenn sie sich auf die Wiedergabe von Kennzahlen beschränkt. In Anlehnung an die von Koesten et al. (2021) beobachteten Aktivitäten wird eine Interpretation in der vorliegenden Arbeit dann als gehaltvoll verstanden, wenn sie Zusammenhänge zwischen Variablen herstellt, ihre Aussagen mit konkreten Werten aus dem Datensatz belegt, Auffälligkeiten und Unsicherheiten benennt und die Grenzen ihrer Aussagekraft reflektiert. Die Interpretationsqualität stellt damit eine von der faktischen Korrektheit zu unterscheidende Bewertungsdimension dar. Dies gilt umso mehr, wenn Analyseschritte nicht von Menschen, sondern von LLMs ausgeführt werden.

2.2 Large Language Models (LLMs)

LLMs sind neuronale Sprachmodelle, die auf Basis der Transformer-Architektur trainiert werden. Der Transformer verarbeitet eine Eingabesequenz nicht schrittweise, sondern setzt ihre Elemente über einen Attention-Mechanismus zueinander in Beziehung. In den Self-Attention-Schichten kann jede Position einer Sequenz auf alle übrigen Positionen zugreifen und deren Relevanz für den jeweiligen Kontext gewichten (Vaswani et al., 2017). Für die Datenanalyse bedeutet dies, dass ein im Prompt bereitgestellter Datensatz als Ganzes in die Verarbeitung eingeht und einzelne Werte zueinander in Bezug gesetzt werden können. Die Wissensgrundlage dieser Modelle entsteht in der Vortrainingsphase, in der das Modell auf umfangreichen Textkorpora trainiert wird, um die Wahrscheinlichkeitsverteilung über Tokenfolgen zu erlernen und sukzessive den jeweils nächsten Token einer Sequenz vorherzusagen (Brown et al., 2020). Durch diesen Prozess werden sprachliche Muster, faktisches Wissen und prozedurale Zusammenhänge implizit in den Modellparametern kodiert. Zur Beantwortung einer Anfrage greift das Modell nicht auf eine externe Wissensquelle zu, sondern ausschließlich auf das in den Gewichten gespeicherte Wissen (Brown et al., 2020). Aus dieser rein parametrischen Wissensrepräsentation resultiert jedoch eine methodische Einschränkung. Da das

Modell nicht zwischen erlerntem Vorwissen und den im Prompt bereitgestellten Daten unterscheidet, besteht die Gefahr, dass Ausgaben stärker durch statistisch häufige Muster im Trainingskorpus geprägt sind als durch die tatsächlichen Eigenschaften des analysierten Datensatzes (Wang et al., 2024). Bender et al. (2021) bezeichnen LLMs in diesem Zusammenhang als stochastische Papageien: Modelle, die sprachliche Formen reproduzieren, ohne notwendigerweise die zugrundeliegenden Inhalte zu verstehen.

Die operative Steuerung dieses Modellverhaltens erfolgt zur Laufzeit maßgeblich durch den Eingabe-Prompt. Durch In-Context Learning kann ein Modell allein auf Basis von Beispielen oder Anweisungen im Prompt auf neue Aufgaben ausgerichtet werden, ohne dass eine Anpassung der Modellgewichte erforderlich ist (Brown et al., 2020). Eine für analytische Aufgaben besonders relevante Strategie ist Chain-of-Thought-Prompting, bei dem das Modell angewiesen wird, Zwischenschritte explizit auszuformulieren, bevor es eine Antwort generiert (Wei et al., 2023). Im Kontext der EDA erweitert sich diese Prompt-Ebene zu einer iterativen Mensch-Modell-Interaktion. Da jede Modellantwort in den nachfolgenden Prompt einfließt, entstehen mehrstufige Analyseprozesse, in denen frühe Ungenauigkeiten in späteren Schritten fortgeführt oder verstärkt werden können (Langer & Meisen, 2019).

Ab einer bestimmten Modellgröße entstehen Fähigkeiten, die bei kleineren Modellen nicht beobachtet werden und nicht linear aus dem Trainingsumfang ableitbar sind (Wei et al., 2022). Gleichzeitig ist bei der Verarbeitung strukturierter Daten schwer zu unterscheiden, ob Ausgaben auf echtem Generalisierungsvermögen oder auf der Reproduktion gelernter Muster beruhen (Wang et al., 2024).

2.3 LLMs in der Datenanalyse

Die zuvor beschriebenen Fähigkeiten von LLMs werden auch für Aufgaben der Datenanalyse genutzt (Cheng et al., 2023; Li et al., 2024). Grundlage hierfür ist ihre Fähigkeit, natürlichsprachliche Anfragen in ausführbaren Programmcode zu überführen (Chen et al., 2021). Damit verschiebt sich der Untersuchungsgegenstand von den sprachlichen Fähigkeiten der Modelle hin zu ihrer Anwendung auf strukturierten Daten.

Einen umfassenden Ansatz in dieser Richtung verfolgen Cheng et al. (2023), die GPT-4 als eigenständigen Datenanalysten einsetzen und den Arbeitsablauf in Datenextraktion, Visualisierung und Analyse gliedern. Ihr Ansatz folgt dem dreistufigen Schema aus Code-Generierung, Code-Ausführung und anschließender Analysegenerierung, das bei Bedarf um externes Wissen ergänzt wird. In ihren Experimenten erreicht das Modell eine mit erfahrenen menschlichen Analytistinnen und Analysten vergleichbare Qualität und übertrifft das Niveau von Berufseinsteigern, bei zugleich geringeren Kosten und

kürzerer Bearbeitungszeit (Cheng et al., 2023).

Während dieser Ansatz von einer einmaligen, eindeutig formulierten Anfrage ausgeht, argumentieren Li et al. (2024), dass reale Analyseprozesse interaktiv verlaufen, da Nutzerintentionen häufig uneindeutig sind und Analysestrategien an Zwischenergebnisse angepasst werden. Sie beschreiben interaktive Datenanalyse als eine Abfolge miteinander verknüpfter Nutzer-Agent-Interaktionen und unterscheiden verschiedene Agentenaktionen, darunter das Stellen von Rückfragen, das Treffen begründeter Annahmen sowie die Korrektur und Aktualisierung von Code. Zur Verbesserung dieser Agenten schlagen sie eine Reflexionsstrategie vor, die aus erfolgreichen Interaktionsverläufen lernt und die relative Leistung um bis zu 44,5% steigert. Zugleich beobachten sie, dass eine zu starke Orientierung an der Interaktionshistorie das eigenständige Schließen aus dem aktuellen Kontext beeinträchtigt und daher gegen die Reaktion auf die unmittelbare Eingabe abzuwägen ist (Li et al., 2024).

Über solche Systeme hinaus wurden Benchmarks vorgeschlagen, die LLM-gestützte Datenanalyse systematisch bewerten, etwa InfiAgent-DABench (Hu et al., 2024). Neben der reinen Leistungsmessung rückt dabei der für diese Arbeit zentrale Unterscheidung zwischen datenbasierten und wissensbasierten Ausgaben in den Blick. Li et al. (2024) adressieren sie explizit, indem sie mit nutzerdefinierten Bibliotheken prüfen, ob ein Modell die bereitgestellten Funktionen tatsächlich verarbeitet oder auf memorisierte Standardsyntax zurückgreift. Diese Spannung zwischen tatsächlicher Datenverarbeitung und dem Rückgriff auf memoriertes Wissen zieht sich als grundlegende Frage durch die Bewertung LLM-gestützter Datenanalyse.

Speziell für die EDA stellt der Einsatz von LLMs eine jüngere Entwicklung dar, die klassische Analysemethoden nicht ersetzt, sondern um generative Fähigkeiten erweitert (Zhecheva, 2024). Empirische Untersuchungen zeigen, dass die Qualität der LLM-Ausgaben stark von der Struktur und dem Informationsgehalt des Eingabe-Prompts abhängt: Bei klar strukturierten Prompts, die den zugrundeliegenden Datensatz enthalten, stimmen die LLM-Ausgaben weitgehend mit unabhängig berechneten Referenzwerten überein. Aufgaben, die ein semantisches Verständnis der Datendomäne erfordern, werden hingegen deutlich schlechter bewältigt, was auf Grenzen der faktischen Verlässlichkeit bei Analyseaufgaben hinweist (Zhecheva, 2024).

Die dargestellten Arbeiten zeigen Anwendungen LLMs-gestützter Datenanalyse, verweisen jedoch auf Einschränkungen wie fehlerhafte Berechnungen (Cheng et al., 2023) oder unbegründete Annahmen (Li et al., 2024). Diese Zuverlässigkeitsaspekte werden im folgenden Abschnitt vertieft.

2.4 Zuverlässigkeit und Grenzen LLM-gestützter Analyse

Bevor die spezifischen Fehlerquellen LLM-gestützter Analyse betrachtet werden, ist zu klären, worin die Zuverlässigkeit eines analytischen Systems besteht. Bornschlegl (2024) überträgt die Dimensionen zwischenmenschlichen Vertrauens auf die Vertrauenswürdigkeit technischer Systeme und benennt für deren Ausgaben insbesondere Reproduzierbarkeit und Validität. Reproduzierbarkeit bezeichnet die Fähigkeit, mit denselben Eingabedaten, Rechenschritten, Methoden und demselben Code konsistente Ergebnisse zu erzielen. Validität beschreibt den Grad, in dem die erzeugten Daten oder Ergebnisse korrekt sind. Übertragen auf die LLM-gestützte explorative Datenanalyse beschreibt Reproduzierbarkeit demnach die Stabilität der Ergebnisse bei gleicher Eingabe und Validität ihre Übereinstimmung mit den tatsächlichen Eigenschaften der Daten (Bornschlegl, 2024). Inwieweit diese beiden Anforderungen durch charakteristische Eigenschaften von LLMs beeinträchtigt werden können, ist Gegenstand der folgenden Betrachtungen.

Ji Ziwei et al. (2022) weisen darauf hin, dass moderne Deep-Learning-Modelle zwar sprachlich kohärente Ausgaben erzeugen, jedoch häufig Inhalte produzieren, die weder mit der zugrundeliegenden Eingabequelle übereinstimmen noch faktisch korrekt sind. Da solche als Halluzination bezeichnete Ausgaben definitionsgemäß von den tatsächlichen Fakten oder der bereitgestellten Eingabe abweichen, betreffen sie unmittelbar die zuvor eingeführte Validität. Solche Angaben lassen sich in zwei Typen unterscheiden. Faktische Halluzination bezeichnet die Diskrepanz zwischen generiertem Inhalt und verifizierbaren Fakten, während treuebezogene Halluzinationen die Abweichung von der Nutzeranweisung oder dem bereitgestellten Eingabekontext sowie eine fehlende Selbstkonsistenz umfassen (Bai et al., 2025). Für die vorliegende Arbeit ist vor allem der zweite Typ relevant, da der analysierte Datensatz den Eingabekontext bildet, von dem eine treuebezogene Halluzination abweicht. Erschwerend kommt hinzu, dass halluzinierte Ausgaben aufgrund ihrer sprachlichen Flüssigkeit und scheinbaren Kontextverankerung kaum von faktisch korrekten Inhalten zu unterscheiden sind (Ji Ziwei et al., 2022).

Dass Halluzinationen messbar und modellabhängig sind, zeigt eine Untersuchung zu fabrizierten Literaturangaben. Agrawal et al. (2024) bestimmen für die Generierung wissenschaftlicher Referenzen modellspezifische Halluzinationsraten, die zwischen 47 Prozent für GPT-4 und über 76 Prozent für kleinere Modelle liegen, wobei leistungsfähigere Modelle durchgängig geringere Raten aufweisen. Zugleich betonen sie, dass Halluzination kein rein binäres Merkmal darstellt, da sich etwa eine generierte Referenz mit Teilen eines existierenden Titels nicht eindeutig klassifizieren lässt (Agrawal

et al., 2024). Ein anschauliches Beispiel aus der explorativen Datenanalyse ist der von GPT-4 erzeugte, nicht existente Titel „Exploratory Data Analysis and the Role of Visualization“, dem das Modell zudem den Autor *John W. Tukey* der klassischen Arbeit zur explorativen Datenanalyse zuschrieb (Agrawal et al., 2024).

Über die empirische Beobachtung hinaus wird die Unvermeidbarkeit von Halluzination theoretisch begründet. Xu et al. (2025) zeigen mit lerntheoretischen Mitteln, dass LLMs nicht alle berechenbaren Funktionen erlernen können und als allgemeine Problemlöser daher zwangsläufig halluzinieren. Für die Analysepraxis bedeutsam ist ihre Schlussfolgerung, dass sich Halluzination nicht allein durch veränderte Prompts beseitigen lässt und die Wirksamkeit des in Abschnitt 2.3 beschriebenen Chain-of-Thought-Promptings somit auf bestimmte Aufgabentypen begrenzt bleibt. Als wirksamerer Ansatzpunkt gilt die Anreicherung mit externem Wissen, etwa durch Wissensdatenbanken oder Werkzeuge, da dem Modell so Information über die Zielfunktion zugeführt wird, die über die reinen Trainingsdaten hinausgeht (Xu et al., 2025). In dieselbe Richtung weist die Untersuchung von Zheng et al. (2024) zur Verlässlichkeit von LLMs als Wissensbasis. Ein faktentreues Modell gibt bekanntes Wissen korrekt wieder und stellt zu unbekannten keine Behauptungen auf, wobei sich die Überschätzung des eigenen Wissens besonders bei numerischen und zeitbezogenen Fragen zeigt. Konsistenz allein ist dabei kein hinreichendes Gütekriterium, da auch fehlerhafte Antworten konsistent wiederholt werden können (Zheng et al., 2024).

Besondere Bedeutung erhält in diesem Zusammenhang die in Abschnitt 2.2 beschriebene rein parametrische Wissensrepräsentation. Ein Modell unterscheidet nicht zwischen erlerntem Vorwissen und den im Prompt bereitgestellten Daten (Wang et al., 2024) und kann einen bekannten Datensatz daher vermeintlich korrekt beschreiben, ohne die konkret bereitgestellten Werte praktisch zu verarbeiten. Dieser Konflikt zwischen datenbasierten und wissensbasierten Ausgaben markiert eine zentrale Grenze der Verlässlichkeit LLM-gestützter Datenanalyse.

Zusammenfassend zeigen die dargestellten Eigenschaften, dass LLMs die benannten Anforderungen an Reproduzierbarkeit und Validität nur eingeschränkt erfüllen. Halluzinationen gefährden die Validität, indem sie inhaltlich nicht gedeckte Ausgaben erzeugen und ihre begründete Unvermeidbarkeit schließt eine vollständige Beseitigung aus (Xu et al., 2025). Hinzu kommt, dass ein Modell aufgrund seiner rein parametrischen Wissensrepräsentation dazu neigen kann, Ausgaben aus vortrainiertem Wissen statt aus den bereitgestellten Daten zu generieren. Für die LLM-gestützte explorative Datenanalyse folgt daraus, dass die Übereinstimmung der Modellausgaben mit dem tatsächlichen Dateninhalt nicht vorausgesetzt, sondern eigens geprüft werden muss. Im Kontext dieser Arbeit wird Datenkonsistenz als die Übereinstimmung zwischen einer generierten Aussage und dem zugrunde liegenden Datensatz verstanden. Sie stellt eine

wesentliche Voraussetzung für die Beurteilung der Verlässlichkeit generierter Inhalte dar.

3 Methodik

3.1 Forschungsdesign

Die vorliegende Arbeit verfolgt ein empirisch-experimentelles Forschungsdesign. Ziel ist es, die Zuverlässigkeit und Datentreue von LLM-gestützter explorativer Datenanalyse unter kontrollierten Bedingungen systematisch zu untersuchen. Dazu werden die Ausgaben zweier LLMs mit einem rechnerisch ermittelten Referenzwert verglichen, der auf Basis denselben Eingabedaten mit etablierten statistischen Methoden berechnet wurde. Der experimentelle Ansatz ermöglicht es, Zusammenhänge zwischen der Art der Eingabedaten, der Gestaltung der Prompts sowie der Qualität der generierten Analyseergebnisse zu untersuchen.

3.2 Untersuchungsansatz

Experiment 1 – Referenzanalyse

Das erste Experiment adressiert die Forschungsfragen 1 und 2 und bildet die Grundlage der gesamten Untersuchung. Zunächst werden auf Basis des gewählten Datensatzes mittels Python und der Bibliothek pandas statistisch korrekte Referenzwerte berechnet. Diese umfassen deskriptive Kennzahlen wie Mittelwert, Median und Standardabweichung zentraler Variablen sowie bivariate Zusammenhänge in Form von Korrelationskoeffizienten. Die so ermittelten Werten bilden den Richtwert, anhand dessen die LLM-Ausgaben bewertet werden.

Im Anschluss werden beide LLMs identische Prompts sowie der vollständige Datensatz über die jeweilige Programmierschnittstelle übergeben. Die generierten Analyseergebnisse werden anschließend mit den Referenzwerten verglichen und anhand des in Abschnitt ?? beschriebenen Evaluationsframeworks bewertet.

3.3 Beschreibung des Analyse-Setups

3.4 Evaluationskriterien

3.5 Datengrundlage

Literaturverzeichnis

- Agrawal, A., Suzgun, M., Mackey, L., & Kalai, A. T. (2024, 20. März). Do Language Models Know When They're Hallucinating References? <https://doi.org/10.48550/arXiv.2305.18248>
- Bai, Z., Wang, P., Xiao, T., He, T., Han, Z., Zhang, Z., & Shou, M. Z. (2025, 1. April). Hallucination of Multimodal Large Language Models: A Survey. <https://doi.org/10.48550/arXiv.2404.18930>
- Bender, E. M., Gebru, T., McMillan-Major, A., & Shmitchell, S. (2021). On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, 610–623. <https://doi.org/10.1145/3442188.3445922>
- Bornschlegl, M. (2024). Towards Trustworthiness in AI-based Big Data Analysis. <https://doi.org/10.18445/20240426-221234-0>
- Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D., Wu, J., Winter, C., & Amodei, D. (2020, 28. Mai). *Language Models are Few-Shot Learners*. <https://doi.org/10.48550/arXiv.2005.14165>
- Chen, M., Tworek, J., Jun, H., Yuan, Q., Pinto, H. P. d. O., Kaplan, J., Edwards, H., Burda, Y., Joseph, N., Brockman, G., Ray, A., Puri, R., Krueger, G., Petrov, M., Khlaaf, H., Sastry, G., Mishkin, P., Chan, B., Gray, S., ... Zaremba, W. (2021, 14. Juli). Evaluating Large Language Models Trained on Code. <https://doi.org/10.48550/arXiv.2107.03374>
Comment: corrected typos, added references, added authors, added acknowledgements.
- Cheng, L., Li, X., & Bing, L. (2023). Is GPT-4 a Good Data Analyst? In H. Bouamor, J. Pino & K. Bali (Hrsg.), *Findings of the Association for Computational Linguistics: EMNLP 2023* (S. 9496–9514). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2023.findings-emnlp.637>
Neu für 2.3.
- Hu, X., Zhao, Z., Wei, S., Chai, Z., Ma, Q., Wang, G., Wang, X., Su, J., Xu, J., Zhu, M., Cheng, Y., Yuan, J., Li, J., Kuang, K., Yang, Y., Yang, H., & Wu, F. (2024, 11. März). InfiAgent-DABench: Evaluating Agents on Data Analysis

- Tasks. <https://doi.org/10.48550/arXiv.2401.05507>
 Comment: 27 pages, 7 figures, work in progress.
- Ji Ziwei, NAYEON LEE, RITA FRIESKE, TIEZHENG YU, DAN SU, HO SHU CHAN, ANDREA MADOTTO & PASCALE FUNG. (2022). Survey of Hallucination in Natural Language Generation. *ACM Comput. Surv.*, (1), 1–59. <https://doi.org/https://doi.org/10.48550/arXiv.2202.03629>
- Koesten, L., Gregory, K., Groth, P., & Simperl, E. (2021). Talking datasets: Understanding data sensemaking behaviours. *International Journal of Human-Computer Studies*, 146, 102562. <https://doi.org/10.1016/j.ijhcs.2020.102562>
- Langer, T., & Meisen, T. (2019). Towards Utilizing Domain Expertise for Exploratory Data Analysis. *Proceedings of the 12th International Symposium on Visual Information Communication and Interaction*, 1–5. <https://doi.org/10.1145/3356422.3356434>
- Li, J., Huo, N., Gao, Y., Shi, J., Zhao, Y., Qu, G., Wu, Y., Ma, C., Lou, J.-G., & Cheng, R. (2024, 8. März). Tapilot-Crossing: Benchmarking and Evolving LLMs Towards Interactive Data Analysis Agents. <https://doi.org/10.48550/arXiv.2403.05307>
 Comment: 30 pages, 7 figures.
- Rahmany, M., Zin, A. M., & Sundararajan, E. A. (2020). COMPARING TOOLS PROVIDED BY PYTHON AND R FOR EXPLORATORY DATA ANALYSIS. *IJISCS (International Journal of Information System and Computer Science)*, 4(3), 131. <https://doi.org/10.56327/ijiscs.v4i3.933>
- Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł. u., & Polosukhin, I. (2017). Attention is All you Need. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan & R. Garnett (Hrsg.), *Advances in Neural Information Processing Systems* (Bd. 30). Curran Associates, Inc. https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf
- Wang, X., Antoniadis, A., Elazar, Y., Amayuelas, A., Albalak, A., Zhang, K., & Wang, W. Y. (2024, 20. Juli). *Generalization v.s. memorization: Tracing language models' capabilities back to pretraining data* [arXiv.org]. Verfügbar 4. Juni 2026 unter <https://arxiv.org/abs/2407.14985v5>
- Wei, J., Tay, Y., Bommasani, R., Raffel, C., Zoph, B., Borgeaud, S., Yogatama, D., Bosma, M., Zhou, D., Metzler, D., Chi, E. H., Hashimoto, T., Vinyals, O., Liang, P., Dean, J., & Fedus, W. (2022, 26. Oktober). Emergent Abilities of Large Language Models. <https://doi.org/10.48550/arXiv.2206.07682>

-
- Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E., Le, Q., & Zhou, D. (2023, 10. Januar). Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. <https://doi.org/10.48550/arXiv.2201.11903>
- Xu, Z., Jain, S., & Kankanhalli, M. (2025, 13. Februar). Hallucination is Inevitable: An Innate Limitation of Large Language Models. <https://doi.org/10.48550/arXiv.2401.11817>
- Zhecheva, D. (2024). Exploratory Data Analysis and the Rise of Large Language Models - Gaming Industry Insights. *TEM Journal*, 13(1), 561–569. Verfügbar 28. Mai 2026 unter <https://www.ceeol.com/search/article-detail?id=1222943>
- Zheng, D., Lapata, M., & Pan, J. Z. (2024, 16. Dezember). How Reliable are LLMs as Knowledge Bases? Re-thinking Factuality and Consistency. <https://doi.org/10.48550/arXiv.2407.13578>

