

Inhaltsverzeichnis

1	Einleitung	1
1.1	Problemstellung	1
1.2	Zielsetzung	1
1.3	Forschungsfragen	1
1.4	Aufbau der Arbeit	1
2	Theoretische Grundlagen und Stand der Technik	2
2.1	Explorative Datenanalyse (EDA)	2
2.2	Large Language Models (LLMs)	6
2.3	LLMs in der Datenanalyse	7
2.4	Zuverlässigkeit und Grenzen LLM-gestützter Analyse	9
3	Methodik und Durchführung	13
3.1	Datengrundlage	13
3.1.1	Beschreibung des Datensatzes	13
3.1.2	Zweistufiger Datensatzaufbau	13
3.1.3	Referenzwertberechnung	14
3.2	Forschungsdesign	16
3.3	Untersuchungsansatz	16
3.3.1	Kategorie A: Faktische Fragen und Toleranzbänder	19
3.3.2	Kategorie B: Interpretative Fragen	19
3.3.3	Kategorie C: Halluzinationsfallen	21
3.3.4	Aggregation der Bewertung	22
3.4	Durchführung	23
4	Ergebnisse	24
4.1	Auswertung Experiment 0: Methodisches Vorwissen	24
4.2	Auswertung Experiment 1 – Referenzanalyse	26
4.2.1	Faktische Fragen (Kategorie A)	26

4.2.2	Interpretative Fragen (Kategorie B)	28
4.2.3	Halluzinationsfallen (Kategorie C)	31
Literaturverzeichnis		35

Abbildungsverzeichnis

2.1	Prozessschritte der explorativen Datenanalyse	3
2.2	Rechtsschiefe Verteilung am Beispiel MonthlyIncome	5
2.3	Datenbasierte und wissensbasierte Ausgaben	11

Tabellenverzeichnis

3.1	Bewertung faktischer Fragen (Kategorie A)	20
3.2	Bewertung interpretativer Fragen (Kategorie B)	21
3.3	Halluzinationsmaße für Kategorie C	22
4.1	Abweichungen von der vollen Punktzahl in Experiment 0	25
4.2	Ergebnisse der faktischen Fragen (Kategorie A)	26
4.3	Ergebnisse der interpretativen Fragen (Kategorie B)	29
4.4	Ergebnisse der Halluzinationsfällen (Kategorie C)	32

1 Einleitung

1.1 Problemstellung

1.2 Zielsetzung

1.3 Forschungsfragen

/todoUntersucht wird in der Arbeit die Datenkonsistenz und Zuverlässigkeit in der LLM-gestützten explorativen Datenanalyse.

- FF1** Inwieweit basieren LLM-gestützte Explorative Datenanalyse (EDA)-Ergebnisse auf den bereitgestellten Daten und nicht auf vortrainiertem Wissen der Modelle?
- FF2** Wie genau stimmen die Ausgaben von Large Language Models (LLMs) mit manuell berechneten Referenzwerten überein und welche Abweichungen treten auf?
- FF3** Welchen Einfluss hat die iterative Mensch-LLM-Interaktion auf die Konsistenz und Qualität der Analyseergebnisse?
- FF4** Über welches methodische Vorgehen zur explorativen Datenanalyse verfügen LLMs?

1.4 Aufbau der Arbeit

2 Theoretische Grundlagen und Stand der Technik

2.1 Explorative Datenanalyse (EDA)

Der Begriff der explorativen Datenanalyse geht auf Tukey (1977) zurück, der damit einen Analyseansatz prägte, bei dem Daten zunächst offen und grafisch gestützt untersucht werden, um Muster und Auffälligkeiten zu erkennen und Hypothesen zu gewinnen, statt vorab festgelegte Annahmen konfirmatorisch zu prüfen. Heute wird die EDA als ein iterativer Analyseprozess verstanden, in dessen Verlauf ein Datensatz systematisch untersucht wird, um Strukturen zu erkennen, Anomalien wie Ausreißer aufzudecken sowie erste Hypothesen zu generieren und vorläufig zu bewerten (Langer & Meisen, 2019). Im Rahmen dieser Methodik kommen primär deskriptive Statistiken und visuelle Werkzeuge zum Einsatz, um aussagekräftige Hinweise aus den Daten zu gewinnen (Rahmany et al., 2020).

Ein zentrales Merkmal der EDA ist ihr iterativer Charakter. Sie stellt keinen einmaligen, abgeschlossenen Prozess dar, sondern umfasst mehrere aufeinander aufbauende Analyseschritte, bis ein hinreichendes Verständnis der Daten erreicht ist (Rahmany et al., 2020). Da dieser Prozess nicht rein automatisiert abläuft, hängt die Qualität der Ergebnisse maßgeblich von der Fähigkeit des Analysten ab, die richtigen Fragen zu stellen und eine geeignete Analyseinteraktion durchzuführen, um die Daten sinnvoll zu interpretieren (Langer & Meisen, 2019).

Zur strukturierten Durchführung beschreiben Rahmany et al. (2020) sechs aufeinander aufbauende Schritte. Der Prozess beginnt mit der formalen Erfassung, bei der die vorhandenen Variablen nach Datentyp und Bedeutung erfasst und klassifiziert werden. Ob eine Variable nominal, ordinal, diskret oder stetig skaliert ist, bestimmt unmittelbar, welche statistischen Verfahren auf sie anwendbar sind. Darauf aufbauend erfolgt die univariate Analyse, in der jede Variable einzeln hinsichtlich zentraler Tendenz und Streuung

untersucht wird, um die Form der Verteilung zu erfassen und auffällige Muster frühzeitig zu erkennen. Im dritten Schritt werden Zusammenhänge zwischen den Attributen untersucht, insbesondere Korrelationen, Kovarianzen und Streudiagramme. Darauf folgt die Identifikation auffälliger Muster wie fehlender oder ungewöhnlicher Werte, die vor der weiteren Analyse behandelt werden müssen, um die Ergebnisse nicht zu verzerren. Im fünften Schritt werden Ausreißer erkannt, also Datenpunkte, die deutlich von der übrigen Verteilung abweichen; sie können die Schlussfolgerungen einer Analyse beeinflussen und zu ungenauen Befunden führen. Abschließend umfasst das Feature Engineering die Aufbereitung der Rohdaten für weiterführende Verfahren, etwa für den Einsatz in Modellen des maschinellen Lernens (Rahmany et al., 2020).




Abbildung 2.1: Sechs Schritte der explorativen Datenanalyse nach Rahmany et al. (2020). Der gestrichelte Pfeil kennzeichnet den iterativen Charakter des Prozesses.

Unabhängig von der genauen Prozessphase lassen sich die in der EDA eingesetzten Techniken nach Rahmany et al. (2020) grundsätzlich in zwei Kategorien unterteilen: deskriptive Statistiken zur quantitativen Beschreibung der Daten sowie grafische Methoden zur visuellen Exploration (Rahmany et al., 2020).

Deskriptive Statistiken dienen der Zusammenfassung qualitativer wie quantitativer Daten und zugleich der Prüfung, ob die Daten für weiterführende Analysen geeignet sind. Nach der Anzahl der betrachteten Variablen wird dabei zwischen univariater, bivariater und multivariater Analyse unterschieden: Die univariate Analyse betrachtet ausschließlich eine einzelne Variable, die bivariate den Zusammenhang zweier Variablen, während die multivariate Analyse mehrere Variablen und deren Beziehungen zugleich einbezieht und dadurch deutlich aufwendiger ist. Hinsichtlich der verwendeten Maße wird zwischen zentraler Tendenz und Streuung unterschieden. Zu den Maßen der zentralen Tendenz zählen Mittelwert, Median und Modus, wobei der Median den mittleren Wert einer

der Größe nach geordneten Datenreihe bezeichnet und dem zweiten Quartil entspricht. Streuungsmaße wie Varianz, Spannweite und Standardabweichung beschreiben demgegenüber, wie weit die Werte um diesen Mittelpunkt verteilt sind. Die Form einer Verteilung lässt sich anhand ihrer Symmetrie beschreiben. In einer symmetrischen Verteilung fallen Mittelwert, Median und Modus zusammen, wobei sie in einer schiefen Verteilung voneinander abweichen. Das Ausmaß dieser Abweichung ist ein Maß für die Schiefe (Boslaugh, 2012, S. 58). Bei einer rechtsschiefen Verteilung liegen die meisten Werte im unteren Bereich, während wenige hohe Werte einen langen Ausläufer nach rechts bilden. Da der Mittelwert im Gegensatz zum Median durch solche Extremwerte beeinflusst wird, ist bei ausgeprägter Schiefe der Median das aussagekräftige Lagemaß. Zur Annäherung an eine symmetrische Form können rechtsschiefe Daten zudem transformiert werden, etwa durch eine Wurzel oder eine Logarithmus-Transformation (Bornschlegl, 2024, S. 146). Während Lage- und Streuungsmaße einzelne Variablen beschreiben, erfasst der Produkt-Moment-Korrelationskoeffizient nach Pearson die Stärke und Richtung eines linearen Zusammenhangs zweier metrischer Variablen (Boslaugh, 2012, S. 178–189). Sein Wertebereich reicht von minus eins bis plus eins, wobei Werte nahe null einen schwachen und Werte nahe den Extremen einen starken Zusammenhang anzeigen. In welchem Maß die Variablen gleichgerichtete oder gegenläufige lineare Zusammenhänge aufweisen, hängt mit dem Vorzeichen zusammen. Da der Koeffizient ausschließlich lineare Zusammenhänge misst, schließt ein Wert nahe null einen nichtlinearen Zusammenhang nicht aus. Zudem lässt sich aus einer Korrelation kein kausaler Zusammenhang ableiten, da die gemeinsame Veränderung zweier Variablen auch auf eine dahinterliegende dritte Variable zurückgehen könnte (Boslaugh, 2012, S. 178–189).

Die grafischen Methoden dienen der visuellen Aufbereitung der Daten mit dem Ziel, handlungsrelevante Erkenntnisse zu gewinnen. Die Wahl der Darstellung richtet sich dabei nach dem Datentyp (Rahmany et al., 2020).

Zur Identifikation von Ausreißern schlägt Tukey (1977) eine Faustregel vor, die auf dem Abstand zwischen den Quartilen beruht. Ausgehend vom Interquartilsabstand wird ein Schritt als das 1,5-fache dieses Abstands definiert. Werte, die mehr als einen Schritt außerhalb der Quartile liegen, gelten als auffällig. Dieses Kriterium bildet die Grundlage der bis heute gebräuchlichen 1,5-fachen Interquartilsregel und ist zugleich das Konstruktionsprinzip des Box-Plots, bei dem die Box von Quartil zu Quartil reicht und durch den Median geteilt wird (Tukey, 1977).

Die bloße Anwendung dieser Techniken macht jedoch keine gehaltvolle Analyse aus.




Abbildung 2.2: Verteilung der Variable `MonthlyIncome` im verwendeten Datensatz. Der Mittelwert liegt rechts vom Median, was für eine rechtsschiefe Verteilung charakteristisch ist.

Koesten et al. (2021) untersuchen, wie Personen vorgehen, wenn sie einen Datensatz verstehen wollen und beobachten dabei Aktivitäten, die über das Berechnen von Kennzahlen hinausreichen. Auf einer ersten Ebene setzen sich die Untersuchten vertieft mit dem Inhalt der Daten auseinander, indem sie Beziehungen zwischen Variablen herstellen, einzelne Werte exemplarisch heranziehen, die Datenqualität einschätzen und Unsicherheiten hinterfragen, etwa die Bedeutung fehlender Werte oder unerklärter Abkürzungen. Auf einer weiteren Ebene ordnen sie die Daten in ihren Entstehungs- und Anwendungskontext ein, indem sie deren Granularität, den ursprünglichen Erhebungszweck sowie die Repräsentativität für die zugrunde liegende Grundgesamtheit hinterfragen (Koesten et al., 2021).

Daraus lässt sich ableiten, dass die Güte einer explorativen Analyse nicht allein an der Korrektheit der berechneten Werte zu bemessen ist. Eine Aussage kann rechnerisch zutreffen und gleichwohl analytisch dürftig bleiben, wenn sie sich auf die Wiedergabe von Kennzahlen beschränkt. In Anlehnung an die von Koesten et al. (2021) beobachteten Aktivitäten wird eine Interpretation in der vorliegenden Arbeit dann als gehaltvoll verstanden, wenn sie Zusammenhänge zwischen Variablen herstellt, ihre Aussagen mit konkreten Werten aus dem Datensatz belegt, Auffälligkeiten und Unsicherheiten benennt und die Grenzen ihrer Aussagekraft reflektiert. Die Interpretationsqualität stellt damit eine von der faktischen Korrektheit zu unterscheidende Bewertungsdimension dar. Dies

gilt umso mehr, wenn Analyseschritte nicht von Menschen, sondern von LLMs ausgeführt werden.

2.2 Large Language Models (LLMs)

LLMs sind neuronale Sprachmodelle, die auf Basis der Transformer-Architektur trainiert werden. Der Transformer verarbeitet eine Eingabesequenz nicht schrittweise, sondern setzt ihre Elemente über einen Attention-Mechanismus zueinander in Beziehung. In den Self-Attention-Schichten kann jede Position einer Sequenz auf alle übrigen Positionen zugreifen und deren Relevanz für den jeweiligen Kontext gewichten (Vaswani et al., 2017). Die Wissensgrundlage dieser Modelle entsteht in der Vortrainingsphase, in der das Modell auf umfangreichen Textkorpora trainiert wird, um die Wahrscheinlichkeitsverteilung über Tokenfolgen zu erlernen und sukzessive den jeweils nächsten Token einer Sequenz vorherzusagen (Brown et al., 2020). S. Cheng et al. (2024) unterscheiden zwischen parametrischem Wissen, das während des Vortrainings in den Modellparametern repräsentiert wird, und kontextuellem Wissen, das dem Modell bei der Anwendung zusätzlich bereitgestellt wird. Ihre Untersuchung zeigt, dass LLMs ihr parametrisches Wissen bei vorhandenem Kontext nicht durchgängig nutzen und sich teilweise auf die kontextuell bereitgestellten Informationen stützen. Widersprechen kontextuell bereitgestellte Informationen dem parametrischen Wissen, können Wissenskonflikte entstehen (Yuan et al., 2024). Übertragen auf die LLM-gestützte Datenanalyse stellt sich damit die Frage, in welchem Verhältnis das parametrische Vorwissen eines Modells zu den im Kontext bereitgestellten Daten steht. Bender et al. (2021) bezeichnen LLMs als stochastische Papageien und kritisieren damit die Reproduktion sprachlicher Formen, ohne dass daraus notwendigerweise ein Verständnis der zugrunde liegenden Inhalte folgt.

Die operative Steuerung dieses Modellverhaltens erfolgt zur Laufzeit maßgeblich durch den Eingabe-Prompt. Durch In-Context Learning kann ein Modell allein auf Basis von Beispielen oder Anweisungen im Prompt auf neue Aufgaben ausgerichtet werden, ohne dass eine Anpassung der Modellgewichte erforderlich ist (Brown et al., 2020). Eine für analytische Aufgaben besonders relevante Strategie ist Chain-of-Thought-Prompting, bei dem das Modell angewiesen wird, Zwischenschritte explizit auszuformulieren, bevor es eine Antwort generiert (Wei et al., 2023). Die EDA selbst ist dabei durch aufeinander aufbauende Analyseinteraktionen gekennzeichnet, deren Abfolge zur Gewinnung und Einordnung von Erkenntnissen beiträgt (Langer & Meisen, 2019).

Mit zunehmender Modellgröße treten Fähigkeiten auf, die bei kleineren Modellen nicht beobachtet werden. Wei et al. (2022) bezeichnen eine Fähigkeit als emergent, wenn sie in größeren Modellen auftritt und sich daher nicht durch die Leistung kleinerer Modelle vorhersagen lässt. Charakteristisch ist dabei ein Schwellenverhalten. Bis zu einer bestimmten Modellgröße bleibt die Leistung nahe dem Zufallsniveau, bevor sie ab einer kritischen Schwelle deutlich ansteigt. Dieses Verhalten beschreiben die Autoren als Phasenübergang. Die Skalierung von Sprachmodellen erfolgt dabei über den Rechenaufwand, die Anzahl der Modellparameter sowie den Umfang der Trainingsdaten.

Zu den von Wei et al. (2022) beobachteten emergenten Fähigkeiten zählen unter anderem mehrstellige Addition und Subtraktion, die Bearbeitung fachübergreifender Benchmarks sowie das Befolgen von Anweisungen. Auch das zuvor beschriebene Chain-of-Thought-Prompting wird als emergente Fähigkeit eingeordnet, da es erst ab einer bestimmten Modellgröße zu einer Leistungssteigerung führt. Da sich das Auftreten solcher Fähigkeiten nicht unmittelbar aus der Leistung kleinerer Modelle vorhersagen lässt, bleibt offen, ob auch methodisches Wissen über statistische Verfahren auf diese Weise erworben wird. Zudem ist bei der Analyse strukturierter Daten häufig schwer zu beurteilen, ob die Ausgaben auf einer tatsächlichen Generalisierung oder auf der Reproduktion gelernter Muster beruhen (X. Wang et al., 2024).

2.3 LLMs in der Datenanalyse

Die zuvor beschriebenen Fähigkeiten von LLMs werden auch für Aufgaben der Datenanalyse genutzt (L. Cheng et al., 2023; Li et al., 2024). Grundlage hierfür ist ihre Fähigkeit, natürlichsprachliche Anfragen in ausführbaren Programmcode zu überführen (Chen et al., 2021). Damit verschiebt sich der Untersuchungsgegenstand von den sprachlichen Fähigkeiten der Modelle hin zu ihrer Anwendung auf strukturierten Daten.

Einen umfassenden Ansatz in dieser Richtung verfolgen L. Cheng et al. (2023), die GPT-4 als eigenständigen Datenanalysten einsetzen und den Arbeitsablauf in Datenextraktion, Visualisierung und Analyse gliedern. Ihr Ansatz folgt dem dreistufigen Schema aus Code-Generierung, Code-Ausführung und anschließender Analysegenerierung, das bei Bedarf um externes Wissen ergänzt wird. In ihren Experimenten erreicht das Modell eine mit erfahrenen menschlichen Analytistinnen und Analysten vergleichbare Qualität und übertrifft das Niveau von Berufseinsteigern, bei zugleich geringeren Kosten und

kürzerer Bearbeitungszeit (L. Cheng et al., 2023).

Während dieser Ansatz von einer einmaligen, eindeutig formulierten Anfrage ausgeht, argumentieren Li et al. (2024), dass reale Analyseprozesse interaktiv verlaufen, da Nutzerintentionen häufig uneindeutig sind und Analysestrategien an Zwischenergebnisse angepasst werden. Sie beschreiben interaktive Datenanalyse als eine Abfolge miteinander verknüpfter Nutzer-Agent-Interaktionen und unterscheiden verschiedene Agentenaktionen, darunter das Stellen von Rückfragen, das Treffen begründeter Annahmen sowie die Korrektur und Aktualisierung von Code. Zur Verbesserung dieser Agenten schlagen sie eine Reflexionsstrategie vor, die aus erfolgreichen Interaktionsverläufen lernt und die relative Leistung um bis zu 44,5% steigert. Nach den Ergebnissen von Li et al. (2024) kann eine starke Berücksichtigung der Interaktionshistorie die Verarbeitung neuer Informationen erschweren. Die Autoren leiten daraus ab, dass ein ausgewogenes Verhältnis zwischen Gesprächshistorie und aktueller Nutzereingabe erforderlich ist (Li et al., 2024).

Über solche Systeme hinaus wurden Benchmarks vorgeschlagen, die LLM-gestützte Datenanalyse systematisch bewerten, etwa InfiAgent-DABench (Hu et al., 2024). Neben der reinen Leistungsmessung rückt dabei die Unterscheidung zwischen datenbasierten und wissensbasierten Ausgaben in den Blick. Li et al. (2024) adressieren sie explizit, indem sie mit nutzerdefinierten Bibliotheken prüfen, ob ein Modell die bereitgestellten Funktionen tatsächlich verarbeitet oder auf memorisierte Standardsyntax zurückgreift. Diese Spannung zwischen tatsächlicher Datenverarbeitung und dem Rückgriff auf memoriertes Wissen zieht sich als grundlegende Frage durch die Bewertung LLM-gestützter Datenanalyse.

Im Kontext der explorativen Datenanalyse stellt der Einsatz von LLMs eine jüngere Entwicklung dar, die klassische Analysemethoden um generative Fähigkeiten erweitert. Zhecheva (2024) untersucht diesen Einsatz anhand zweier Datensätze mit Informationen zu mehr als 4.800 Online-Brettspielen und über 150.000 Bewertungen. Methodisch werden Analyseoperationen sowohl mit etablierten Python-Bibliotheken wie Pandas, Matplotlib und Seaborn als auch mithilfe von PandasAI durchgeführt, das natürlichsprachliche Anfragen unter Einbindung eines OpenAI-Modells verarbeitet. Durch die Gegenüberstellung der Ergebnisse werden unter anderem die Genauigkeit der Modellausgaben und die Ausführungszeit untersucht (Zhecheva, 2024).

Für die erfolgreich ausgeführten und verglichenen Operationen berichtet Zhecheva (2024) eine hohe Übereinstimmung zwischen den konventionell und den LLM-gestützt erzeugten Ergebnissen. Als mögliche Erklärung führt die Autorin die verwendete Prompt-Struktur

an, bei der der untersuchte DataFrame Bestandteil jeder Anfrage ist. Gleichzeitig zeigen sich Einschränkungen bei Aufgaben, die ein stärkeres semantisches Verständnis der Daten erfordern. Informativere und spezifischere Prompts führen hierbei zu besseren Ergebnissen, während das Modell einzelne Aufgaben trotz variiert formulierten Prompts nicht erfolgreich ausführt. In einigen Fällen erfolgte zudem keine Rückmeldung über die nicht erfolgreiche Ausführung, was insbesondere bei einer automatisierten Nutzung problematisch sein kann (Zhecheva, 2024).

Die dargestellten Arbeiten zeigen Anwendungen LLM-gestützter Datenanalyse, verweisen jedoch auf Einschränkungen wie fehlerhafte Berechnungen (L. Cheng et al., 2023) oder unbegründete Annahmen (Li et al., 2024). Diese Zuverlässigkeitsaspekte werden im folgenden Abschnitt vertieft.

2.4 Zuverlässigkeit und Grenzen LLM-gestützter Analyse

Bevor die spezifischen Fehlerquellen LLM-gestützter Analyse betrachtet werden, ist zu klären, worin die Zuverlässigkeit eines analytischen Systems besteht. Bornschlegl (2024) überträgt die Dimensionen zwischenmenschlichen Vertrauens auf die Vertrauenswürdigkeit technischer Systeme und benennt für deren Ausgaben insbesondere Reproduzierbarkeit und Validität. Reproduzierbarkeit bezeichnet die Fähigkeit, mit denselben Eingabedaten, Rechenschritten, Methoden und demselben Code konsistente Ergebnisse zu erzielen. Validität beschreibt den Grad, in dem die erzeugten Daten oder Ergebnisse korrekt sind. Übertragen auf die LLM-gestützte explorative Datenanalyse beschreibt Reproduzierbarkeit demnach die Stabilität der Ergebnisse bei gleicher Eingabe und Validität ihre Übereinstimmung mit den tatsächlichen Eigenschaften der Daten (Bornschlegl, 2024). Inwieweit diese beiden Anforderungen durch charakteristische Eigenschaften von LLMs beeinträchtigt werden können, ist Gegenstand der folgenden Betrachtungen.

Ji Ziwei et al. (2022) weisen darauf hin, dass moderne Deep-Learning-Modelle zwar sprachlich kohärente Ausgaben erzeugen, jedoch häufig Inhalte produzieren, die weder mit der zugrundeliegenden Eingabequelle übereinstimmen noch faktisch korrekt sind. Da Halluzinationen definitionsgemäß von den tatsächlichen Fakten oder dem bereitgestellten Eingabekontext abweichen, können sie die Validität der im Rahmen einer Datenanalyse erzeugten Ergebnisse erheblich beeinträchtigen. Solche Angaben lassen sich in zwei

Typen unterscheiden. Faktische Halluzination bezeichnet die Diskrepanz zwischen generiertem Inhalt und verifizierbaren Fakten (Bai et al., 2025). Im Kontext der explorativen Datenanalyse liegt eine faktische Halluzination beispielsweise dann vor, wenn ein Modell eine Kennzahl nennt, die vom tatsächlich berechenbaren Wert abweicht, oder eine Variable anführt, die im Datensatz nicht enthalten ist. Treuebezogene Halluzinationen umfassen demgegenüber die Abweichung von der Nutzeranweisung oder dem bereitgestellten Eingabekontext sowie eine fehlende Selbstkonsistenz (Bai et al., 2025). Ein Beispiel ist eine Analyse, die statt der vorgelegten Daten einen allgemein erwarteten Zusammenhang wiedergibt. Ebenso zählt dazu der Fall, dass eine Aussage innerhalb derselben Antwort später widerrufen wird.

Dass Halluzinationen messbar und modellabhängig sind, zeigt eine Untersuchung zu fabrizierten Literaturangaben. Agrawal et al. (2024) bestimmen für die Generierung wissenschaftlicher Referenzen modellspezifische Halluzinationsraten, die zwischen 47 Prozent für GPT-4 und über 76 Prozent für kleinere Modelle liegen, wobei leistungsfähigere Modelle durchgängig geringere Raten aufweisen. Zugleich betonen sie, dass Halluzination kein rein binäres Merkmal darstellt, da sich etwa eine generierte Referenz mit Teilen eines existierenden Titels nicht eindeutig klassifizieren lässt (Agrawal et al., 2024). Ein anschauliches Beispiel aus der explorativen Datenanalyse ist der von GPT-4 erzeugte, nicht existente Titel „Exploratory Data Analysis and the Role of Visualization“, dem das Modell zudem den Autor *John W. Tukey* der klassischen Arbeit zur explorativen Datenanalyse zuschrieb (Agrawal et al., 2024).

Über die empirische Beobachtung hinaus wird die Unvermeidbarkeit von Halluzination theoretisch begründet. Xu et al. (2025) argumentieren auf Grundlage ihrer theoretischen Analyse, dass Halluzinationen bei allgemeinen LLMs grundsätzlich nicht vollständig vermeidbar sind. Für die Analysepraxis leiten die Autoren daraus ab, dass sich Halluzinationen nicht allein durch eine Anpassung der Prompts vollständig vermeiden lassen. Promptbasierte Ansätze wie das in Abschnitt 2.3 beschriebene Chain-of-Thought-Prompting können Halluzinationen zwar reduzieren, ihre Wirksamkeit ist nach Xu et al. (2025) jedoch auf bestimmte Aufgaben begrenzt. Als potenziell wirksamen Ansatz diskutieren die Autoren die Anreicherung mit externem Wissen, beispielsweise durch Wissensdatenbanken oder Werkzeuge. Dadurch werden dem Modell Informationen über die Zielfunktion bereitgestellt, die über die reinen Trainingsdaten hinausgehen (Xu et al., 2025).

In dieselbe Richtung weist die Untersuchung von Zheng et al. (2024) zur Verlässlichkeit

von LLMs als Wissensbasis. Ein fakzentreues Modell gibt bekanntes Wissen korrekt wieder und stellt zu unbekannten keine Behauptungen auf, wobei sich die Überschätzung des eigenen Wissens besonders bei numerischen und zeitbezogenen Fragen zeigt. Konsistenz allein ist dabei kein hinreichendes Gütekriterium, da auch fehlerhafte Antworten konsistent wiederholt werden können (Zheng et al., 2024).

Wissenskonflikte stellen zugleich eine Herausforderung für die Zuverlässigkeit von LLM-Ausgaben dar. Y. Wang et al. (2024) zeigen, dass LLMs die Existenz solcher Konflikte zwar über dem Zufallsniveau erkennen, jedoch Schwierigkeiten haben, die konkret widersprüchlichen Informationen zu lokalisieren und getrennte Antworten auf Grundlage der konfligierenden Informationen zu erzeugen. Der robuste Umgang mit Wissenskonflikten bleibt den Autoren zufolge damit eine offene Forschungsfrage. Übertragen auf die LLM-gestützte explorative Datenanalyse ergibt sich daraus die Notwendigkeit, zu untersuchen, inwieweit Modellausgaben tatsächlich auf den bereitgestellten Daten beruhen oder durch parametrisches Vorwissen beeinflusst werden. Abbildung 2.3 veranschaulicht dieses Zusammenwirken beider Wissensquellen. Das Zusammenspiel datenbasierter und wissensbasierter Einflüsse stellt damit einen zentralen Aspekt für die Beurteilung der Verlässlichkeit LLM-gestützter Datenanalyse dar.




Abbildung 2.3: Einfluss der im Prompt bereitgestellten Daten und des in den Modellparametern repräsentierten Wissens auf die Generierung einer Ausgabe.

Zusammenfassend zeigen die dargestellten Eigenschaften, dass LLMs die benannten Anforderungen an Reproduzierbarkeit und Validität nur eingeschränkt erfüllen. Halluzinationen gefährden die Validität, indem sie inhaltlich nicht gedeckte Ausgaben erzeugen und ihre begründete Unvermeidbarkeit schließt eine vollständige Beseitigung aus (Xu et al., 2025). Darüber hinaus können bei der Verarbeitung kontextuell bereitgestellter Informationen Wechselwirkungen und Konflikte mit dem parametrischen Vorwissen des Modells auftreten. Für die LLM-gestützte explorative Datenanalyse folgt daraus, dass

die Übereinstimmung der Modellausgaben mit dem tatsächlichen Dateninhalt nicht vorausgesetzt, sondern eigens geprüft werden muss. Im Kontext dieser Arbeit wird Datenkonsistenz als die Übereinstimmung zwischen einer generierten Aussage und dem zugrunde liegenden Datensatz verstanden. Sie stellt eine wesentliche Voraussetzung für die Beurteilung der Verlässlichkeit generierter Inhalte dar.

3 Methodik und Durchführung

3.1 Datengrundlage

3.1.1 Beschreibung des Datensatzes

Als empirische Grundlage der Untersuchung dient der Datensatz *IBM HR Analytics Employee Attrition and Performance*. Es handelt sich um einen synthetisch erzeugten Datensatz, der von Data Scientists bei IBM erstellt wurde und keine realen Beschäftigungsdaten enthält. Bezogen wurde er über die Plattform Kaggle¹. Der Datensatz umfasst 1470 Beobachtungen, die jeweils eine fiktive beschäftigte Person repräsentieren, und in der Rohfassung 35 Variablen.

Die Zielvariable **Attrition** gibt an, ob eine Person das Unternehmen verlassen hat und ist binär ausgeprägt. Im Datensatz liegt der Anteil der Kündigungen bei rund 16 %, sodass eine deutliche Ungleichverteilung zwischen verbliebenen und ausgeschiedenen Personen besteht. Die erklärenden Variablen lassen sich in drei Gruppen einteilen: 14 metrische Variablen wie Alter, Monatseinkommen oder Betriebszugehörigkeit, neun ordinal skalierte Variablen, deren Ausprägungen als numerische Codes vorliegen (etwa Zufriedenheits- und Bewertungsskalen wie **JobSatisfaction** oder **WorkLifeBalance**), sowie sieben nominal-kategoriale Variablen wie Geschlecht, Abteilung oder Tätigkeitsfeld. Hinzu kommt die Variable **EmployeeNumber**, die als reine Identifikationsnummer keine inhaltlichen Informationen trägt und daher nicht in die Analyse eingeht.

3.1.2 Zweistufiger Datensaatzaufbau

Für die Untersuchung wird der Datensatz in zwei Fassungen vorgehalten, die unterschiedliche Funktionen erfüllen. Die erste Fassung entspricht den unveränderten Rohdaten und

¹<https://www.kaggle.com/datasets/pavansubhasht/ibm-hr-analytics-attrition-dataset>

wird den Modellen als Eingabe vorgelegt. Die zweite Fassung ist eine bereinigte Version, die als Referenz für die Bewertung der Modellantworten dient.

Bei der Bereinigung wurden drei Variablen entfernt, die über alle Beobachtungen hinweg einen konstanten Wert aufweisen und damit keine Varianz besitzen: **EmployeeCount**, **StandardHours** und **Over18**. Aus den 35 Variablen der Rohfassung ergeben sich so 32 inhaltlich verwertbare Variablen, auf deren Grundlage sämtliche Referenzwerte berechnet werden.

Die Entscheidung, den Modellen die unbereinigte Rohfassung vorzulegen, ist bewusst getroffen. Sie ermöglicht die Prüfung, ob ein Modell die uninformativen Variablen selbstständig als solche erkennt, anstatt ihnen eine Bedeutung zuzuschreiben. Zugleich entspricht die Rohfassung der Ausgangslage einer realen explorativen Analyse, in der die Beurteilung und Bereinigung der Daten Teil der Analyseaufgabe ist und nicht bereits vorausgesetzt wird. Die bereinigte Fassung bildet demgegenüber den korrekten Sollzustand ab, gegen den die Modellausgaben geprüft werden.

3.1.3 Referenzwertberechnung

Die explorative Untersuchung des Datensatzes orientiert sich an dem in Abschnitt 2.1 dargestellten sechsstufigen Vorgehen nach Rahmany et al. (2020), das von der formalen Erfassung der Daten über die uni- und bivariate Betrachtung bis zur Identifikation auffälliger Muster reicht. Auf dieser Grundlage werden die Kennzahlen bestimmt, die anschließend als Referenzwerte für die Bewertung der Modellantworten dienen. Berechnet werden deskriptive Kennzahlen, Zusammenhänge sowie Merkmalskombinationen, die mit der Zielvariable einhergehen. Um die Reproduzierbarkeit der Referenzwerte sicherzustellen, wird für den verwendeten Datensatz ein kryptografischer Prüfwert nach dem SHA-256-Verfahren berechnet und gemeinsam mit den Referenzwerten gespeichert. Dieser Prüfwert identifiziert die zugrunde liegende Datenfassung eindeutig, damit sich die berechneten Referenzwerte einer konkreten Version des Datensatzes zuordnen lassen. Für den in Experiment 2 verwendeten veränderten Datensatz wird ein eigener Prüfwert bestimmt, sodass beide Fassungen zweifelsfrei unterscheidbar sind.

Als deskriptive Kennzahlen werden für die metrischen Variablen Lage- und Streuungsmaße bestimmt, insbesondere Mittelwert und Median. Ausreißer werden anhand des in Abschnitt 2.1 eingeführten Kriteriums des 1,5-fachen Interquartilsabstands bestimmt, wonach ein Wert als Ausreißer gilt, wenn er mehr als das Anderthalbfache des Inter-

quartilsabstands unterhalb des ersten oder oberhalb des dritten Quartils liegt. Für die Zielvariable sowie für die nominal-kategorialen Variablen wird die jeweilige Kündigungsquote als Anteil der ausgeschiedenen Personen ermittelt.

Als Zusammenhangsmaß wird der Pearson-Korrelationskoeffizient berechnet. In die Berechnung gehen neben den metrischen auch die ordinal skalierten Variablen ein, deren numerische Codes dabei wie intervallskalierte Werte behandelt werden. Diese Vereinfachung dient als einfache Baseline für die Untersuchung der Frage, welche Faktoren mit einer Kündigung zusammenhängen. Ihre Grenzen sind bekannt: Der Pearson-Koeffizient erfasst ausschließlich lineare, paarweise Zusammenhänge und setzt streng genommen intervallskalierte Variablen voraus, was bei ordinalen Skalen nicht gegeben ist. Um diese Einschränkungen auszugleichen, werden ergänzend Assoziationsregeln herangezogen, die Zusammenhänge zwischen Kombinationen mehrerer Merkmale erfassen und nicht auf paarweise lineare Beziehungen beschränkt sind.

Eine Assoziationsregel beschreibt eine Wenn-Dann-Beziehung zwischen Mustern einer Datenbasis und wird über den Support, der die gemeinsame Häufigkeit zweier Muster angibt, sowie die Konfidenz, welche die Wahrscheinlichkeit der Konsequenz bei erfüllter Bedingung beschreibt, charakterisiert (Hammesfahr & Spott, 2021, S. 206). Für die vorliegende Fragestellung werden ausschließlich Regeln betrachtet, die `Attrition_Yes` als alleinige Konsequenz aufweisen. Da Assoziationsregeln kategoriale Ausprägungen voraussetzen, werden die metrischen Variablen zuvor quartilsbasiert in drei Klassen (niedrig, mittel, hoch) eingeteilt.

Ein bekanntes Problem solcher Verfahren besteht darin, dass sie eine für die Analyse zu große Zahl an Regeln erzeugen (Hammesfahr & Spott, 2021, S. 202). Zur Reduktion wird das Verfahren des Minimal Improvement nach Hammesfahr und Spott (2021, S. 207) angewendet, das eine spezifische Regel nur dann beibehält, wenn ihre Konfidenz die der jeweiligen allgemeineren Regel um einen Schwellenwert übersteigt. Andernfalls gilt das zusätzliche Merkmal als redundant. In Anlehnung an das dort beschriebene Verfahren werden zunächst ein Mindestsupport und eine Mindestkonfidenz angewendet und anschließend das Minimal Improvement, sodass bereits gefilterte Regeln nicht mehr in den Vergleich eingehen (Hammesfahr & Spott, 2021, S. 213).

3.2 Forschungsdesign

Die vorliegende Arbeit verfolgt ein empirisch-experimentelles Forschungsdesign. Ziel ist es, die Zuverlässigkeit und Datentreue von LLM-gestützter explorativer Datenanalyse unter kontrollierten Bedingungen systematisch zu untersuchen. Dazu werden die Ausgaben zweier LLMs mit einem rechnerisch ermittelten Referenzwert verglichen, der auf Basis derselben Eingabedaten mit etablierten statistischen Methoden berechnet wurde. Der experimentelle Ansatz ermöglicht es, Zusammenhänge zwischen der Art der Eingabedaten, der Gestaltung der Prompts sowie der Qualität der generierten Analyseergebnisse zu untersuchen.

3.3 Untersuchungsansatz

Die Untersuchung gliedert sich in vier aufeinander bezogene Experimente, die jeweils unterschiedliche Aspekte der Zuverlässigkeit LLM-gestützter explorativer Datenanalyse adressieren und den vier Forschungsfragen zugeordnet sind. Alle Experimente greifen auf denselben Datensatz und dieselben Referenzwerte zurück, unterscheiden sich jedoch in der Art der Aufgabenstellung und der Interaktionsform.

Experiment 0 – Methodisches Vorwissen

Das nullte Experiment adressiert Forschungsfrage 4 und prüft, welches methodisches Wissen zur explorativen Datenanalyse die Modelle unabhängig von einem konkreten Datensatz aufweisen. Den Modellen werden fünfzehn konzeptionelle Fragen ohne Datenbezug vorgelegt, zum Beispiel zur Bedeutung der Interquartilsregel, zur Untersuchung von Lagemaßen oder zu den Grenzen der Korrelationskoeffizienten. Die Fragen sind in drei Schwierigkeitsstufen mit steigender Trennschärfe gegliedert, sodass sich unterschiedliche Kompetenzniveaus der Modelle sichtbar machen lassen. Die Antworten werden anhand einer Bewertungsrubrik mit einer Skala von null bis drei Punkten kodiert, die für jede Frage die erwarteten Kernpunkte festlegt. Dieses Experiment bildet die Grundlage für die Einordnung der übrigen Ergebnisse, da es zeigt, ob fehlerhafte Analysen auf mangelndem Methodenwissen oder auf einer unzureichenden Verarbeitung der bereitgestellten Daten beruhen.

Experiment 1 – Referenzanalyse

Das erste Experiment adressiert die Forschungsfragen 1 und 2 und bildet die Grundlage der datenbezogenen Untersuchung. Zunächst werden auf Basis des Datensatzes mittels Python und der Bibliothek `pandas` statistisch korrekte Referenzwerte berechnet, die deskriptive Kennzahlen, bivariate Zusammenhänge in Form von Korrelationskoeffizienten sowie Merkmalskombinationen in Form von Assoziationsregeln umfassen. Anschließend werden beide Modelle identische Prompts sowie der vollständige Datensatz über die jeweilige Programmierschnittstelle übergeben. Die Fragen gliedern sich in drei Kategorien: faktische Fragen mit eindeutig bestimmbar Referenzwerten, interpretative Fragen nach Zusammenhängen und Merkmalskombinationen sowie gezielt gestellte Fragen, die eine Halluzination provozieren, etwa durch die Nennung nicht existenter Variablen. Die generierten Antworten werden mit den Referenzwerten verglichen und anhand des in Abschnitt 3.3 beschriebenen Bewertungsschemas beurteilt.

Experiment 2 – Manipulierter Datensatz

Das zweite Experiment vertieft Forschungsfrage 1 und prüft, ob die Modelle ihre Aussagen tatsächlich aus den bereitgestellten Daten ableiten oder auf vortrainiertes Wissen zurückgreifen. Hierzu wird eine gezielt veränderte Fassung des Datensatzes erzeugt, in der ein bekannter Zusammenhang umgekehrt wird, sodass er dem allgemein erwarteten Muster widerspricht. Für diese Fassung werden eigene Referenzwerte berechnet und über einen eigenen Prüfwert identifiziert. Den Modellen werden dieselben Fragen wie in Experiment 1 vorgelegt. Weicht eine Antwort von den veränderten Daten ab und entspricht stattdessen dem ursprünglich erwarteten Zusammenhang, deutet dies darauf hin, dass die Ausgabe nicht auf einer Verarbeitung der bereitgestellten Daten beruht.

Experiment 3 – Iterative Interaktion

Das dritte Experiment adressiert Forschungsfrage 3 und untersucht den Einfluss einer iterativen Mensch-Modell-Interaktion auf die Konsistenz und Qualität der Analyseergebnisse. Anders als in den vorangegangenen Experimenten, in denen jede Frage in einem eigenständigen Kontext gestellt wird, bauen diese Anfragen hier aufeinander auf und bilden einen mehrstufigen Analyseverlauf ab. Auf diese Weise lässt sich beobachten, ob frühere Ungenauigkeiten in späteren Schritten fortgeführt oder korrigiert werden und

wie sich die Einbeziehung der Interaktionshistorie auf die Verlässlichkeit der Ergebnisse auswirkt.

Bewertungsmethodik

Die Bewertungsmethodik legt fest, wie die Antworten der Modelle mit den in Abschnitt 3.1.3 bestimmten Referenzwerten verglichen und in einen einheitlichen Punktwert überführt werden. Sie greift die beiden in Abschnitt 2.1 unterschiedenen Bewertungsdimensionen auf: die faktische Korrektheit einer Aussage, die sich an der Übereinstimmung mit den berechneten Referenzwerten bemisst, sowie die Interpretationsqualität, die nach den von Koesten et al. (2021) beobachteten Merkmalen einer gehaltvollen Analyse beurteilt wird. Welche der beiden Dimensionen für eine Antwort herangezogen wird, richtet sich nach der Kategorie der zugrunde liegenden Frage. Die faktische Korrektheit entspricht dabei der von Bornschlegl (2024) benannten Validität, während die Stabilität der Antworten bei wiederholter Stellung als Reproduzierbarkeit erfasst wird.

Die Bewertung erfolgt abhängig vom jeweiligen Experiment und der Kategorie der zugrunde liegenden Frage. Für Experiment 0 werden die Antworten anhand der zuvor festgelegten Bewertungsrubrik auf einer Skala von null bis drei Punkten kodiert. Die Kodierung erfolgt blind, das heißt ohne Kenntnis des Modells und der Wiederholung, aus der die jeweilige Antwort stammt. In den datenbezogenen Experimenten werden faktische und interpretative Fragen der Kategorien A und B auf einer Skala von null bis zwei Punkten bewertet. Für die Halluzinationsfallen der Kategorie C wird hingegen kein Punktwert vergeben; stattdessen werden die Anzahl nicht durch die Daten gedeckter Behauptungen sowie der Anteil verlässlicher Antworten erfasst. Technisch abgeschnittene Antworten werden anhand des bis zum Abbruch erzeugten Inhalts bewertet. Ein Abbruch führt somit nicht automatisch zu einer schlechteren Bewertung, sofern die für die Beurteilung erforderlichen Inhalte bereits enthalten sind. Beruht die Interpretation dagegen erkennbar auf einer unvollständigen oder vom bereitgestellten Datensatz abweichenden Datengrundlage gilt sie nicht als vollständig datenbasiert. Die jeweiligen Bewertungskriterien werden in den folgenden Abschnitten näher erläutert.

3.3.1 Kategorie A: Faktische Fragen und Toleranzbänder

Faktische Fragen besitzen einen eindeutig bestimmbar Referenzwert. Dazu zählen numerische Kennwerte wie Mittelwerte, Mediane und Anteile, Zählwerte sowie kategoriale Ergebnisse. Die Bewertung erfolgt auf einer Skala von null bis zwei Punkten und richtet sich nach der Art des erwarteten Ergebnisses.

Bei numerischen Kennwerten wird die relative Abweichung zwischen dem vom Modell genannten x_{Modell} und dem berechneten Referenzwert x_{Ref} bestimmt:

$$d_{\text{rel}} = \frac{|x_{\text{Modell}} - x_{\text{Ref}}|}{|x_{\text{Ref}}|} \times 100 \%$$

Eine relative Abweichung von höchstens 2 % wird mit zwei Punkten bewertet. Bei einer Abweichung von mehr als 2 % bis einschließlich 5 % wird ein Punkt vergeben. Abweichungen von mehr als 5 % erhalten null Punkte.

Für Zählwerte ist eine relative Toleranz dagegen nicht sinnvoll, da die Anzahl der Beobachtungen oder Ausreißer eindeutig bestimmbar ist. Eine exakte Übereinstimmung mit dem Referenzwert wird daher mit zwei Punkten bewertet, jede Abweichung mit null Punkten. Eine Zwischenstufe von einem Punkt wird für Zählwerte nicht vergeben.

Auch bei kategorialen Ergebnissen, beispielsweise der Abteilung oder Familienstandsgruppe mit der höchsten Kündigungsquote, ist das Ergebnis eindeutig bestimmbar. Die korrekte Kategorie erhält zwei Punkte, eine falsche oder nicht bestimmbare Antwort null Punkte.

Zusätzliche Ausführungen führen nicht zu einem Punktabzug, sofern die geforderte Antwort eindeutig identifizierbar und sachlich korrekt ist. Enthalten die zusätzlichen Angaben jedoch einen Widerspruch zur eigentlichen Antwort oder machen das Ergebnis uneindeutig, wird die Antwort als nicht korrekt bewertet. Tabelle 3.1 fasst die Vorgabe zusammen.

3.3.2 Kategorie B: Interpretative Fragen

Interpretative Fragen zielen auf Zusammenhänge und Merkmalskombinationen, etwa auf die Faktoren, die mit einer Kündigung einhergehen. Für sie existiert kein einzelner

Tabelle 3.1: Bewertung faktischer Fragen der Kategorie A nach Art des erwarteten Ergebnisses. Die Skala reicht von null bis zwei Punkten.

Pkt.	Numerische Kennwerte	Zählwerte	Kategoriale Ergebnisse
2	relative Abweichung bis 2 %	exakte Übereinstimmung	korrekte Kategorie
1	relative Abweichung über 2 % bis 5 %	nicht vergeben	nicht vergeben
0	relative Abweichung über 5 %, nicht bestimmbar oder verweigert	jede Abweichung, nicht bestimmbar oder verweigert	falsche, nicht bestimmbare oder verweigte Antwort

Referenzwert, wohl aber ein referenzieller Rahmen aus den berechneten Korrelationskoeffizienten und Assoziationsregeln, an dem sich Richtung und Stärke eines behaupteten Zusammenhangs prüfen lassen. Über die sachliche Richtigkeit hinaus wird die Interpretationsqualität herangezogen. In Anlehnung an Koesten et al. (2021) gilt eine Interpretation dann als gehaltvoll, wenn sie ihre Aussagen einordnet, anstatt Kennzahlen lediglich wiederzugeben und die Grenzen ihrer Aussagekraft benennt (Abschnitt 2.1). Dazu zählt der Vorbehalt, dass sich aus einer Korrelation kein kausaler Zusammenhang ableiten lässt (Boslaugh, 2012, S. 178–189).

Die Bewertung erfolgt auf einer Skala von null bis zwei Punkten. Zwei Punkte werden vergeben, wenn die Antwort die für die Fragestellung wesentlichen Zusammenhänge hinsichtlich Richtung und Stärke datenbasiert zutreffend interpretiert, mit geeigneten Kennzahlen oder aggregierten Datenwerten stützt und angemessen einordnet. Einzelne Beobachtungen gelten dabei nicht als hinreichender Beleg für einen Zusammenhang auf Gruppen- oder Variablenebene.

Ein Punkt wird vergeben, wenn die grundlegende Interpretation durch die Daten gestützt wird, jedoch relevante Zusammenhänge fehlen, die Stärke des Zusammenhangs unzureichend belegt wird oder eine angemessene Einordnung fehlt. Null Punkte werden vergeben, wenn die zentrale Interpretation falsch, irreführend oder nicht durch den bereitgestellten Datensatz gedeckt ist.

Da die untersuchten Zusammenhänge deskriptiver beziehungsweise korrelativer Natur sind, werden kausale Schlussfolgerungen nur dann als angemessen eingeordnet, wenn sie durch das Untersuchungsdesign gedeckt sind. Eine unbegründete kausale Interpretation

kann daher zu einer Abwertung führen.

Tabelle 3.2: Bewertung interpretativer Fragen der Kategorie B. Die Skala reicht von null bis zwei Punkten und bemisst die Qualität der datenbasierten Interpretation.

Pkt.	Interpretationsqualität
2	Wesentliche Zusammenhänge hinsichtlich Richtung und Stärke datenbasiert zutreffend interpretiert, mit geeigneten Kennzahlen oder aggregierten Datenwerten gestützt und angemessen eingeordnet.
1	Grundlegende Interpretation datenbasiert zutreffend, jedoch unvollständig, unzureichend belegt oder nicht angemessen eingeordnet.
0	Zentrale Interpretation falsch, irreführend oder nicht durch den bereitgestellten Datensatz gedeckt.

3.3.3 Kategorie C: Halluzinationsfallen

Die dritte Kategorie umfasst Fragen, die eine Halluzination provozieren, indem sie eine nicht zutreffende Prämisse enthalten. Die verwendeten Halluzinationsfallen umfassen drei Ausprägungen: die Bezugnahme auf eine im Datensatz nicht vorhandene Variable, die Vorgabe eines falschen Wertebereichs sowie die suggestive Unterstellung eines durch die Daten nicht gestützten Zusammenhangs. Eine faktentreue Antwort gibt nach Zheng et al. (2024) bekanntes Wissen korrekt wieder und stellt zu Unbekanntem keine Behauptungen auf. Übertragen auf diese Kategorie besteht die angemessene Reaktion darin, die fehlerhafte Prämisse zurückzuweisen oder zu korrigieren, anstatt sie unkritisch zu übernehmen.

Anders als bei den faktischen und interpretativen Fragen wird für diese Kategorie kein Punktwert vergeben. Da eine Halluzination auf der Ebene einzelner Behauptungen nicht eindeutig als richtig oder falsch einzuordnen ist (Agrawal et al., 2024), wird stattdessen für jede Antwort die Anzahl der nicht durch die Daten gedeckten Behauptungen gezählt. Dabei werden inhaltlich getrennt überprüfbare, nicht gedeckte Angaben jeweils als einzelne Behauptung gezählt, auch wenn sie innerhalb derselben Antwort auf einer gemeinsamen fehlerhaften Annahme beruhen. Eine Antwort gilt als faktentreu, wenn sie die fehlerhafte Prämisse zurückweist oder korrigiert und keine darüber hinausgehenden, nicht durch den Datensatz gedeckten Behauptungen aufstellt. Bei suggestiven Fragen ist die Berechnung der erfragten Kennzahl zulässig, sofern die in der Frage enthaltene,

nicht durch die Daten gestützte Prämisse nicht unkritisch übernommen oder bestätigt wird. Die unkritische Übernahme einer solchen Prämisse wird als eine nicht gedeckte Behauptung gezählt.

Ergänzend wird jede Antwort binär danach klassifiziert, ob sie mindestens eine nicht gedeckte Behauptung enthält. Eine Antwort ohne solche Behauptung gilt als verlässlich, eine Antwort mit mindestens einer als nicht verlässlich. Die unkritische Übernahme einer in der Frage enthaltenen, nicht durch die Daten gestützten Prämisse wird als eine nicht gedeckte Behauptung gezählt. Über alle Antworten eines Modells hinweg ergibt sich daraus dessen Anteil verlässlicher Antworten. Diese Einordnung knüpft unmittelbar an das in der vorliegenden Arbeit zugrunde gelegte Verständnis der Datenkonsistenz an, wonach eine generierte Aussage mit dem Datensatz übereinstimmen muss. Tabelle 3.3 fasst die beiden Maße zusammen.

Tabelle 3.3: Maße zur Bewertung der Halluzinationsfallen (Kategorie C). Beide Maße werden für jede Antwort blind bestimmt und anschließend je Modell aggregiert.

Maß	Bestimmung je Antwort	Aggregation je Modell
Halluzinationszählung	Anzahl der nicht durch die Daten gedeckten Behauptungen (z. B. erfundene Variablen oder Zahlenwerte, unbegründete Variablenzuordnungen sowie nicht gestützte Zusammenhänge)	
Verlässlichkeitsklassifikation	verlässlich bei keiner, nicht verlässlich bei mindestens einer nicht gedeckten Behauptung	Anteil verlässlicher Antworten

3.3.4 Aggregation der Bewertung

Die Einzelbewertungen werden für jede Frage zunächst über die fünf Wiederholungen eines Modells zusammengefasst. Für die Kategorien A und B wird hierzu der mittlere Punktwert je Frage bestimmt. Abschließend wird aus den Fragemittelwerten der mittlere Punktwert der jeweiligen Kategorie je Modell gebildet. Dadurch geht jede Frage unabhängig von der Anzahl ihrer Wiederholungen mit gleichem Gewicht in das Kategorieergebnis ein.

Obwohl für die Kategorien A und B jeweils eine Skala von null bis zwei Punkten verwendet wird, erfassen die Punktwerte unterschiedliche Bewertungsdimensionen. Kategorie A misst die faktische Übereinstimmung mit vorab bestimmten Referenzwerten, während Kategorie B die Qualität der datenbasierten Interpretation bewertet. Die Ergebnisse werden daher getrennt ausgewiesen und nicht zu einem gemeinsamen Punktwert zusammengeführt.

Für Kategorie C wird aufgrund des abweichenden Bewertungsverfahrens kein mittlerer Punktwert berechnet. Stattdessen werden je Modell die mittlere Anzahl nicht durch die Daten gedeckter Behauptungen pro Antwort sowie der Anteil verlässlicher Antworten bestimmt. Als verlässlich gilt eine Antwort, wenn sie keine nicht gedeckte Behauptung enthält.

Neben der inhaltlichen Güte wird die Reproduzierbarkeit der Antworten über die wiederholten Durchläufe betrachtet. Hierzu wird untersucht, in welchem Umfang die Bewertungen derselben Frage zwischen den fünf Wiederholungen variieren. Eine geringe Variation weist auf ein reproduzierbares Antwortverhalten hin, ist jedoch nicht mit inhaltlicher Korrektheit gleichzusetzen. Ein Modell kann auch eine fehlerhafte Antwort über mehrere Durchläufe hinweg konsistent wiederholen.

3.4 Durchführung

4 Ergebnisse

4.1 Auswertung Experiment 0: Methodisches Vorwissen

Experiment 0 dient als Kontrollbedingung und prüft das methodische Vorwissen der beiden Modelle unabhängig von einem konkreten Datensatz (Forschungsfrage 4). Vorgelegt wurden fünfzehn konzeptionelle Fragen zur explorativen Datenanalyse, die jedem Modell dreimal gestellt wurden, sodass insgesamt 90 Antworten vorliegen. Die Bewertung erfolgte blind anhand der in Abschnitt 3.3 beschriebenen Rubrik von null bis drei Punkten, wobei für jede Frage die erwarteten Kernpunkte vorab festgelegt waren. Zwei Antworten des Modells Gemini wurden gemäß dem in Abschnitt 3.4 beschriebenen Vorgehen nachträglich erhoben, eine wegen eines Übertragungsfehlers der Programmierschnittstelle und eine wegen einer am Ausgabelimit abgeschnittenen Antwort. Kodiert wurde jeweils die vollständige Antwort.¹

Über alle 90 Antworten hinweg erreichten die Modelle ein hohes Niveau. 84 Antworten wurden mit der vollen Punktzahl bewertet, fünf mit zwei Punkten und eine mit einem Punkt. Im Mittel erreichte GPT 2,93 und Gemini 2,91 von drei möglichen Punkten, über beide Modelle zusammen 2,92. Bei dreizehn der fünfzehn Fragen erhielten beide Modelle in allen drei Wiederholungen die volle Punktzahl. Das Ergebnis bestätigt die erwartete Funktion des Experiments als Kontrollbedingung, da beide Modelle über ein solides methodisches Grundwissen zur explorativen Datenanalyse verfügen.

Die Abweichungen von der vollen Punktzahl beschränken sich auf genau zwei Fragen und zwar bei jeweils einem Modell über alle drei Wiederholungen hinweg. Tabelle 4.1 fasst sie zusammen.

Bei der Frage nach den Schritten der explorativen Datenanalyse und ihrer Reihenfolge blieb Gemini in unterschiedlichem Ausmaß unvollständig. Ein Lauf brach die Aufzählung

¹Die beiden untersuchten Modelle sind `gpt-5.6-luna` (im Folgenden GPT) und `gemini-3.6-flash` (im Folgenden Gemini).

Tabelle 4.1: Antworten in Experiment 0, die nicht die volle Punktzahl erreichten. Alle übrigen dreizehn Fragen wurden von beiden Modellen in allen drei Läufen mit drei Punkten bewertet.

Thema der Frage	Modell	It. 1	It. 2	It. 3	Mittel	Fehlender Kernpunkt
Schritte der EDA	gemini-3.6-flash	2	2	1	1,67	späte Schritte der Analyseketten, insbesondere Feature Engineering, teils auch multivariate Betrachtung und Ausreißererkennung
Mittelwert, Median, Modus	gpt-5.6-luna	2	2	2	2,00	Bezug der Lagemaße zu den Skalenniveaus

bereits bei der univariaten Analyse an und ließ damit die späteren Schritte aus (ein Punkt), die beiden anderen Läufe gaben den überwiegenden Teil des Ablaufs wieder, ließen aber das Feature Engineering und teilweise die multivariate Betrachtung sowie die Ausreißererkennung aus (je zwei Punkte). Gemessen an den sechs Schritten nach Rahmany et al. (2020), die in Abschnitt 2.1 dargestellt sind, fehlen damit systematisch die hinteren Schritte der Analyseketten. GPT nannte den Ablauf demgegenüber in allen drei Läufen vollständig.

Bei der Frage nach Mittelwert, Median und Modus verhielt es sich umgekehrt. Hier blieb GPT in allen drei Läufen bei zwei Punkten, weil durchgängig der Bezug zu den Skalenniveaus fehlte, also die Zuordnung, welches Lagemaß für welches Skalenniveau angemessen ist. Im Gegensatz dazu beantwortete Gemini diese Frage in allen drei Läufen vollständig.

Die beiden Lücken sind damit komplementär und themenspezifisch. Kein Modell ist durchgehend überlegen, jedes weist an anderer Stelle eine Schwäche auf. Zudem sind die Abweichungen über die Wiederholungen hinweg stabil. Bei GPT tritt die Lücke in allen drei Läufen in gleicher Form auf, bei Gemini mit leichter Streuung zwischen einem und zwei Punkten. Die Abweichungen treten damit wiederholt bei denselben Fragen auf und zeigen über die drei Wiederholungen hinweg ein weitgehend stabiles Muster.

Für die weitere Untersuchung erfüllt Experiment 0 damit seine Kontrollfunktion. Da beide Modelle das methodische Grundwissen weitgehend beherrschen, lassen sich Fehler,

die in den datenbezogenen Experimenten auftreten, eher auf die Verarbeitung der bereitgestellten Daten als auf ein fehlendes Methodenwissen zurückführen. Die vergleichende Einordnung über alle Experimente hinweg erfolgt im Anschluss an die datenbezogenen Experimente.

4.2 Auswertung Experiment 1 – Referenzanalyse

4.2.1 Faktische Fragen (Kategorie A)

Die faktischen Fragen der Kategorie A umfassen zehn Fragen mit eindeutig bestimm-
barem Referenzwert, die je Modell in fünf Wiederholungen gestellt wurden. Bewertet
wurde auf einer Skala von null bis zwei Punkten nach der in Tabelle 3.1 festgelegten
Rubrik. Tabelle 4.2 weist für jede Frage den mittleren Punktwert über die fünf Wieder-
holungen sowie dessen Standardabweichung aus. Über alle Fragen erreicht GPT einen
mittleren Punktwert von 1,96, Gemini einen mittleren Punktwert von 1,38.

Tabelle 4.2: Mittlerer Punktwert und Standardabweichung über fünf Wiederholungen
je Frage und Modell für die faktischen Fragen der Kategorie A. Die Skala
reicht von null bis zwei Punkten.

Frage	Ergebnistyp	gpt-5.6-luna		gemini-3.6-flash	
		Mittel	SD	Mittel	SD
A01	Zählwert	2,00	0,00	0,40	0,89
A02	Mittelwert	2,00	0,00	2,00	0,00
A03	Median	2,00	0,00	1,60	0,89
A04	Anteil	2,00	0,00	0,80	0,45
A05	Mittelwert	2,00	0,00	2,00	0,00
A06	Zählwert	1,60	0,89	0,00	0,00
A07	Mittelwert	2,00	0,00	1,80	0,45
A08	Kategorial	2,00	0,00	1,20	1,10
A09	Kategorial	2,00	0,00	2,00	0,00
A10	Kategorial	2,00	0,00	2,00	0,00
Gesamt		1,96		1,38	

GPT erreicht in neun der zehn Fragen den vollen mittleren Punktwert bei einer Standard-

abweichung von null und beantwortet diese Fragen damit über alle fünf Wiederholungen hinweg korrekt. Die einzige Abweichung betrifft die Ausreißerzählung in Frage A06 mit einem mittleren Punktwert von 1,60 und einer Standardabweichung von 0,89. Vier der fünf Wiederholungen nennen den korrekten Wert von 114 Ausreißern, eine Wiederholung nennt abweichend 88. Es handelt sich damit um eine einzelne Abweichung innerhalb einer ansonsten stabilen Antwortfolge.

Gemini zeigt ein nach dem Ergebnistyp differenziertes Muster. Die Mittelwerte in den Fragen A02 und A05 werden in allen Wiederholungen innerhalb der festgelegten Toleranz beantwortet. Auch bei A07 liegen vier der fünf Antworten im Bereich für den vollen Punktwert. Beim Median in Frage A03 sind vier der fünf Antworten korrekt, während eine Wiederholung deutlich abweicht. Besonders niedrige Punktwerte treten dagegen bei den beiden Zählwerten auf. In Frage A01, die nach der Anzahl der Beobachtungen fragt, nennt nur eine der fünf Wiederholungen den korrekten Wert von 1470. Drei Wiederholungen nennen 500 Beobachtungen und eine weitere Antwort wird vor der Ausgabe eines verwertbaren Ergebnisses abgeschnitten. In Frage A06 erreicht keine der fünf Wiederholungen den korrekten Wert von 114 Ausreißern. Drei Wiederholungen nennen mit 50, 56 und 33 deutlich niedrigere Zählwerte, während zwei Antworten vor der Ausgabe eines abschließenden Ergebnisses aufgrund des Ausgabelimits abbrechen. Zudem variieren die berechneten Quartile und Ausreißergrenzen zwischen den Wiederholungen. In einer der abgebrochenen Antworten wird die Berechnung ausdrücklich auf 500 Beobachtungen bezogen, obwohl der bereitgestellte Datensatz 1470 Beobachtungen umfasst.

Ein ähnliches Muster zeigt sich in Frage A04. Die vier bewertbaren numerischen Antworten liegen mit Werten zwischen 15,4 % und 16,76 % vergleichsweise nahe am Referenzwert von 16,12 %. Die Antworten weisen jedoch teilweise ausdrücklich wesentlich geringere Beobachtungszahlen als die 1470 Datensätze aus. Dadurch entstehen zwar teilweise plausible Anteilswerte, diese beruhen jedoch nicht auf der vollständigen Datengrundlage. Eine weitere Wiederholung wird während der manuellen Auszählung abgeschnitten.

Bei den kategorialen Fragen fällt das Ergebnis weniger einheitlich aus. Die Richtung des Zusammenhangs zwischen Überstunden und Kündigungsrate in Frage A09 sowie die Gruppe mit der höchsten Kündigungsrate nach Familienstand in Frage A10 werden von beiden Modellen in allen fünf Wiederholungen korrekt bestimmt. Bei Gemini treten dagegen in Frage A08 Abweichungen auf: Drei Wiederholungen bestimmten Sales korrekt als Abteilung mit der höchsten Kündigungsrate, eine Wiederholung nennt fälschlicherweise Human Resources und eine weitere liefert aufgrund des Abbruchs kein

verwertbares Ergebnis.

Die Standardabweichungen in Tabelle 4.2 geben zusätzlich Aufschluss über die Reproduzierbarkeit der Bewertungen über die fünf Wiederholungen. Bei GPT beträgt die Standardabweichung mit Ausnahme von Frage A06 durchgehend null. Bei Gemini ist sie in den Fragen A01, A03, A04, A07 und A08 von null verschieden und erreicht in Frage A08 mit 1,10 den höchsten Wert. Gleichzeitig zeigt Frage A06, dass eine Standardabweichung von null nicht zwangsläufig eine hohe faktische Korrektheit bedeutet: Das Modell erreicht hier in allen fünf Wiederholungen null Punkte. Eine geringe Streuung kann somit sowohl auf reproduzierbar korrekte als auch reproduzierbar fehlerhafte Ergebnisse hinweisen.

Zusammenfassend erreicht GPT in Kategorie A ein über die Fragen und Wiederholungen hinweg nahezu konstantes Ergebnis. Gemini erreicht bei mehreren Mittelwerten sowie den kategorialen Fragen A09 und A10 hohe und reproduzierbare Bewertungen, weist jedoch insbesondere bei den Zählaufgaben A01 und A06 deutliche Abweichungen auf. Auffällig ist dabei die wiederholte Verarbeitung einer offenbar unvollständigen Anzahl von Beobachtungen. Die mögliche Bedeutung dieses Musters für die Zuverlässigkeit der datenbasierten Analyse wird in der Diskussion näher eingeordnet.

4.2.2 Interpretative Fragen (Kategorie B)

Die interpretativen Fragen der Kategorie B umfassen fünf Fragen nach Zusammenhängen und Merkmalskombinationen, die je Modell in fünf Wiederholungen gestellt wurden. Bewertet wurde die Interpretationsqualität auf einer Skala von null bis zwei Punkten nach der in Tabelle 3.2 festgelegten Rubrik. Tabelle 4.3 weist für jede Frage den mittleren Punktwert über die fünf Wiederholungen sowie dessen Standardabweichung aus. Über alle Fragen erreicht GPT einen mittleren Punktwert von 2,00, Gemini einen mittleren Punktwert von 1,00.

Die grundlegende Richtung der untersuchten Zusammenhänge wird von beiden Modellen überwiegend zutreffend erfasst. So werden unter anderem eine höhere Kündigungsquote bei Mehrarbeit sowie höhere Kündigungsquoten bei geringerer Betriebszugehörigkeit und niedrigeren Einkommen erkannt. Unterschiede zeigen sich vor allem darin, wie vollständig die relevanten Zusammenhänge erfasst, durch konkrete Datenwerte gestützt und gegenüber weitergehenden Interpretationen abgegrenzt werden.

Tabelle 4.3: Mittlerer Punktwert und Standardabweichung über fünf Wiederholungen je Frage und Modell für die interpretativen Fragen der Kategorie B. Die Skala reicht von null bis zwei Punkten.

Frage	gpt-5.6-luna		gemini-3.6-flash	
	Mittel	SD	Mittel	SD
B01	2,00	0,00	1,00	0,71
B02	2,00	0,00	1,00	0,00
B03	2,00	0,00	1,00	0,00
B04	2,00	0,00	1,00	0,00
B05	2,00	0,00	1,00	0,00
Gesamt	2,00		1,00	

GPT erreicht bei allen fünf Fragen und in sämtlichen Wiederholungen den vollen Punktwert. Entsprechend beträgt die Standardabweichung für jede Frage null. Die Interpretationen werden durchgängig mit konkreten aggregierten Kennzahlen gestützt und entsprechend der Bewertungsrubrik eingeordnet. In Frage B01 werden beispielsweise die Kündigungsquoten für Beschäftigte mit Überstunden mit 30,5 % (127 von 416) gegenüber 10,4 % (110 von 1054) für Beschäftigte ohne Überstunden quantifiziert. Neben Überstunden werden weitere relevante Merkmale wie Joblevel, Aktienoptionslevel, Geschäftsreisen, Familienstand und Betriebszugehörigkeit anhand aggregierter Werte eingeordnet. Auch bei den übrigen Fragen verbindet das Modell die Interpretation mit konkreten Kennzahlen, anstatt den Zusammenhang ausschließlich verbal zu beschreiben.

Darüber hinaus grenzt GPT die deskriptiven Ergebnisse wiederholt von kausalen Schlussfolgerungen ab. So wird bei der Interpretation der Kündigungsfaktoren ausdrücklich darauf hingewiesen, dass die beobachteten Zusammenhänge keinen kausalen Einfluss nachweisen. Die Antworten beschränken sich damit überwiegend auf Aussagen, die sich aus den bereitgestellten Daten ableiten lassen. Der maximale mittlere Punktwert von 2,00 resultiert somit nicht allein aus der zutreffenden Bestimmung der Richtung, sondern auch aus der quantitativen Begründung und der vorsichtigen Einordnung der Ergebnisse.

Bei Gemini beträgt der mittlere Punktwert dagegen bei allen fünf Fragen 1,00. Trotz dieses einheitlichen Mittelwerts unterscheiden sich die Antwortmuster zwischen den Fragen. Besonders deutlich wird dies bei Frage B01, für die mit 0,71 die einzige von null

verschiedene Standardabweichung vorliegt. Einzelne Wiederholungen identifizieren die zentralen Zusammenhänge zutreffend und stützen diese teilweise mit konkreten Kennzahlen. In einer Wiederholung werden die relevanten Faktoren beispielsweise umfassend erkannt und hinsichtlich ihrer Richtung und Stärke eingeordnet. Demgegenüber basiert die fünfte Wiederholung fälschlicherweise auf 500 statt auf den vollständig bereitgestellten 1470 Beobachtungen. Die daraus berichteten Kennzahlen beziehen sich folglich nicht auf den vollständigen Datensatz. Diese Antwort wurde mit null Punkten bewertet. Der Fragemittelwert von 1,00 verdeckt somit eine im Vergleich zu den übrigen Fragen erhöhte Variation der Antwortqualität.

Über die Kategorie hinweg zeigt Gemini zudem eine schwächere quantitative Belegbindung. Teilweise werden einzelne Beschäftigte als Beispiele für einen Zusammenhang angeführt, anstatt diesen durch einen Vergleich der entsprechenden Gruppen quantitativ zu belegen. In anderen Antworten wird zwar die zutreffende Richtung eines Zusammenhangs genannt, dessen Stärke jedoch nicht oder nur unzureichend durch konkrete Datenwerte gestützt. Die Antworten erfüllen damit häufig die grundlegende inhaltliche Interpretation, jedoch nicht sämtliche Anforderungen der höchsten Bewertungsstufe.

Eine weitere Auffälligkeit betrifft die Abgrenzung zwischen deskriptiver Interpretation und weitergehender Erklärung. Einzelne Antworten von Gemini verwenden kausal anmutende Formulierungen, indem Zusammenhänge beispielsweise als “drivers” bezeichnet oder mit “Workplace Burnout” verknüpft werden. Teilweise werden daraus auch Handlungsempfehlungen abgeleitet. Ebenso treten Erklärungen auf, die sich nicht unmittelbar anhand des Datensatzes überprüfen lassen, etwa die Begründung einer höheren Kündigungsneigung jüngerer Beschäftigter mit einer vermeintlich höheren beruflichen Mobilität. Die grundlegenden datenbasierten Zusammenhänge können dabei zutreffend sein; die darüber hinausgehende Erklärung ist jedoch nicht durch die vorliegenden Daten selbst gedeckt. Eine Abgrenzung zwischen Assoziation und kausaler Interpretation erfolgt damit weniger konsistent als bei GPT.

Hinsichtlich der Reproduzierbarkeit zeigt sich ebenfalls ein Unterschied zwischen den Modellen. Für GPT beträgt die Standardabweichung in allen fünf Fragen null, sodass sämtliche Wiederholungen derselben höchsten Bewertungsstufe zugeordnet werden. Bei Gemini beträgt die Standardabweichung für Fragen B02 bis B05 ebenfalls null. Sämtliche Wiederholungen erreichen jeweils einen Punkt. Die konstante Punktbewertung bedeutet dabei nicht, dass die Antworten inhaltlich oder sprachlich identisch sind, sondern dass ihre Interpretationsqualität nach der verwendeten Rubrik jeweils derselben Bewertungs-

stufe entspricht. Frage B01 bildet mit einer Standardabweichung von 0,71 die Ausnahme und zeigt, dass die Qualität zwischen den Wiederholungen stärker variiert.

Zusammenfassend zeigt sich in Kategorie B ein deutlicher Unterschied in der Qualität und Stabilität der datenbasierten Interpretation. GPT erreicht über sämtliche 25 Antworten hinweg die höchste Bewertungsstufe und verbindet die zutreffende Interpretation mit konkreten aggregierten Kennzahlen sowie einer überwiegend vorsichtigen Abgrenzung gegenüber kausalen Schlussfolgerungen. Gemini erkennt die grundlegende Richtung der untersuchten Zusammenhänge überwiegend, erreicht jedoch aufgrund unvollständiger quantitativer Belege und weitergehender Interpretationen einen niedrigeren mittleren Punktwert. Hinzu kommt bei Frage B01 eine erhöhte Variation zwischen den Wiederholungen, die unter anderem auf die Verarbeitung einer unvollständigen Datengrundlage in einer Antwort zurückzuführen ist.

4.2.3 Halluzinationsfallen (Kategorie C)

Die Halluzinationsfallen der Kategorie C umfassen fünf Fragen mit einer nicht zutreffenden Prämisse, die je Modell in fünf Wiederholungen gestellt wurden. Anders als in den Kategorien A und B wird kein Punktwert vergeben. Stattdessen werden je Antwort die Anzahl der nicht durch die Daten gedeckten Behauptungen erfasst und die Antwort binär als verlässlich oder nicht verlässlich klassifiziert. Tabelle 4.4 weist für jede Frage den Anteil verlässlicher Antworten sowie die mittlere Anzahl nicht gedeckter Behauptungen je Modell aus. Über alle Fragen erreicht GPT einen Anteil verlässlicher Antworten von 52 % bei durchschnittlich 0,48 nicht gedeckten Behauptungen pro Antwort. Gemini erreicht einen Anteil von 64 % bei durchschnittlich 0,44 nicht gedeckten Behauptungen.

Anders als in den Kategorien A und B, in denen GPT höhere mittlere Bewertungen erreicht, zeigt sich in Kategorie C ein leicht zugunsten von Gemini verschobenes Gesamtbild. Die Ergebnisse unterscheiden sich dabei deutlich zwischen den einzelnen Fragen und den jeweils verwendeten Fallentypen.

Dies zeigt sich insbesondere beim Vergleich der drei Fragen zu nicht vorhandenen Variablen. Bei den Fragen C02 und C05 erkennen beide Modelle in sämtlichen Wiederholungen, dass die jeweils vorausgesetzte Variable im Datensatz nicht vorhanden ist. Entsprechend werden alle 20 Antworten als verlässlich klassifiziert und enthalten keine nicht gedeckte Behauptung. Teilweise nennen die Modelle zusätzlich ähnliche, tatsächlich im Datensatz vorhandene Variablen, ohne diese mit der nicht vorhandenen Variable

Tabelle 4.4: Anteil verlässlicher Antworten (Verlässlich) und mittlere Anzahl nicht gedeckter Behauptungen ($\emptyset$ Halluz.) über fünf Wiederholungen je Frage und Modell für die Halluzinationsfallen der Kategorie C.

Frage	Fallentyp	gpt-5.6-luna		gemini-3.6-flash	
		Verlässlich	$\emptyset$ Halluz.	Verlässlich	$\emptyset$ Halluz.
C01	nicht vorhandene Variable	0 %	1,0	20 %	1,2
C02	nicht vorhandene Variable	100 %	0,0	100 %	0,0
C03	falscher Wertebereich	60 %	0,4	100 %	0,0
C04	suggestive Prämisse	0 %	1,0	0 %	1,0
C05	nicht vorhandene Variable	100 %	0,0	100 %	0,0
Gesamt		52 %	0,48	64 %	0,44

gleichzusetzen.

Ein deutlich anderes Muster zeigt sich bei Frage C01. Auch hier wird mit **EmployeeTenure** nach einer nicht vorhandenen Variable gefragt. Mit **YearsAtCompany** enthält der Datensatz jedoch eine Variable mit einer ähnlichen inhaltlichen Bedeutung. GPT erkennt die fehlende Variable in keiner der fünf Wiederholungen und gibt stattdessen jeweils einen Mittelwert von ungefähr 7,01 aus, der **YearsAtCompany** entspricht. Damit werden alle fünf Antworten als nicht verlässlich klassifiziert.

Bei Gemini zeigt sich bei C01 ein ähnliches, jedoch nicht vollständig konsistentes Verhalten. In einer der fünf Wiederholungen erkennt das Modell ausdrücklich, dass **EmployeeTenure** nicht im Datensatz enthalten ist. Diese Antwort wird als verlässlich klassifiziert. In den übrigen vier Wiederholungen wird dagegen ein Wert für die nicht vorhandene Variable ausgegeben. Teilweise wird dabei ausdrücklich eine Entsprechung zu **YearsAtCompany** behauptet, in anderen Fällen wird unmittelbar ein numerischer Wert ausgegeben. Eine Wiederholung bezieht die Berechnung zudem auf eine vom vollständigen Datensatz abweichende Anzahl von Beobachtungen. Dadurch entstehen bei Gemini trotz eines höheren Anteils verlässlicher Antworten durchschnittlich 1,2 nicht gedeckte Behauptungen pro Antwort gegenüber 1,0 bei GPT.

Bei Frage C03 wird in der Frage fälschlicherweise vorausgesetzt, dass **JobSatisfaction**

Werte von eins bis zehn annehmen könne. Tatsächlich liegt der Wertebereich im Datensatz zwischen eins und vier. Hier zeigt sich der deutlichste Unterschied zwischen den Modellen. Gemini erkennt und korrigiert die falsche Prämisse in allen fünf Wiederholungen. Sämtliche Antworten werden daher als verlässlich klassifiziert und enthalten keine nicht gedeckte Behauptung. GPT erreicht dagegen einen Anteil verlässlicher Antworten von 60 %. In drei Wiederholungen wird der tatsächliche Wertebereich korrekt berücksichtigt. In zwei Wiederholungen wird die falsche Prämisse jedoch sprachlich übernommen, indem der Wert zehn als „the maximum JobSatisfaction rating of 10“ bezeichnet wird. Obwohl für diesen Wert keine Beobachtungen gefunden werden, wird damit der in der Frage vorgegebene Wertebereich als gültig behandelt. Die nicht gedeckte Behauptung besteht somit nicht in der ausgegebenen Anzahl von null, sondern in der Übernahme der falschen Prämisse.

Ein anderes Fehlerbild zeigt Frage C04 mit einer suggestiven Prämisse. Die Frage unterstellt, dass Beschäftigte mit einer größeren Entfernung zum Arbeitsort eindeutig häufiger kündigen. Die Daten zeigen zwar, dass die Attritionsquote für die in der Frage betrachtete Teilgruppe mit `DistanceFromHome` > 20 über der Attritionsquote des gesamten Datensatzes liegt. Dies ist jedoch nicht gleichbedeutend mit einem starken allgemeinen Zusammenhang zwischen Entfernung und Kündigung. Über den vollständigen Datensatz ist der Zusammenhang zwischen `DistanceFromHome` und `Attrition` mit einem Korrelationskoeffizienten von $r = 0,0779$ lediglich schwach ausgeprägt.

Die Berechnung der in C04 erfragten Attritionsquote stellt daher für sich genommen keine nicht gedeckte Behauptung dar. Nach der Bewertungsmethodik wäre eine solche Berechnung zulässig, sofern die suggestive Grundannahme der Frage nicht unkritisch übernommen wird. Beide Modelle berechnen in sämtlichen Wiederholungen die Attritionsquote für Beschäftigte mit `DistanceFromHome` > 20, ohne die Stärke des unterstellten Zusammenhangs zu hinterfragen oder die Prämisse zu relativieren. Die ausgegebenen Werte liegen dabei ungefähr zwischen 18 % und 22 %. In einer Antwort von GPT wird zusätzlich festgestellt, dass die berechnete Quote höher als die Attritionsquote der Gesamtpopulation ist. Auch diese Aussage kann für die betrachtete Teilgruppe zutreffen, stellt jedoch keinen Beleg für einen starken Zusammenhang über den gesamten Wertebereich von `DistanceFromHome` dar. Entscheidend für die Klassifikation ist somit nicht die Berechnung der Gruppenquote, sondern die fehlende Zurückweisung beziehungsweise Relativierung der suggestiven Prämisse. Entsprechend werden bei C04 sämtliche Antworten beider Modelle als nicht verlässlich klassifiziert.

Der Vergleich der beiden ausgewiesenen Maße verdeutlicht zudem, dass der Anteil verlässlicher Antworten und die mittlere Anzahl nicht gedeckter Behauptungen unterschiedliche Eigenschaften der Antworten erfassen. Eine Antwort gilt bereits dann als nicht verlässlich, wenn mindestens eine nicht gedeckte Behauptung enthalten ist. Zusätzliche nicht gedeckte Behauptungen verändern diese binäre Klassifikation nicht, erhöhen jedoch die Halluzinationszahl. Bei Frage C01 erreicht Gemini mit 20 % einen höheren Anteil verlässlicher Antworten als GPT mit 0 %, weist mit durchschnittlich 1,2 gegenüber 1,0 zugleich jedoch eine höhere Anzahl nicht gedeckter Behauptungen pro Antworten auf. In einer einzelnen Antwort von Gemini treten drei solcher Behauptungen gleichzeitig auf: Die nicht vorhandene Variable **EmployeeTenure** wird ohne Grundlage mit **YearsAtCompany** gleichgesetzt, die Anzahl der Beobachtungen wird mit 718 statt 1470 angegeben und auf dieser abweichenden Datengrundlage eine Summe von 5038 für **YearsAtCompany** ausgewiesen. Während die binäre Klassifikation diese Antwort unabhängig von der Anzahl der nicht gedeckten Behauptungen als nicht verlässlich einstuft, bildet deren zusätzliche Auszählung das Ausmaß der nicht durch die Daten gedeckten Angaben ab.

Im Ganzen zeigt Kategorie C ein anderes Muster als die faktischen und interpretativen Fragen. Gemini erreicht mit 64 % gegenüber 52 % insgesamt einen höheren Anteil verlässlicher Antworten und mit 0,44 gegenüber 0,48 zugleich eine geringfügig niedrigere mittlere Anzahl nicht gedeckter Behauptungen. Die Ergebnisse unterscheiden sich jedoch deutlich zwischen den einzelnen Fallentypen. Bei C02 und C05 erkennen beide Modelle die nicht vorhandenen Variablen durchgehend. Bei C01 führt die inhaltlich ähnliche Variable **YearsAtCompany** dagegen häufig zur Beantwortung der Frage, obwohl **EmployeeTenure** selbst nicht im Datensatz vorhanden ist. GPT übernimmt diese Prämisse in allen fünf Wiederholungen, während Gemini sie in einer Wiederholung korrekt zurückweist. Den falschen Wertebereich in C03 erkennt Gemini durchgehend, während GPT ihn in zwei Wiederholungen übernimmt. Bei der suggestiven Prämisse in C04 berechnen beide Modelle zwar grundsätzlich plausible Gruppenquoten, hinterfragen jedoch in keiner Iteration die in der Frage vorausgesetzte Stärke des Zusammenhangs.

Literaturverzeichnis

- Agrawal, A., Suzgun, M., Mackey, L., & Kalai, A. T. (2024, 20. März). Do Language Models Know When They're Hallucinating References? <https://doi.org/10.48550/arXiv.2305.18248>
- Bai, Z., Wang, P., Xiao, T., He, T., Han, Z., Zhang, Z., & Shou, M. Z. (2025, 1. April). Hallucination of Multimodal Large Language Models: A Survey. <https://doi.org/10.48550/arXiv.2404.18930>
- Bender, E. M., Gebru, T., McMillan-Major, A., & Shmitchell, S. (2021). On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, 610–623. <https://doi.org/10.1145/3442188.3445922>
- Bornschlegl, M. (2024). Towards Trustworthiness in AI-based Big Data Analysis. <https://doi.org/10.18445/20240426-221234-0>
- Boslaugh, S. (2012). *Statistics in a Nutshell* (2. Aufl.). O'Reilly Media.
- Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D., Wu, J., Winter, C., & Amodei, D. (2020, 28. Mai). *Language Models are Few-Shot Learners*. <https://doi.org/10.48550/arXiv.2005.14165>
- Chen, M., Tworek, J., Jun, H., Yuan, Q., Pinto, H. P. d. O., Kaplan, J., Edwards, H., Burda, Y., Joseph, N., Brockman, G., Ray, A., Puri, R., Krueger, G., Petrov, M., Khlaaf, H., Sastry, G., Mishkin, P., Chan, B., Gray, S., ... Zaremba, W. (2021, 14. Juli). Evaluating Large Language Models Trained on Code. <https://doi.org/10.48550/arXiv.2107.03374>
- Comment: corrected typos, added references, added authors, added acknowledgements.
- Cheng, L., Li, X., & Bing, L. (2023). Is GPT-4 a Good Data Analyst? In H. Bouamor, J. Pino & K. Bali (Hrsg.), *Findings of the Association for Computational Linguistics: EMNLP 2023* (S. 9496–9514). Association for Computational Linguistics.

- <https://doi.org/10.18653/v1/2023.findings-emnlp.637>
Neu für 2.3.
- Cheng, S., Pan, L., Yin, X., Wang, X., & Wang, W. Y. (2024, 10. Oktober). Understanding the Interplay between Parametric and Contextual Knowledge for Large Language Models. <https://doi.org/10.48550/arXiv.2410.08414>
- Hammesfahr, J., & Spott, M. (2021). Identifikation relevanter Zusammenhänge in Daten mit maschinellem Lernen. In T. Barton & C. Müller (Hrsg.), *Data Science anwenden: Einführung, Anwendungen und Projekte* (S. 201–218). Springer Fachmedien. https://doi.org/10.1007/978-3-658-33813-8_12
- Hu, X., Zhao, Z., Wei, S., Chai, Z., Ma, Q., Wang, G., Wang, X., Su, J., Xu, J., Zhu, M., Cheng, Y., Yuan, J., Li, J., Kuang, K., Yang, Y., Yang, H., & Wu, F. (2024, 11. März). InfiAgent-DABench: Evaluating Agents on Data Analysis Tasks. <https://doi.org/10.48550/arXiv.2401.05507>
Comment: 27 pages, 7 figures, work in progress.
- Ji Ziwei, NAYEON LEE, RITA FRIESKE, TIEZHENG YU, DAN SU, HO SHU CHAN, ANDREA MADOTTO & PASCALE FUNG. (2022). Survey of Hallucination in Natural Language Generation. *ACM Comput. Surv.*, (1), 1–59. <https://doi.org/https://doi.org/10.48550/arXiv.2202.03629>
- Koesten, L., Gregory, K., Groth, P., & Simperl, E. (2021). Talking datasets: Understanding data sensemaking behaviours. *International Journal of Human-Computer Studies*, 146, 102562. <https://doi.org/10.1016/j.ijhcs.2020.102562>
- Langer, T., & Meisen, T. (2019). Towards Utilizing Domain Expertise for Exploratory Data Analysis. *Proceedings of the 12th International Symposium on Visual Information Communication and Interaction*, 1–5. <https://doi.org/10.1145/3356422.3356434>
- Li, J., Huo, N., Gao, Y., Shi, J., Zhao, Y., Qu, G., Wu, Y., Ma, C., Lou, J.-G., & Cheng, R. (2024, 8. März). Tapilot-Crossing: Benchmarking and Evolving LLMs Towards Interactive Data Analysis Agents. <https://doi.org/10.48550/arXiv.2403.05307>
Comment: 30 pages, 7 figures.
- Rahmany, M., Zin, A. M., & Sundararajan, E. A. (2020). COMPARING TOOLS PROVIDED BY PYTHON AND R FOR EXPLORATORY DATA ANALYSIS. *IJISCS (International Journal of Information System and Computer Science)*, 4(3), 131. <https://doi.org/10.56327/ijiscs.v4i3.933>
- Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.

- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł. u., & Polosukhin, I. (2017). Attention is All you Need. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan & R. Garnett (Hrsg.), *Advances in Neural Information Processing Systems* (Bd. 30). Curran Associates, Inc. https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf
- Wang, X., Antoniadis, A., Elazar, Y., Amayuelas, A., Albalak, A., Zhang, K., & Wang, W. Y. (2024, 20. Juli). *Generalization v.s. memorization: Tracing language models' capabilities back to pretraining data* [arXiv.org]. Verfügbar 4. Juni 2026 unter <https://arxiv.org/abs/2407.14985v5>
- Wang, Y., Feng, S., Wang, H., Shi, W., Balachandran, V., He, T., & Tsvetkov, Y. (2024, 15. Oktober). Resolving Knowledge Conflicts in Large Language Models. <https://doi.org/10.48550/arXiv.2310.00935>
- Wei, J., Tay, Y., Bommasani, R., Raffel, C., Zoph, B., Borgeaud, S., Yogatama, D., Bosma, M., Zhou, D., Metzler, D., Chi, E. H., Hashimoto, T., Vinyals, O., Liang, P., Dean, J., & Fedus, W. (2022, 26. Oktober). Emergent Abilities of Large Language Models. <https://doi.org/10.48550/arXiv.2206.07682>
- Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E., Le, Q., & Zhou, D. (2023, 10. Januar). Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. <https://doi.org/10.48550/arXiv.2201.11903>
- Xu, Z., Jain, S., & Kankanhalli, M. (2025, 13. Februar). Hallucination is Inevitable: An Innate Limitation of Large Language Models. <https://doi.org/10.48550/arXiv.2401.11817>
- Yuan, X., Yang, Z., Wang, Y., Liu, S., Zhao, J., & Liu, K. (2024). Discerning and Resolving Knowledge Conflicts through Adaptive Decoding with Contextual Information-Entropy Constraint. In L.-W. Ku, A. Martins & V. Srikumar (Hrsg.), *Findings of the Association for Computational Linguistics: ACL 2024* (S. 3903–3922). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2024.findings-acl.234>
- Zhecheva, D. (2024). Exploratory Data Analysis and the Rise of Large Language Models - Gaming Industry Insights. *TEM Journal*, 13(1), 561–569. Verfügbar 28. Mai 2026 unter <https://www.ceeol.com/search/article-detail?id=1222943>
- Zheng, D., Lapata, M., & Pan, J. Z. (2024, 16. Dezember). How Reliable are LLMs as Knowledge Bases? Re-thinking Facutality and Consistency. <https://doi.org/10.48550/arXiv.2407.13578>