

Inhaltsverzeichnis

1	Einleitung	1
1.1	Problemstellung	1
1.2	Zielsetzung	1
1.3	Forschungsfragen	1
1.4	Aufbau der Arbeit	1
2	Theoretische Grundlagen und Stand der Technik	2
2.1	Explorative Datenanalyse (EDA)	2
2.2	Large Language Models (LLMs)	6
2.3	LLMs in der Datenanalyse	7
2.4	Zuverlässigkeit und Grenzen LLM-gestützter Analyse	9
3	Methodik und Durchführung	12
3.1	Datengrundlage	12
3.1.1	Beschreibung des Datensatzes	12
3.1.2	Zweistufiger Datensatzaufbau	12
3.1.3	Referenzwertberechnung	13
3.2	Forschungsdesign	14
3.3	Untersuchungsansatz	15
3.3.1	Kategorie A: Faktische Fragen und Toleranzbänder	17
3.3.2	Kategorie B: Interpretative Fragen	18
3.3.3	Kategorie C: Halluzinationsfallen	19
3.3.4	Aggregation der Bewertung	20
3.3.5	Bewertung in Experiment 2	22
3.4	Durchführung	24
3.4.1	Experiment 0	24
3.4.2	Experiment 1	25
3.4.3	Experiment 2	25

4	Ergebnisse	27
4.1	Auswertung Experiment 0: Methodisches Vorwissen	27
4.2	Auswertung Experiment 1 – Referenzanalyse	29
4.2.1	Faktische Fragen (Kategorie A)	29
4.2.2	Interpretative Fragen (Kategorie B)	31
4.2.3	Halluzinationsfallen (Kategorie C)	34
4.2.4	Ergebnisse zu Experiment 2	37
4.3	Zusammenfassung der Ergebnisse	40
5	Diskussion	42
5.1	Beantwortung der Forschungsfragen	42
5.1.1	FF1: Datengrundlage gegenüber vortrainiertem Wissen	42
5.1.2	FF2: Übereinstimmung mit den Referenzwerten und auftretende Abweichungen	43
5.1.3	FF3: Methodisches Vorgehen zur explorativen Datenanalyse	45
5.2	Übergreifende Diskussion	45
5.3	Limitationen	49
6	Fazit und Ausblick	53
6.1	Fazit	53
6.2	Ausblick	53
	Literaturverzeichnis	54

Abbildungsverzeichnis

2.1	Prozessschritte der explorativen Datenanalyse	3
2.2	Rechtsschiefe Verteilung am Beispiel MonthlyIncome	5
2.3	Datenbasierte und wissensbasierte Ausgaben	11

Tabellenverzeichnis

3.1	Bewertung faktischer Fragen (Kategorie A)	18
3.2	Bewertung interpretativer Fragen (Kategorie B)	19
3.3	Halluzinationsmaße für Kategorie C	21
3.4	Kodierschema für Experiment 2	22
3.5	Kreuztabelle vor und nach der Manipulation	26
4.1	Abweichungen von der vollen Punktzahl in Experiment 0	28
4.2	Ergebnisse der faktischen Fragen (Kategorie A)	29
4.3	Ergebnisse der interpretativen Fragen (Kategorie B)	32
4.4	Ergebnisse der Halluzinationsfällen (Kategorie C)	35
4.5	Ergebnisse zu Experiment 2	38
4.6	Ergebnisse von Experiment 2 nach Analysefrage	38

1 Einleitung

1.1 Problemstellung

1.2 Zielsetzung

1.3 Forschungsfragen

/todoUntersucht wird in der Arbeit die Datenkonsistenz und Zuverlässigkeit in der LLM-gestützten explorativen Datenanalyse.

FF1 Inwieweit basieren LLM-gestützte Explorative Datenanalyse (EDA)-Ergebnisse auf den bereitgestellten Daten und nicht auf vortrainiertem Wissen der Modelle?

FF2 Wie genau stimmen die Ausgaben von Large Language Models (LLMs) mit manuell berechneten Referenzwerten überein und welche Abweichungen treten auf?

FF3 Über welches methodische Vorgehen zur explorativen Datenanalyse verfügen LLMs?

1.4 Aufbau der Arbeit

2 Theoretische Grundlagen und Stand der Technik

2.1 Explorative Datenanalyse (EDA)

Der Begriff der explorativen Datenanalyse geht auf Tukey (1977) zurück, der damit einen Analyseansatz prägte, bei dem Daten zunächst offen und grafisch gestützt untersucht werden, um Muster und Auffälligkeiten zu erkennen und Hypothesen zu gewinnen, statt vorab festgelegte Annahmen konfirmatorisch zu prüfen. Heute wird die EDA als ein iterativer Analyseprozess verstanden, in dessen Verlauf ein Datensatz systematisch untersucht wird, um Strukturen zu erkennen, Anomalien wie Ausreißer aufzudecken sowie erste Hypothesen zu generieren und vorläufig zu bewerten (Langer & Meisen, 2019). Im Rahmen dieser Methodik kommen primär deskriptive Statistiken und visuelle Werkzeuge zum Einsatz, um aussagekräftige Hinweise aus den Daten zu gewinnen (Rahmany et al., 2020).

Ein zentrales Merkmal der EDA ist ihr iterativer Charakter. Sie stellt keinen einmaligen, abgeschlossenen Prozess dar, sondern umfasst mehrere aufeinander aufbauende Analyseschritte, bis ein hinreichendes Verständnis der Daten erreicht ist (Rahmany et al., 2020). Da dieser Prozess nicht rein automatisiert abläuft, hängt die Qualität der Ergebnisse maßgeblich von der Fähigkeit des Analysten ab, die richtigen Fragen zu stellen und eine geeignete Analyseinteraktion durchzuführen, um die Daten sinnvoll zu interpretieren (Langer & Meisen, 2019).

Zur strukturierten Durchführung beschreiben Rahmany et al. (2020) sechs aufeinander aufbauende Schritte. Der Prozess beginnt mit der formalen Erfassung, bei der die vorhandenen Variablen nach Datentyp und Bedeutung erfasst und klassifiziert werden. Ob eine Variable nominal, ordinal, diskret oder stetig skaliert ist, bestimmt unmittelbar, welche statistischen Verfahren auf sie anwendbar sind. Darauf aufbauend erfolgt die univariate Analyse, in der jede Variable einzeln hinsichtlich zentraler Tendenz und Streuung

untersucht wird, um die Form der Verteilung zu erfassen und auffällige Muster frühzeitig zu erkennen. Im dritten Schritt werden Zusammenhänge zwischen den Attributen untersucht, insbesondere Korrelationen, Kovarianzen und Streudiagramme. Darauf folgt die Identifikation auffälliger Muster wie fehlender oder ungewöhnlicher Werte, die vor der weiteren Analyse behandelt werden müssen, um die Ergebnisse nicht zu verzerren. Im fünften Schritt werden Ausreißer erkannt, also Datenpunkte, die deutlich von der übrigen Verteilung abweichen; sie können die Schlussfolgerungen einer Analyse beeinflussen und zu ungenauen Befunden führen. Abschließend umfasst das Feature Engineering die Aufbereitung der Rohdaten für weiterführende Verfahren, etwa für den Einsatz in Modellen des maschinellen Lernens (Rahmany et al., 2020).




Abbildung 2.1: Sechs Schritte der explorativen Datenanalyse nach Rahmany et al. (2020). Der gestrichelte Pfeil kennzeichnet den iterativen Charakter des Prozesses.

Unabhängig von der genauen Prozessphase lassen sich die in der EDA eingesetzten Techniken nach Rahmany et al. (2020) grundsätzlich in zwei Kategorien unterteilen: deskriptive Statistiken zur quantitativen Beschreibung der Daten sowie grafische Methoden zur visuellen Exploration (Rahmany et al., 2020).

Deskriptive Statistiken dienen der Zusammenfassung qualitativer wie quantitativer Daten und zugleich der Prüfung, ob die Daten für weiterführende Analysen geeignet sind. Nach der Anzahl der betrachteten Variablen wird dabei zwischen univariater, bivariater und multivariater Analyse unterschieden: Die univariate Analyse betrachtet ausschließlich eine einzelne Variable, die bivariate den Zusammenhang zweier Variablen, während die multivariate Analyse mehrere Variablen und deren Beziehungen zugleich einbezieht und dadurch deutlich aufwendiger ist. Hinsichtlich der verwendeten Maße wird zwischen zentraler Tendenz und Streuung unterschieden. Zu den Maßen der zentralen Tendenz zählen Mittelwert, Median und Modus, wobei der Median den mittleren Wert einer

der Größe nach geordneten Datenreihe bezeichnet und dem zweiten Quartil entspricht. Streuungsmaße wie Varianz, Spannweite und Standardabweichung beschreiben demgegenüber, wie weit die Werte um diesen Mittelpunkt verteilt sind. Die Form einer Verteilung lässt sich anhand ihrer Symmetrie beschreiben. In einer symmetrischen Verteilung fallen Mittelwert, Median und Modus zusammen, wobei sie in einer schiefen Verteilung voneinander abweichen. Das Ausmaß dieser Abweichung ist ein Maß für die Schiefe (Boslaugh, 2012, S. 58). Bei einer rechtsschiefen Verteilung liegen die meisten Werte im unteren Bereich, während wenige hohe Werte einen langen Ausläufer nach rechts bilden. Da der Mittelwert im Gegensatz zum Median durch solche Extremwerte beeinflusst wird, ist bei ausgeprägter Schiefe der Median das aussagekräftige Lagemaß. Zur Annäherung an eine symmetrische Form können rechtsschiefe Daten zudem transformiert werden, etwa durch eine Wurzel oder eine Logarithmus-Transformation (Bornschlegl, 2024, S. 146). Während Lage- und Streuungsmaße einzelne Variablen beschreiben, erfasst der Produkt-Moment-Korrelationskoeffizient nach Pearson die Stärke und Richtung eines linearen Zusammenhangs zweier metrischer Variablen (Boslaugh, 2012, S. 178–189). Sein Wertebereich reicht von minus eins bis plus eins, wobei Werte nahe null einen schwachen und Werte nahe den Extremen einen starken Zusammenhang anzeigen. In welchem Maß die Variablen gleichgerichtete oder gegenläufige lineare Zusammenhänge aufweisen, hängt mit dem Vorzeichen zusammen. Da der Koeffizient ausschließlich lineare Zusammenhänge misst, schließt ein Wert nahe null einen nichtlinearen Zusammenhang nicht aus. Zudem lässt sich aus einer Korrelation kein kausaler Zusammenhang ableiten, da die gemeinsame Veränderung zweier Variablen auch auf eine dahinterliegende dritte Variable zurückgehen könnte (Boslaugh, 2012, S. 178–189).

Die grafischen Methoden dienen der visuellen Aufbereitung der Daten mit dem Ziel, handlungsrelevante Erkenntnisse zu gewinnen. Die Wahl der Darstellung richtet sich dabei nach dem Datentyp (Rahmany et al., 2020).

Zur Identifikation von Ausreißern schlägt Tukey (1977) eine Faustregel vor, die auf dem Abstand zwischen den Quartilen beruht. Ausgehend vom Interquartilsabstand wird ein Schritt als das 1,5-fache dieses Abstands definiert. Werte, die mehr als einen Schritt außerhalb der Quartile liegen, gelten als auffällig. Dieses Kriterium bildet die Grundlage der bis heute gebräuchlichen 1,5-fachen Interquartilsregel und ist zugleich das Konstruktionsprinzip des Box-Plots, bei dem die Box von Quartil zu Quartil reicht und durch den Median geteilt wird (Tukey, 1977).

Die bloße Anwendung dieser Techniken macht jedoch keine gehaltvolle Analyse aus.




Abbildung 2.2: Verteilung der Variable `MonthlyIncome` im verwendeten Datensatz. Der Mittelwert liegt rechts vom Median, was für eine rechtsschiefe Verteilung charakteristisch ist.

Koesten et al. (2021) untersuchen, wie Personen vorgehen, wenn sie einen Datensatz verstehen wollen und beobachten dabei Aktivitäten, die über das Berechnen von Kennzahlen hinausreichen. Auf einer ersten Ebene setzen sich die Untersuchten vertieft mit dem Inhalt der Daten auseinander, indem sie Beziehungen zwischen Variablen herstellen, einzelne Werte exemplarisch heranziehen, die Datenqualität einschätzen und Unsicherheiten hinterfragen, etwa die Bedeutung fehlender Werte oder unerklärter Abkürzungen. Auf einer weiteren Ebene ordnen sie die Daten in ihren Entstehungs- und Anwendungskontext ein, indem sie deren Granularität, den ursprünglichen Erhebungszweck sowie die Repräsentativität für die zugrunde liegende Grundgesamtheit hinterfragen (Koesten et al., 2021).

Daraus lässt sich ableiten, dass die Güte einer explorativen Analyse nicht allein an der Korrektheit der berechneten Werte zu bemessen ist. Eine Aussage kann rechnerisch zutreffen und gleichwohl analytisch dürftig bleiben, wenn sie sich auf die Wiedergabe von Kennzahlen beschränkt. In Anlehnung an die von Koesten et al. (2021) beobachteten Aktivitäten wird eine Interpretation in der vorliegenden Arbeit dann als gehaltvoll verstanden, wenn sie Zusammenhänge zwischen Variablen herstellt, ihre Aussagen mit konkreten Werten aus dem Datensatz belegt, Auffälligkeiten und Unsicherheiten benennt und die Grenzen ihrer Aussagekraft reflektiert. Die Interpretationsqualität stellt damit eine von der faktischen Korrektheit zu unterscheidende Bewertungsdimension dar. Dies

gilt umso mehr, wenn Analyseschritte nicht von Menschen, sondern von LLMs ausgeführt werden.

2.2 Large Language Models (LLMs)

LLMs sind neuronale Sprachmodelle, die auf Basis der Transformer-Architektur trainiert werden. Der Transformer verarbeitet eine Eingabesequenz nicht schrittweise, sondern setzt ihre Elemente über einen Attention-Mechanismus zueinander in Beziehung. In den Self-Attention-Schichten kann jede Position einer Sequenz auf alle übrigen Positionen zugreifen und deren Relevanz für den jeweiligen Kontext gewichten (Vaswani et al., 2017). Die Wissensgrundlage dieser Modelle entsteht in der Vortrainingsphase, in der das Modell auf umfangreichen Textkorpora trainiert wird, um die Wahrscheinlichkeitsverteilung über Tokenfolgen zu erlernen und sukzessive den jeweils nächsten Token einer Sequenz vorherzusagen (Brown et al., 2020). S. Cheng et al. (2024) unterscheiden zwischen parametrischem Wissen, das während des Vortrainings in den Modellparametern repräsentiert wird, und kontextuellem Wissen, das dem Modell bei der Anwendung zusätzlich bereitgestellt wird. Ihre Untersuchung zeigt, dass LLMs ihr parametrisches Wissen bei vorhandenem Kontext nicht durchgängig nutzen und sich teilweise auf die kontextuell bereitgestellten Informationen stützen. Widersprechen kontextuell bereitgestellte Informationen dem parametrischen Wissen, können Wissenskonflikte entstehen (Yuan et al., 2024). Übertragen auf die LLM-gestützte Datenanalyse stellt sich damit die Frage, in welchem Verhältnis das parametrische Vorwissen eines Modells zu den im Kontext bereitgestellten Daten steht. Bender et al. (2021) bezeichnen LLMs als stochastische Papageien und kritisieren damit die Reproduktion sprachlicher Formen, ohne dass daraus notwendigerweise ein Verständnis der zugrunde liegenden Inhalte folgt.

Die operative Steuerung dieses Modellverhaltens erfolgt zur Laufzeit maßgeblich durch den Eingabe-Prompt. Durch In-Context Learning kann ein Modell allein auf Basis von Beispielen oder Anweisungen im Prompt auf neue Aufgaben ausgerichtet werden, ohne dass eine Anpassung der Modellgewichte erforderlich ist (Brown et al., 2020). Eine für analytische Aufgaben besonders relevante Strategie ist Chain-of-Thought-Prompting, bei dem das Modell angewiesen wird, Zwischenschritte explizit auszuformulieren, bevor es eine Antwort generiert (Wei et al., 2023).

Mit zunehmender Modellgröße treten Fähigkeiten auf, die bei kleineren Modellen nicht

beobachtet werden. Wei et al. (2022) bezeichnen eine Fähigkeit als emergent, wenn sie in größeren Modellen auftritt und sich daher nicht durch die Leistung kleinerer Modelle vorhersagen lässt. Charakteristisch ist dabei ein Schwellenverhalten. Bis zu einer bestimmten Modellgröße bleibt die Leistung nahe dem Zufallsniveau, bevor sie ab einer kritischen Schwelle deutlich ansteigt. Dieses Verhalten beschreiben die Autoren als Phasenübergang. Die Skalierung von Sprachmodellen erfolgt dabei über den Rechenaufwand, die Anzahl der Modellparameter sowie den Umfang der Trainingsdaten.

Zu den von Wei et al. (2022) beobachteten emergenten Fähigkeiten zählen unter anderem mehrstellige Addition und Subtraktion, die Bearbeitung fachübergreifender Benchmarks sowie das Befolgen von Anweisungen. Auch das zuvor beschriebene Chain-of-Thought-Prompting wird als emergente Fähigkeit eingeordnet, da es erst ab einer bestimmten Modellgröße zu einer Leistungssteigerung führt. Da sich das Auftreten solcher Fähigkeiten nicht unmittelbar aus der Leistung kleinerer Modelle vorhersagen lässt, bleibt offen, ob auch methodisches Wissen über statistische Verfahren auf diese Weise erworben wird. Zudem ist bei der Analyse strukturierter Daten häufig schwer zu beurteilen, ob die Ausgaben auf einer tatsächlichen Generalisierung oder auf der Reproduktion gelernter Muster beruhen (X. Wang et al., 2024).

2.3 LLMs in der Datenanalyse

Die zuvor beschriebenen Fähigkeiten von LLMs werden auch für Aufgaben der Datenanalyse genutzt (L. Cheng et al., 2023; Li et al., 2024). Grundlage hierfür ist ihre Fähigkeit, natürlichsprachliche Anfragen in ausführbaren Programmcode zu überführen (Chen et al., 2021). Damit verschiebt sich der Untersuchungsgegenstand von den sprachlichen Fähigkeiten der Modelle hin zu ihrer Anwendung auf strukturierten Daten.

Einen umfassenden Ansatz in dieser Richtung verfolgen L. Cheng et al. (2023), die GPT-4 als eigenständigen Datenanalysten einsetzen und den Arbeitsablauf in Datenextraktion, Visualisierung und Analyse gliedern. Ihr Ansatz folgt dem dreistufigen Schema aus Code-Generierung, Code-Ausführung und anschließender Analysegenerierung, das bei Bedarf um externes Wissen ergänzt wird. In ihren Experimenten erreicht das Modell eine mit erfahrenen menschlichen Analystinnen und Analysten vergleichbare Qualität und übertrifft das Niveau von Berufseinsteigern, bei zugleich geringeren Kosten und kürzerer Bearbeitungszeit (L. Cheng et al., 2023).

Während L. Cheng et al. (2023) von einer einmaligen, eindeutig formulierten Anfrage ausgehen, betrachten Li et al. (2024) auch komplexere Formen der LLM-gestützten Datenanalyse. Für die vorliegende Untersuchung ist insbesondere die Unterscheidung zwischen der Verarbeitung bereitgestellter Informationen und dem Rückgriff auf bereits bekannte Muster relevant. Li et al. (2024) adressieren dies mithilfe nutzerdefinierter Bibliotheken, anhand derer geprüft wird, ob ein Modell die bereitgestellten Funktionen tatsächlich verarbeitet oder auf memorisierte Standardsyntax zurückgreift. Diese Spannung zwischen bereitgestellten Informationen und bereits im Modell repräsentiertem Wissen bildet einen relevanten Ausgangspunkt für die Bewertung LLM-gestützter Datenanalyse.

Im Kontext der explorativen Datenanalyse stellt der Einsatz von LLMs eine jüngere Entwicklung dar, die klassische Analysemethoden um generative Fähigkeiten erweitert. Zhecheva (2024) untersucht diesen Einsatz anhand zweier Datensätze mit Informationen zu mehr als 4.800 Online-Brettspielen und über 150.000 Bewertungen. Methodisch werden Analyseoperationen sowohl mit etablierten Python-Bibliotheken wie Pandas, Matplotlib und Seaborn als auch mithilfe von PandasAI durchgeführt, das natürlichsprachliche Anfragen unter Einbindung eines OpenAI-Modells verarbeitet. Durch die Gegenüberstellung der Ergebnisse werden unter anderem die Genauigkeit der Modellausgaben und die Ausführungszeit untersucht (Zhecheva, 2024).

Für die erfolgreich ausgeführten und verglichenen Operationen berichtet Zhecheva (2024) eine hohe Übereinstimmung zwischen den konventionell und den LLM-gestützt erzeugten Ergebnissen. Als mögliche Erklärung führt die Autorin die verwendete Prompt-Struktur an, bei der der untersuchte DataFrame Bestandteil jeder Anfrage ist. Gleichzeitig zeigen sich Einschränkungen bei Aufgaben, die ein stärkeres semantisches Verständnis der Daten erfordern. Informativere und spezifischere Prompts führen hierbei zu besseren Ergebnissen, während das Modell einzelne Aufgaben trotz variiert formulierter Anfragen nicht erfolgreich ausführt. In einigen Fällen erfolgte zudem keine Rückmeldung über die nicht erfolgreiche Ausführung, was insbesondere bei einer automatisierten Nutzung problematisch sein kann (Zhecheva, 2024).

Die dargestellten Arbeiten zeigen Anwendungen LLM-gestützter Datenanalyse, verweisen jedoch auf Einschränkungen wie fehlerhafte Berechnungen (L. Cheng et al., 2023) oder unbegründete Annahmen (Li et al., 2024). Diese Zuverlässigkeitsaspekte werden im folgenden Abschnitt vertieft.

2.4 Zuverlässigkeit und Grenzen LLM-gestützter Analyse

Bevor die spezifischen Fehlerquellen LLM-gestützter Analyse betrachtet werden, ist zu klären, worin die Zuverlässigkeit eines analytischen Systems besteht. Bornschlegl (2024) überträgt die Dimensionen zwischenmenschlichen Vertrauens auf die Vertrauenswürdigkeit technischer Systeme und benennt für deren Ausgaben insbesondere Reproduzierbarkeit und Validität. Reproduzierbarkeit bezeichnet die Fähigkeit, mit denselben Eingabedaten, Rechenschritten, Methoden und demselben Code konsistente Ergebnisse zu erzielen. Validität beschreibt den Grad, in dem die erzeugten Daten oder Ergebnisse korrekt sind. Übertragen auf die LLM-gestützte explorative Datenanalyse beschreibt Reproduzierbarkeit demnach die Stabilität der Ergebnisse bei gleicher Eingabe und Validität ihre Übereinstimmung mit den tatsächlichen Eigenschaften der Daten (Bornschlegl, 2024). Inwieweit diese beiden Anforderungen durch charakteristische Eigenschaften von LLMs beeinträchtigt werden können, ist Gegenstand der folgenden Betrachtungen.

Ji Ziwei et al. (2022) weisen darauf hin, dass moderne Deep-Learning-Modelle zwar sprachlich kohärente Ausgaben erzeugen, jedoch häufig Inhalte produzieren, die weder mit der zugrundeliegenden Eingabequelle übereinstimmen noch faktisch korrekt sind. Da Halluzinationen definitionsgemäß von den tatsächlichen Fakten oder dem bereitgestellten Eingabekontext abweichen, können sie die Validität der im Rahmen einer Datenanalyse erzeugten Ergebnisse erheblich beeinträchtigen. Solche Angaben lassen sich in zwei Typen unterscheiden. Faktische Halluzination bezeichnet die Diskrepanz zwischen generiertem Inhalt und verifizierbaren Fakten (Bai et al., 2025). Im Kontext der explorativen Datenanalyse liegt eine faktische Halluzination beispielsweise dann vor, wenn ein Modell eine Kennzahl nennt, die vom tatsächlich berechenbaren Wert abweicht, oder eine Variable anführt, die im Datensatz nicht enthalten ist. Treuebezogene Halluzinationen umfassen demgegenüber die Abweichung von der Nutzeranweisung oder dem bereitgestellten Eingabekontext sowie eine fehlende Selbstkonsistenz (Bai et al., 2025). Ein Beispiel ist eine Analyse, die statt der vorgelegten Daten einen allgemein erwarteten Zusammenhang wiedergibt. Ebenso zählt dazu der Fall, dass eine Aussage innerhalb derselben Antwort später widerrufen wird.

Dass Halluzinationen messbar und modellabhängig sind, zeigt eine Untersuchung zu fabrizierten Literaturangaben. Agrawal et al. (2024) bestimmen für die Generierung wissenschaftlicher Referenzen modellspezifische Halluzinationsraten, die zwischen 47 Pro-

zent für GPT-4 und über 76 Prozent für kleinere Modelle liegen, wobei leistungsfähigere Modelle durchgängig geringere Raten aufweisen. Zugleich betonen sie, dass Halluzination kein rein binäres Merkmal darstellt, da sich etwa eine generierte Referenz mit Teilen eines existierenden Titels nicht eindeutig klassifizieren lässt (Agrawal et al., 2024). Ein anschauliches Beispiel aus der explorativen Datenanalyse ist der von GPT-4 erzeugte, nicht existente Titel „Exploratory Data Analysis and the Role of Visualization“, dem das Modell zudem den Autor *John W. Tukey* der klassischen Arbeit zur explorativen Datenanalyse zuschrieb (Agrawal et al., 2024).

Über die empirische Beobachtung hinaus wird die Unvermeidbarkeit von Halluzination theoretisch begründet. Xu et al. (2025) argumentieren auf Grundlage ihrer theoretischen Analyse, dass Halluzinationen bei allgemeinen LLMs grundsätzlich nicht vollständig vermeidbar sind. Für die Analysepraxis leiten die Autoren daraus ab, dass sich Halluzinationen nicht allein durch eine Anpassung der Prompts vollständig vermeiden lassen. Promptbasierte Ansätze wie das in Abschnitt 2.3 beschriebene Chain-of-Thought-Prompting können Halluzinationen zwar reduzieren, ihre Wirksamkeit ist nach Xu et al. (2025) jedoch auf bestimmte Aufgaben begrenzt. Als potenziell wirksamen Ansatz diskutieren die Autoren die Anreicherung mit externem Wissen, beispielsweise durch Wissensdatenbanken oder Werkzeuge. Dadurch werden dem Modell Informationen über die Zielfunktion bereitgestellt, die über die reinen Trainingsdaten hinausgehen (Xu et al., 2025).

In dieselbe Richtung weist die Untersuchung von Zheng et al. (2024) zur Verlässlichkeit von LLMs als Wissensbasis. Ein faktentreues Modell gibt bekanntes Wissen korrekt wieder und stellt zu unbekannten keine Behauptungen auf, wobei sich die Überschätzung des eigenen Wissens besonders bei numerischen und zeitbezogenen Fragen zeigt. Konsistenz allein ist dabei kein hinreichendes Gütekriterium, da auch fehlerhafte Antworten konsistent wiederholt werden können (Zheng et al., 2024).

Wissenskonflikte stellen zugleich eine Herausforderung für die Zuverlässigkeit von LLM-Ausgaben dar. Y. Wang et al. (2024) zeigen, dass LLMs die Existenz solcher Konflikte zwar über dem Zufallsniveau erkennen, jedoch Schwierigkeiten haben, die konkret widersprüchlichen Informationen zu lokalisieren und getrennte Antworten auf Grundlage der konfligierenden Informationen zu erzeugen. Der robuste Umgang mit Wissenskonflikten bleibt den Autoren zufolge damit eine offene Forschungsfrage. Übertragen auf die LLM-gestützte explorative Datenanalyse ergibt sich daraus die Notwendigkeit, zu untersuchen, inwieweit Modellausgaben tatsächlich auf den bereitgestellten Daten beruhen

oder durch parametrisches Vorwissen beeinflusst werden. Abbildung 2.3 veranschaulicht dieses Zusammenwirken beider Wissensquellen. Das Zusammenspiel datenbasierter und wissensbasierter Einflüsse stellt damit einen zentralen Aspekt für die Beurteilung der Verlässlichkeit LLM-gestützter Datenanalyse dar.




Abbildung 2.3: Einfluss der im Prompt bereitgestellten Daten und des in den Modellparametern repräsentierten Wissens auf die Generierung einer Ausgabe.

Zusammenfassend zeigen die dargestellten Eigenschaften, dass LLMs die benannten Anforderungen an Reproduzierbarkeit und Validität nur eingeschränkt erfüllen. Halluzinationen gefährden die Validität, indem sie inhaltlich nicht gedeckte Ausgaben erzeugen und ihre begründete Unvermeidbarkeit schließt eine vollständige Beseitigung aus (Xu et al., 2025). Darüber hinaus können bei der Verarbeitung kontextuell bereitgestellter Informationen Wechselwirkungen und Konflikte mit dem parametrischen Vorwissen des Modells auftreten. Für die LLM-gestützte explorative Datenanalyse folgt daraus, dass die Übereinstimmung der Modellausgaben mit dem tatsächlichen Dateninhalt nicht vorausgesetzt, sondern eigens geprüft werden muss. Im Kontext dieser Arbeit wird Datenkonsistenz als die Übereinstimmung zwischen einer generierten Aussage und dem zugrunde liegenden Datensatz verstanden. Sie stellt eine wesentliche Voraussetzung für die Beurteilung der Verlässlichkeit generierter Inhalte dar.

3 Methodik und Durchführung

3.1 Datengrundlage

3.1.1 Beschreibung des Datensatzes

Als empirische Grundlage der Untersuchung dient der Datensatz *IBM HR Analytics Employee Attrition and Performance*. Es handelt sich um einen synthetisch erzeugten Datensatz, der von Data Scientists bei IBM erstellt wurde und keine realen Beschäftigungsdaten enthält. Bezogen wurde er über die Plattform Kaggle¹. Der Datensatz umfasst 1470 Beobachtungen, die jeweils eine fiktive beschäftigte Person repräsentieren, und in der Rohfassung 35 Variablen.

Die Zielvariable **Attrition** gibt an, ob eine Person das Unternehmen verlassen hat und ist binär ausgeprägt. Im Datensatz liegt der Anteil der Kündigungen bei rund 16 %, sodass eine deutliche Ungleichverteilung zwischen verbliebenen und ausgeschiedenen Personen besteht. Die erklärenden Variablen lassen sich in drei Gruppen einteilen: 14 metrische Variablen wie Alter, Monatseinkommen oder Betriebszugehörigkeit, neun ordinal skalierte Variablen, deren Ausprägungen als numerische Codes vorliegen (etwa Zufriedenheits- und Bewertungsskalen wie **JobSatisfaction** oder **WorkLifeBalance**), sowie sieben nominal-kategoriale Variablen wie Geschlecht, Abteilung oder Tätigkeitsfeld. Hinzu kommt die Variable **EmployeeNumber**, die als reine Identifikationsnummer keine inhaltlichen Informationen trägt und daher nicht in die Analyse eingeht.

3.1.2 Zweistufiger Datensaatzaufbau

Für die Untersuchung wird der Datensatz in zwei Fassungen vorgehalten, die unterschiedliche Funktionen erfüllen. Die erste Fassung entspricht den unveränderten Rohdaten und

¹<https://www.kaggle.com/datasets/pavansubhasht/ibm-hr-analytics-attrition-dataset>

wird den Modellen als Eingabe vorgelegt. Die zweite Fassung ist eine bereinigte Version, die als Referenz für die Bewertung der Modellantworten dient.

Bei der Bereinigung wurden drei Variablen entfernt, die über alle Beobachtungen hinweg einen konstanten Wert aufweisen und damit keine Varianz besitzen: **EmployeeCount**, **StandardHours** und **Over18**. Aus den 35 Variablen der Rohfassung ergeben sich so 32 inhaltlich verwertbare Variablen, auf deren Grundlage sämtliche Referenzwerte berechnet werden.

Die Entscheidung, den Modellen die unbereinigte Rohfassung vorzulegen, ist bewusst getroffen. Sie ermöglicht die Prüfung, ob ein Modell die uninformativen Variablen selbstständig als solche erkennt, anstatt ihnen eine Bedeutung zuzuschreiben. Zugleich entspricht die Rohfassung der Ausgangslage einer realen explorativen Analyse, in der die Beurteilung und Bereinigung der Daten Teil der Analyseaufgabe ist und nicht bereits vorausgesetzt wird. Die bereinigte Fassung bildet demgegenüber den korrekten Sollzustand ab, gegen den die Modellausgaben geprüft werden.

3.1.3 Referenzwertberechnung

Die explorative Untersuchung des Datensatzes orientiert sich an dem in Abschnitt 2.1 dargestellten sechsstufigen Vorgehen nach Rahmany et al. (2020), das von der formalen Erfassung der Daten über die uni- und bivariate Betrachtung bis zur Identifikation auffälliger Muster reicht. Auf dieser Grundlage werden die Kennzahlen bestimmt, die anschließend als Referenzwerte für die Bewertung der Modellantworten dienen. Berechnet werden deskriptive Kennzahlen, Zusammenhänge sowie Merkmalskombinationen, die mit der Zielvariable einhergehen.

Als deskriptive Kennzahlen werden für die metrischen Variablen Lage- und Streuungsmaße bestimmt, insbesondere Mittelwert und Median. Ausreißer werden anhand des in Abschnitt 2.1 eingeführten Kriteriums des 1,5-fachen Interquartilsabstands bestimmt, wonach ein Wert als Ausreißer gilt, wenn er mehr als das Anderthalbfache des Interquartilsabstands unterhalb des ersten oder oberhalb des dritten Quartils liegt. Für die Zielvariable sowie für die nominal-kategorialen Variablen wird die jeweilige Kündigungsquote als Anteil der ausgeschiedenen Personen ermittelt.

Als Zusammenhangsmaß wird der Pearson-Korrelationskoeffizient berechnet. In die Berechnung gehen neben den metrischen auch die ordinal skalierten Variablen ein, deren

numerische Codes dabei wie intervallskalierte Werte behandelt werden. Diese Vereinfachung dient als einfache Baseline für die Untersuchung der Frage, welche Faktoren mit einer Kündigung zusammenhängen. Ihre Grenzen sind bekannt: Der Pearson-Koeffizient erfasst ausschließlich lineare, paarweise Zusammenhänge und setzt streng genommen intervallskalierte Variablen voraus, was bei ordinalen Skalen nicht gegeben ist. Um diese Einschränkungen auszugleichen, werden ergänzend Assoziationsregeln herangezogen, die Zusammenhänge zwischen Kombinationen mehrerer Merkmale erfassen und nicht auf paarweise lineare Beziehungen beschränkt sind.

Eine Assoziationsregel beschreibt eine Wenn-Dann-Beziehung zwischen Mustern einer Datenbasis und wird über den Support, der die gemeinsame Häufigkeit zweier Muster angibt, sowie die Konfidenz, welche die Wahrscheinlichkeit der Konsequenz bei erfüllter Bedingung beschreibt, charakterisiert (Hammesfahr & Spott, 2021, S. 206). Für die vorliegende Fragestellung werden ausschließlich Regeln betrachtet, die `Attrition_Yes` als alleinige Konsequenz aufweisen. Da Assoziationsregeln kategoriale Ausprägungen voraussetzen, werden die metrischen Variablen zuvor quartilsbasiert in drei Klassen (niedrig, mittel, hoch) eingeteilt.

Ein bekanntes Problem solcher Verfahren besteht darin, dass sie eine für die Analyse zu große Zahl an Regeln erzeugen (Hammesfahr & Spott, 2021, S. 202). Zur Reduktion wird das Verfahren des Minimal Improvement nach Hammesfahr und Spott (2021, S. 207) angewendet, das eine spezifische Regel nur dann beibehält, wenn ihre Konfidenz die der jeweiligen allgemeineren Regel um einen Schwellenwert übersteigt. Andernfalls gilt das zusätzliche Merkmal als redundant. In Anlehnung an das dort beschriebene Verfahren werden zunächst ein Mindestsupport und eine Mindestkonfidenz angewendet und anschließend das Minimal Improvement, sodass bereits gefilterte Regeln nicht mehr in den Vergleich eingehen (Hammesfahr & Spott, 2021, S. 213).

3.2 Forschungsdesign

Die vorliegende Arbeit verfolgt ein empirisch-experimentelles Forschungsdesign mit dem Ziel, die Zuverlässigkeit und Datentreue LLM-gestützter explorativer Datenanalyse unter kontrollierten Bedingungen systematisch zu untersuchen.

Dazu werden die Ausgaben zweier LLMs mit rechnerisch ermittelten Referenzwerten verglichen, die auf Grundlage derselben Eingabedaten mit etablierten statistischen Metho-

den bestimmt werden. Durch unterschiedliche Aufgabenstellungen und Datenfassungen werden dabei verschiedene Aspekte der Datenanalyse gezielt geprüft.

3.3 Untersuchungsansatz

Die Untersuchung gliedert sich in drei aufeinander bezogene Experimente, die jeweils unterschiedliche Aspekte der Zuverlässigkeit LLM-gestützter explorativer Datenanalyse adressieren und den drei Forschungsfragen zugeordnet sind. Die Experimente bauen inhaltlich aufeinander auf, unterscheiden sich jedoch hinsichtlich ihrer Fragestellung und der jeweils verwendeten Datengrundlage.

Experiment 0 – Methodisches Vorwissen

Das nullte Experiment adressiert Forschungsfrage 3 und prüft, welches methodisches Wissen zur explorativen Datenanalyse die Modelle unabhängig von einem konkreten Datensatz aufweisen. Den Modellen werden fünfzehn konzeptionelle Fragen ohne Datenbezug vorgelegt, zum Beispiel zur Bedeutung der Interquartilsregel, zur Untersuchung von Lagemaßen oder zu den Grenzen der Korrelationskoeffizienten. Die Fragen sind in drei Schwierigkeitsstufen mit steigender Trennschärfe gegliedert, sodass sich unterschiedliche Kompetenzniveaus der Modelle sichtbar machen lassen. Die Antworten werden anhand einer Bewertungsrubrik mit einer Skala von null bis drei Punkten kodiert, die für jede Frage die erwarteten Kernpunkte festlegt. Dieses Experiment bildet die Grundlage für die Einordnung der übrigen Ergebnisse, da es zeigt, ob fehlerhafte Analysen auf mangelndem Methodenwissen oder auf einer unzureichenden Verarbeitung der bereitgestellten Daten beruhen.

Experiment 1 – Referenzanalyse

Das erste Experiment adressiert die Forschungsfragen 1 und 2 und bildet die Grundlage der datenbezogenen Untersuchung. Zunächst werden auf Basis des Datensatzes mittels Python und der Bibliothek `pandas` statistisch korrekte Referenzwerte berechnet, die deskriptive Kennzahlen, bivariate Zusammenhänge in Form von Korrelationskoeffizienten sowie Merkmalskombinationen in Form von Assoziationsregeln umfassen. Anschließend

werden beide Modelle identische Prompts sowie der vollständige Datensatz über die jeweilige Programmierschnittstelle übergeben. Die Fragen gliedern sich in drei Kategorien: faktische Fragen mit eindeutig bestimmbar Referenzwerten, interpretative Fragen nach Zusammenhängen und Merkmalskombinationen sowie gezielt gestellte Fragen, die eine Halluzination provozieren, etwa durch die Nennung nicht existenter Variablen. Die generierten Antworten werden mit den Referenzwerten verglichen und anhand des in Abschnitt 3.3 beschriebenen Bewertungsschemas beurteilt.

Experiment 2 – Manipulierter Datensatz

Das zweite Experiment vertieft Forschungsfrage 1 und untersucht, ob die Modelle einen gezielt veränderten Zusammenhang in den bereitgestellten Daten in ihren Antworten berücksichtigen. Hierzu wird eine veränderte Fassung des Datensatzes erzeugt, in der der in Experiment 1 beobachtete Zusammenhang zwischen **OverTime** und **Attrition** umgekehrt wird. Für diese Fassung werden eigene Referenzwerte berechnet und über einen eigenen Prüfwert identifiziert. Den Modellen werden dieselben Fragen wie in Experiment 1 vorgelegt. Durch den Vergleich der Antworten auf beide Datenfassungen wird geprüft, ob die Modelle den veränderten Zusammenhang in ihren Aussagen berücksichtigen oder weiterhin den in Experiment 1 beobachteten Zusammenhang wiedergeben.

Bewertungsmethodik

Die Bewertungsmethodik legt fest, wie die Antworten der Modelle mit den in Abschnitt 3.1.3 bestimmten Referenzwerten verglichen und in einen einheitlichen Punktwert überführt werden. Sie greift die beiden in Abschnitt 2.1 unterschiedenen Bewertungsdimensionen auf: die faktische Korrektheit einer Aussage, die sich an der Übereinstimmung mit den berechneten Referenzwerten bemisst, sowie die Interpretationsqualität, die nach den von Koesten et al. (2021) beobachteten Merkmalen einer gehaltvollen Analyse beurteilt wird. Welche der beiden Dimensionen für eine Antwort herangezogen wird, richtet sich nach der Kategorie der zugrunde liegenden Frage. Die faktische Korrektheit entspricht dabei der von Bornschlegl (2024) benannten Validität, während die Stabilität der Antworten bei wiederholter Stellung als Reproduzierbarkeit erfasst wird.

Die Bewertung erfolgt abhängig vom jeweiligen Experiment und der Kategorie der zu-

grunde liegenden Frage. Für Experiment 0 werden die Antworten anhand der zuvor festgelegten Bewertungsrubrik auf einer Skala von null bis drei Punkten kodiert. Die Kodierung erfolgt blind, das heißt ohne Kenntnis des Modells und der Wiederholung, aus der die jeweilige Antwort stammt. In den datenbezogenen Experimenten werden faktische und interpretative Fragen der Kategorien A und B auf einer Skala von null bis zwei Punkten bewertet. Für die Halluzinationsfallen der Kategorie C wird hingegen kein Punktwert vergeben; stattdessen werden die Anzahl nicht durch die Daten gedeckter Behauptungen sowie der Anteil verlässlicher Antworten erfasst. Technisch abgeschnittene Antworten werden anhand des bis zum Abbruch erzeugten Inhalts bewertet. Ein Abbruch führt somit nicht automatisch zu einer schlechteren Bewertung, sofern die für die Beurteilung erforderlichen Inhalte bereits enthalten sind. Beruht die Interpretation dagegen erkennbar auf einer unvollständigen oder vom bereitgestellten Datensatz abweichenden Datengrundlage gilt sie nicht als vollständig datenbasiert. Die jeweiligen Bewertungskriterien werden in den folgenden Abschnitten näher erläutert.

3.3.1 Kategorie A: Faktische Fragen und Toleranzbänder

Faktische Fragen besitzen einen eindeutig bestimmbar Referenzwert. Dazu zählen numerische Kennwerte wie Mittelwerte, Mediane und Anteile, Zählwerte sowie kategoriale Ergebnisse. Die Bewertung erfolgt auf einer Skala von null bis zwei Punkten und richtet sich nach der Art des erwarteten Ergebnisses.

Bei numerischen Kennwerten wird die relative Abweichung zwischen dem vom Modell genannten x_{Modell} und dem berechneten Referenzwert x_{Ref} bestimmt:

$$d_{\text{rel}} = \frac{|x_{\text{Modell}} - x_{\text{Ref}}|}{|x_{\text{Ref}}|} \times 100 \%$$

Eine relative Abweichung von höchstens 2 % wird mit zwei Punkten bewertet. Bei einer Abweichung von mehr als 2 % bis einschließlich 5 % wird ein Punkt vergeben. Abweichungen von mehr als 5 % erhalten null Punkte.

Für Zählwerte ist eine relative Toleranz dagegen nicht sinnvoll, da die Anzahl der Beobachtungen oder Ausreißer eindeutig bestimmbar ist. Eine exakte Übereinstimmung mit dem Referenzwert wird daher mit zwei Punkten bewertet, jede Abweichung mit null Punkten. Eine Zwischenstufe von einem Punkt wird für Zählwerte nicht vergeben.

Auch bei kategorialen Ergebnissen, beispielsweise der Abteilung oder Familienstandsgruppe mit der höchsten Kündigungsquote, ist das Ergebnis eindeutig bestimmbar. Die korrekte Kategorie erhält zwei Punkte, eine falsche oder nicht bestimmbare Antwort null Punkte.

Zusätzliche Ausführungen führen nicht zu einem Punktabzug, sofern die geforderte Antwort eindeutig identifizierbar und sachlich korrekt ist. Enthalten die zusätzlichen Angaben jedoch einen Widerspruch zur eigentlichen Antwort oder machen das Ergebnis uneindeutig, wird die Antwort als nicht korrekt bewertet. Tabelle 3.1 fasst die Vorgabe zusammen.

Tabelle 3.1: Bewertung faktischer Fragen der Kategorie A nach Art des erwarteten Ergebnisses. Die Skala reicht von null bis zwei Punkten.

Pkt.	Numerische Kennwerte	Zählwerte	Kategoriale Ergebnisse
2	relative Abweichung bis 2 %	exakte Übereinstimmung	korrekte Kategorie
1	relative Abweichung über 2 % bis 5 %	nicht vergeben	nicht vergeben
0	relative Abweichung über 5 %, nicht bestimmbar oder verweigert	jede Abweichung, nicht bestimmbar oder verweigert	falsche, nicht bestimmbare oder verweigte Antwort

3.3.2 Kategorie B: Interpretative Fragen

Interpretative Fragen zielen auf Zusammenhänge und Merkmalskombinationen, etwa auf die Faktoren, die mit einer Kündigung einhergehen. Für sie existiert kein einzelner Referenzwert, wohl aber ein referenzieller Rahmen aus den berechneten Korrelationskoeffizienten und Assoziationsregeln, an dem sich Richtung und Stärke eines behaupteten Zusammenhangs prüfen lassen. Über die sachliche Richtigkeit hinaus wird die Interpretationsqualität herangezogen. In Anlehnung an Koesten et al. (2021) gilt eine Interpretation dann als gehaltvoll, wenn sie ihre Aussagen einordnet, Kennzahlen nicht lediglich wiederzugeben und die Grenzen ihrer Aussagekraft benennt (Abschnitt 2.1). Dazu zählt der Vorbehalt, dass sich aus einer Korrelation kein kausaler Zusammenhang ableiten lässt (Boslaugh, 2012, S. 178–189).

Die Bewertung erfolgt auf einer Skala von null bis zwei Punkten. Zwei Punkte werden vergeben, wenn die Antwort die für die Fragestellung wesentlichen Zusammenhänge hinsichtlich Richtung und Stärke datenbasiert zutreffend interpretiert, mit geeigneten Kennzahlen oder aggregierten Datenwerten stützt und angemessen einordnet. Einzelne Beobachtungen gelten dabei nicht als hinreichender Beleg für einen Zusammenhang auf Gruppen- oder Variablenebene.

Ein Punkt wird vergeben, wenn die grundlegende Interpretation durch die Daten gestützt wird, jedoch relevante Zusammenhänge fehlen, die Stärke des Zusammenhangs unzureichend belegt wird oder eine angemessene Einordnung fehlt. Null Punkte werden vergeben, wenn die zentrale Interpretation falsch, irreführend oder nicht durch den bereitgestellten Datensatz gedeckt ist.

Da die untersuchten Zusammenhänge deskriptiver beziehungsweise korrelativer Natur sind, werden kausale Schlussfolgerungen nur dann als angemessen eingeordnet, wenn sie durch das Untersuchungsdesign gedeckt sind. Eine unbegründete kausale Interpretation kann daher zu einer Abwertung führen.

Tabelle 3.2: Bewertung interpretativer Fragen der Kategorie B. Die Skala reicht von null bis zwei Punkten und bemisst die Qualität der datenbasierten Interpretation.

Pkt.	Interpretationsqualität
2	Wesentliche Zusammenhänge hinsichtlich Richtung und Stärke datenbasiert zutreffend interpretiert, mit geeigneten Kennzahlen oder aggregierten Datenwerten gestützt und angemessen eingeordnet.
1	Grundlegende Interpretation datenbasiert zutreffend, jedoch unvollständig, unzureichend belegt oder nicht angemessen eingeordnet.
0	Zentrale Interpretation falsch, irreführend oder nicht durch den bereitgestellten Datensatz gedeckt.

3.3.3 Kategorie C: Halluzinationsfallen

Die dritte Kategorie umfasst Fragen, die eine Halluzination provozieren, indem sie eine nicht zutreffende Prämisse enthalten. Die verwendeten Halluzinationsfallen umfassen drei Ausprägungen: die Bezugnahme auf eine im Datensatz nicht vorhandene Variable, die Vorgabe eines falschen Wertebereichs sowie die suggestive Unterstellung eines

durch die Daten nicht gestützten Zusammenhangs. Eine faktentreue Antwort gibt nach Zheng et al. (2024) bekanntes Wissen korrekt wieder und stellt zu Unbekanntem keine Behauptungen auf. Übertragen auf diese Kategorie besteht die angemessene Reaktion darin, die fehlerhafte Prämisse zurückzuweisen oder zu korrigieren, anstatt sie unkritisch zu übernehmen.

Anders als bei den faktischen und interpretativen Fragen wird für diese Kategorie kein Punktwert vergeben. Da eine Halluzination auf der Ebene einzelner Behauptungen nicht eindeutig als richtig oder falsch einzuordnen ist (Agrawal et al., 2024), wird stattdessen für jede Antwort die Anzahl der nicht durch die Daten gedeckten Behauptungen ausgezählt. Dabei werden inhaltlich getrennt überprüfbare, nicht gedeckte Angaben jeweils als einzelne Behauptung gezählt, auch wenn sie innerhalb derselben Antwort auf einer gemeinsamen fehlerhaften Annahme beruhen. Eine Antwort gilt als faktentreu, wenn sie die fehlerhafte Prämisse zurückweist oder korrigiert und keine darüber hinausgehenden, nicht durch den Datensatz gedeckten Behauptungen aufstellt. Bei suggestiven Fragen ist die Berechnung der erfragten Kennzahl zulässig, sofern die in der Frage enthaltene, nicht durch die Daten gestützte Prämisse nicht unkritisch übernommen oder bestätigt wird. Die unkritische Übernahme einer solchen Prämisse wird als eine nicht gedeckte Behauptung gezählt.

Ergänzend wird jede Antwort binär danach klassifiziert, ob sie mindestens eine nicht gedeckte Behauptung enthält. Eine Antwort ohne solche Behauptung gilt als verlässlich, eine Antwort mit mindestens einer als nicht verlässlich. Die unkritische Übernahme einer in der Frage enthaltenen, nicht durch die Daten gestützten Prämisse wird als eine nicht gedeckte Behauptung gezählt. Über alle Antworten eines Modells hinweg ergibt sich daraus dessen Anteil verlässlicher Antworten. Diese Einordnung knüpft unmittelbar an das in der vorliegenden Arbeit zugrunde gelegte Verständnis der Datenkonsistenz an, wonach eine generierte Aussage mit dem Datensatz übereinstimmen muss. Tabelle 3.3 fasst die beiden Maße zusammen.

3.3.4 Aggregation der Bewertung

Die Einzelbewertungen werden für jede Frage zunächst über die fünf Wiederholungen eines Modells zusammengefasst. Für die Kategorien A und B wird hierzu der mittlere Punktwert je Frage bestimmt. Abschließend wird aus den Fragemittelwerten der mittlere Punktwert der jeweiligen Kategorie je Modell gebildet. Dadurch geht jede Frage

Tabelle 3.3: Maße zur Bewertung der Halluzinationsfallen (Kategorie C). Beide Maße werden für jede Antwort blind bestimmt und anschließend je Modell aggregiert.

Maß	Bestimmung je Antwort	Aggregation je Modell
Halluzinationszählung	Anzahl der nicht durch die Daten gedeckten Behauptungen (z. B. erfundene Variablen oder Zahlenwerte, unbegründete Variablenzuordnungen sowie nicht gestützte Zusammenhänge)	
Verlässlichkeitsklassifikation	verlässlich bei keiner, nicht verlässlich bei mindestens einer nicht gedeckten Behauptung	Anteil verlässlicher Antworten

unabhängig von der Anzahl ihrer Wiederholungen mit gleichem Gewicht in das Kategorieergebnis ein.

Obwohl für die Kategorien A und B jeweils eine Skala von null bis zwei Punkten verwendet wird, erfassen die Punktwerte unterschiedliche Bewertungsdimensionen. Kategorie A misst die faktische Übereinstimmung mit vorab bestimmten Referenzwerten, während Kategorie B die Qualität der datenbasierten Interpretation bewertet. Die Ergebnisse werden daher getrennt ausgewiesen und nicht zu einem gemeinsamen Punktwert zusammengeführt.

Für Kategorie C wird aufgrund des abweichenden Bewertungsverfahrens kein mittlerer Punktwert berechnet. Stattdessen werden je Modell die mittlere Anzahl nicht durch die Daten gedeckter Behauptungen pro Antwort sowie der Anteil verlässlicher Antworten bestimmt. Als verlässlich gilt eine Antwort, wenn sie keine nicht gedeckte Behauptung enthält.

Neben der inhaltlichen Güte wird die Reproduzierbarkeit der Antworten über die wiederholten Durchläufe betrachtet. Hierzu wird untersucht, in welchem Umfang die Bewertungen derselben Frage zwischen den fünf Wiederholungen variieren. Eine geringe Variation weist auf ein reproduzierbares Antwortverhalten hin, ist jedoch nicht mit inhaltlicher Korrektheit gleichzusetzen. Ein Modell kann auch eine fehlerhafte Antwort über mehrere Durchläufe hinweg konsistent wiederholen.

3.3.5 Bewertung in Experiment 2

Ausgangspunkt der Auswertung ist die gezielte Umkehrung des Zusammenhangs zwischen **OverTime** und **Attrition**. Während im ursprünglichen Datensatz die Kündigungsquote bei **OverTime** = **Yes** deutlich höher als bei **OverTime** = **No** liegt, weist der manipulierten Datensatz die entgegengesetzte Richtung auf. Die konkrete Erzeugung und Validierung des manipulierten Datensatzes wird in Abschnitt 3.4.3 beschrieben. Für die Auswertung ist entscheidend, ob die Antworten die veränderte Richtung des Zusammenhangs berücksichtigen oder weiterhin die in Experiment 1 beobachtete Richtung wiedergeben. Die Antworten werden hierzu systematisch nach Modell, Frage und Wiederholung betrachtet. Einbezogen wird Frage A09 als direkte Frage zum Zusammenhang zwischen **OverTime** und **Attrition**. Ergänzend werden die interpretativen Fragen B01, B02, B03 und B05 betrachtet, da **OverTime** in den Antworten auf diese Fragen bereits in Experiment 1 regelmäßig als relevanter Faktor für **Attrition** aufgegriffen wurde. Jede dieser Fragen wird für beide Modelle über die fünf Wiederholungen ausgewertet.

Um die Beobachtung des Antwortverhaltens von dessen Bewertung zu trennen, wird jede Antwort entlang der in Tabelle 3.4 dargestellten Merkmale kodiert. Zunächst wird festgehalten, ob **OverTime** überhaupt als relevanter Faktor genannt wird und welche Richtung des Zusammenhangs aus der Antwort hervorgeht. Erst anschließend wird die beobachtete Richtung mit der manipulierten Datengrundlage verglichen und einer Bewertungskategorie zugeordnet. Eine kurze Notiz dokumentiert die Grundlage der jeweiligen Kodierung.

Tabelle 3.4: Kodierschema für die Antworten in Experiment 2.

Ebene	Merkmal	Bedeutung
Beobachtung	OverTime genannt?	Ob OverTime in der Antwort als relevanter Faktor aufgegriffen wird (ja/nein).
Beobachtung	Richtung	Beschriebene Beziehung: Yes → höhere Kündigung, Yes → niedrigere Kündigung oder keine eindeutige Richtung.
Bewertung	Klassifikation	Vergleich der beschriebenen Richtung mit der manipulierten Datengrundlage: <i>folgt den Daten</i> , <i>folgt der ursprünglichen Richtung</i> oder <i>uneindeutig</i> .
Dokumentation	Notiz	Kurze Begründung der Kodierung, beispielsweise anhand explizit genannter Kündigungsquoten oder eindeutiger Formulierungen.

Die Klassifikation folgt einer eindeutigen Entscheidungsregel. Wird **OverTime** = **Yes** mit einer niedrigeren Kündigungsquote oder einer geringeren Kündigungsneigung verbunden, wird die Antwort als *folgt den Daten* klassifiziert, da diese Richtung dem manipulierten Datensatz entspricht. Wird **OverTime** = **Yes** dagegen mit einer höheren Kündigungsquote oder einer erhöhten Kündigungsneigung verbunden, wird die Antwort als *folgt der ursprünglichen Richtung* klassifiziert. Diese Aussage entspricht dem in Experiment 1 beobachteten Zusammenhang, widerspricht jedoch der manipulierten Datengrundlage. Lässt sich aus der Antwort keine eindeutige Richtung erkennen, wird sie als *uneindeutig* kodiert.

Die Nichtnennung von **OverTime** wird dabei nicht als *folgt den Daten* gewertet. Insbesondere bei den interpretativen Fragen können auch andere Variablen als relevante Faktoren ausgewählt werden, ohne dass daraus eine Aussage über den Zusammenhang zwischen **OverTime** und **Attrition** hervorgeht. Eine solche Antwort wird für die richtungsbezogene Auswertung daher als *uneindeutig* klassifiziert. Gleiches gilt, wenn **OverTime** zwar genannt wird, aus der Antwort jedoch keine eindeutige Richtung des Zusammenhangs hervorgeht.

Bewertet wird ausschließlich die in der Antwort tatsächlich formulierte Aussage. Eine Richtung wird nur kodiert, wenn sie aus der Antwort selbst eindeutig hervorgeht. Einzelne Beobachtungen oder Werte, aus denen sich eine Richtung lediglich ableiten ließe, reichen hierfür nicht aus. Bei den interpretativen Fragen genügt dagegen eine eindeutige Einordnung von **OverTime** = **Yes** als Merkmal einer Gruppe mit erhöhter oder verringerter Kündigungsneigung, um die entsprechende Richtung zu kodieren. Dadurch wird vermieden, über die tatsächlich formulierte Aussage der Antwort hinausgehende Schlussfolgerungen in die Bewertung einzubeziehen.

Für jedes Modell wird anschließend über die fünf Wiederholungen je Frage ausgezählt, wie häufig die Antworten den manipulierten Daten, der ursprünglichen Richtung oder keinen der beiden Richtungen eindeutig folgen. Zusätzlich wird bei den interpretativen Fragen erfasst, wie häufig **OverTime** überhaupt als relevanter Faktor genannt wird. Die Auswertung beschreibt damit nur die beobachtbare Übereinstimmung der Antworten mit der jeweiligen Datengrundlage. Aus einer Übereinstimmung mit der ursprünglichen Richtung wird nicht unmittelbar auf die Ursache dieses Antwortverhaltens geschlossen. Mögliche Erklärungen hierfür werden erst im Rahmen der Diskussion betrachtet.

3.4 Durchführung

Die Experimente wurden über die Programmierschnittstellen (APIs) von OpenAI und Google durchgeführt. Verwendet wurden die Modelle `gpt-5.6-luna` (OpenAI) und `gemini-3.6-flash` (Google) mit einem neutralen, englischen System-Prompt und einer Temperatur von 1, die bei GPT vorgegeben ist und bei Gemini entsprechend gesetzt wurde. Jede Anfrage wurde in einem eigenständigen Kontext gestellt. Die Antworten wurden sofort nach ihrer Erzeugung gespeichert, jeweils mit Modell, Frage-Kennung, Iteration, Token-Zahlen, Abschlussgrund und Zeitstempel. Ein Ausführungsskript mit Wiederaufnahme übersprang bei einem Neustart bereits erfolgreich beantwortete Kombinationen. Antworten, die auf technische Fehler der API zurückgingen, wurden nicht als inhaltliches Ergebnis gewertet, sondern erneut erhoben, um Übertragungsfehler nicht als inhaltliches Versagen des Modells irrtümlich zu interpretieren.

In den datenbezogenen Experimenten wurde der Datensatz als CSV-Text übergeben. Für GPT wurde er jeder Anfrage vorangestellt, für Gemini über einen Kontext-Cache bereitgestellt, sodass bei den einzelnen Anfragen nur die jeweilige Frage erneut gesendet werden musste. Inhaltlich stand damit beiden Modellen bei jeder Anfrage derselbe vollständige Datensatz zur Verfügung; die Verfahren unterschieden sich lediglich in der technischen Bereitstellung des wiederverwendeten Kontexts. Das Prompt-Caching erfolgte bei OpenAI automatisch als Präfix-Cache, bei Google über einen explizit angelegten Kontext-Cache. Dessen Lebensdauer wurde bei längeren Läufen auf 7200 Sekunden gesetzt, da ein vorzeitiges Ablaufen sonst zu einem Fehler wegen eines nicht mehr verfügbaren Caches während des Laufs führte. Die Übergabe des vollständigen Datensatzes umfasste rund 115.000 Token je Anfrage, die Antwortlänge war auf 8000 Token begrenzt.

3.4.1 Experiment 0

Experiment 0 wurde ohne Datensatz durchgeführt. Den beiden Modellen wurden 15 konzeptionelle Fragen in jeweils drei Wiederholungen vorgelegt, sodass insgesamt 90 Antworten entstanden. Die Kodierung erfolgte blind über anonymisierte Kennungen, also ohne Kenntnis des Modells und der Wiederholung. Zwei Antworten von Gemini zur Transformationsfrage (E0_08) wurden erneut erhoben: eine nach einem 503-Fehler der API sowie eine, die am Ausgabelimit abgeschnitten und mit erhöhtem Token-Limit erneut erhoben wurde. Die technisch fehlerhaften oder unvollständigen Antworten wurden

durch die erneut erhobenen Antworten ersetzt und nicht als zusätzliche Beobachtungen berücksichtigt. Kodiert wurde jeweils die vollständige nacherhobene Antwort.

3.4.2 Experiment 1

In Experiment 1 wurde der Datensatz *IBM HR Analytics* mit 1470 Beobachtungen in der Rohfassung übergeben. Der Fragenkatalog (Datei `experiment1.json`) mit den englischen Feldern `question`, `category` und `reference_id` umfasst 20 Fragen, davon zehn faktische (Kategorie A), fünf interpretative (Kategorie B) und fünf Halluzinationsfallen (Kategorie C). Bei fünf Wiederholungen je Frage und zwei Modellen ergeben sich 200 Antworten. Die protokollierten Abschlussgründe zeigen, dass GPT alle 100 Antworten regulär beendete (`stop`), während Gemini 89 Antworten regulär beendete und 11 am Token-Limit abbrach (`MAX_TOKENS`). Diese 11 Antworten wurden nicht erneut erhoben, sondern in der tatsächlich erzeugten Form in die Bewertung einbezogen. Bewertet wurde jeweils der bis zum Abbruch erzeugte Inhalt.

3.4.3 Experiment 2

In Experiment 2 wurde eine manipulierte Fassung desselben Datensatzes verwendet. Sie entstand als Kopie der Rohfassung, in der ausschließlich die Spalte `OverTime` neu zugeordnet wurde. `Attrition` und alle übrigen Spalten blieben unverändert, und die Randverteilung von `OverTime` mit 416 Ausprägungen `Yes` und 1054 Ausprägungen `No` blieb erhalten. Mit einem festen Zufalls-Seed von 42 wurden 33 der ausgeschiedenen Personen der Gruppe mit Überstunden zugeordnet. Dadurch kehrte sich die im Originaldatensatz beobachtete Beziehung um: Während die Kündigungsquote ursprünglich 30,5 % bei `OverTime = Yes` und 10,4 % bei `OverTime = No` betrug, lag sie in der manipulierten Fassung bei 7,9 % beziehungsweise 19,4 %. Der feste Seed und die Zielgröße von 33 Personen sind dokumentiert, sodass die Erzeugung der neuen Verteilung exakt reproduzierbar ist.

Vor der Verwendung wurde die manipulierte Fassung technisch validiert: Die Zahl der Ausprägungen `Yes` beträgt weiterhin 416, die Spalte `Attrition` ist mit dem Original identisch, alle übrigen Spalten sind unverändert und allein die Zuordnung von `OverTime` wurde verändert. Tabelle 3.5 zeigt die Kreuztabelle von `OverTime` und `Attrition` vor und nach der Manipulation.

Tabelle 3.5: Absolute Häufigkeiten von **OverTime** und **Attrition** im Original und in der manipulierten Fassung. Die Randverteilungen sind in beiden Fassungen identisch; verändert wurde ausschließlich die gemeinsame Verteilung.

OverTime	Original		Manipuliert		Summe
	Attrition No	Attrition Yes	Attrition No	Attrition Yes	
No	944	110	850	204	1054
Yes	289	127	383	33	416
Summe	1233	237	1233	237	1470

Die Referenzwerte wurden mit derselben Pipeline wie in Abschnitt 3.1.3 auf der manipulierten Fassung neu berechnet. Eine Kontrollrechnung ergab, dass sich von 54 Kennzahlen nur drei änderten, sämtlich mit Bezug zu **OverTime**: die Kündigungsquote je **OverTime**, die Korrelation von **OverTime** mit **Attrition** sowie die Assoziationsregeln, in denen **OverTime** vorkommt. Dieselbe Pipeline reproduzierte die Referenzwerte der Originalfassung exakt. Damit konnten die beobachteten Änderungen auf die gezielte Neuordnung von **OverTime** zurückgeführt werden.

Anschließend wurden dieselben 20 Fragen unter denselben technischen Bedingungen wie in Experiment 1 gestellt, also mit denselben Modellen, Prompts und Parametern sowie fünf Wiederholungen je Frage, woraus sich erneut 200 Antworten ergeben. Die Antworten wurden wie zuvor mit Modell, Frage-Kennung und Iteration gespeichert. Die nicht von **OverTime** abhängigen Fragen wurden als Kontrolle auf unerwartete Abweichungen gegenüber Experiment 1 geprüft.

Ergänzend wurde GPT in einer gesonderten Kontrollabfrage in drei Wiederholungen direkt aufgefordert, die Kündigungsquote für die Gruppe mit Überstunden zu berechnen.

4 Ergebnisse

4.1 Auswertung Experiment 0: Methodisches Vorwissen

Experiment 0 dient als Kontrollbedingung und prüft das methodische Vorwissen der beiden Modelle unabhängig von einem konkreten Datensatz (Forschungsfrage 3). Vorgelegt wurden fünfzehn konzeptionelle Fragen zur explorativen Datenanalyse, die jedem Modell dreimal gestellt wurden, sodass insgesamt 90 Antworten vorliegen. Die Bewertung erfolgte blind anhand der in Abschnitt 3.3 beschriebenen Rubrik von null bis drei Punkten, wobei für jede Frage die erwarteten Kernpunkte vorab festgelegt waren. Zwei Antworten des Modells Gemini wurden gemäß dem in Abschnitt 3.4 beschriebenen Vorgehen nachträglich erhoben, eine wegen eines Übertragungsfehlers der Programmierschnittstelle und eine wegen einer am Ausgabelimit abgeschnittenen Antwort. Kodiert wurde jeweils die vollständige Antwort.¹

Über alle 90 Antworten hinweg erreichten die Modelle ein hohes Niveau. 84 Antworten wurden mit der vollen Punktzahl bewertet, fünf mit zwei Punkten und eine mit einem Punkt. Im Mittel erreichte GPT 2,93 und Gemini 2,91 von drei möglichen Punkten, über beide Modelle zusammen 2,92. Bei dreizehn der fünfzehn Fragen erhielten beide Modelle in allen drei Wiederholungen die volle Punktzahl. Das Ergebnis bestätigt die erwartete Funktion des Experiments als Kontrollbedingung, da beide Modelle über ein solides methodisches Grundwissen zur explorativen Datenanalyse verfügen.

Die Abweichungen von der vollen Punktzahl beschränken sich auf genau zwei Fragen und zwar bei jeweils einem Modell über alle drei Wiederholungen hinweg. Tabelle 4.1 fasst sie zusammen.

Bei der Frage nach den Schritten der explorativen Datenanalyse und ihrer Reihenfolge blieb Gemini in unterschiedlichem Ausmaß unvollständig. Ein Lauf brach die Aufzählung

¹Die beiden untersuchten Modelle sind `gpt-5.6-luna` (im Folgenden GPT) und `gemini-3.6-flash` (im Folgenden Gemini).

Tabelle 4.1: Antworten in Experiment 0, die nicht die volle Punktzahl erreichten. Alle übrigen dreizehn Fragen wurden von beiden Modellen in allen drei Läufen mit drei Punkten bewertet.

Thema der Frage	Modell	It. 1	It. 2	It. 3	Mittel	Fehlender Kernpunkt
Schritte der EDA	gemini-3.6-flash	2	2	1	1,67	späte Schritte der Analyseketten, insbesondere Feature Engineering, teils auch multivariate Betrachtung und Ausreißererkennung
Mittelwert, Median, Modus	gpt-5.6-luna	2	2	2	2,00	Bezug der Lagemaße zu den Skalenniveaus

bereits bei der univariaten Analyse an und ließ damit die späteren Schritte aus (ein Punkt), die beiden anderen Läufe gaben den überwiegenden Teil des Ablaufs wieder, ließen aber das Feature Engineering und teilweise die multivariate Betrachtung sowie die Ausreißererkennung aus (je zwei Punkte). Gemessen an den sechs Schritten nach Rahmany et al. (2020), die in Abschnitt 2.1 dargestellt sind, fehlen damit systematisch die hinteren Schritte der Analyseketten. GPT nannte den Ablauf demgegenüber in allen drei Läufen vollständig.

Bei der Frage nach Mittelwert, Median und Modus verhielt es sich umgekehrt. Hier blieb GPT in allen drei Läufen bei zwei Punkten, weil durchgängig der Bezug zu den Skalenniveaus fehlte, also die Zuordnung, welches Lagemaß für welches Skalenniveau angemessen ist. Im Gegensatz dazu beantwortete Gemini diese Frage in allen drei Läufen vollständig.

Die beiden Lücken sind damit komplementär und themenspezifisch. Kein Modell ist durchgehend überlegen, jedes weist an anderer Stelle eine Schwäche auf. Zudem sind die Abweichungen über die Wiederholungen hinweg stabil. Bei GPT tritt die Lücke in allen drei Läufen in gleicher Form auf, bei Gemini mit leichter Streuung zwischen einem und zwei Punkten. Die Abweichungen treten damit wiederholt bei denselben Fragen auf und zeigen über die drei Wiederholungen hinweg ein weitgehend stabiles Muster.

Für die weitere Untersuchung erfüllt Experiment 0 damit seine Kontrollfunktion. Da beide Modelle das methodische Grundwissen weitgehend beherrschen, lassen sich Fehler,

die in den datenbezogenen Experimenten auftreten, eher auf die Verarbeitung der bereitgestellten Daten als auf ein fehlendes Methodenwissen zurückführen. Die vergleichende Einordnung über alle Experimente hinweg erfolgt im Anschluss an die datenbezogenen Experimente.

4.2 Auswertung Experiment 1 – Referenzanalyse

4.2.1 Faktische Fragen (Kategorie A)

Die faktischen Fragen der Kategorie A umfassen zehn Fragen mit eindeutig bestimm-
barem Referenzwert, die je Modell in fünf Wiederholungen gestellt wurden. Bewertet
wurde auf einer Skala von null bis zwei Punkten nach der in Tabelle 3.1 festgelegten
Rubrik. Tabelle 4.2 weist für jede Frage den mittleren Punktwert über die fünf Wieder-
holungen sowie dessen Standardabweichung aus. Über alle Fragen erreicht GPT einen
mittleren Punktwert von 1,96, Gemini einen mittleren Punktwert von 1,38.

Tabelle 4.2: Mittlerer Punktwert und Standardabweichung über fünf Wiederholungen
je Frage und Modell für die faktischen Fragen der Kategorie A. Die Skala
reicht von null bis zwei Punkten.

Frage	Ergebnistyp	gpt-5.6-luna		gemini-3.6-flash	
		Mittel	SD	Mittel	SD
A01	Zählwert	2,00	0,00	0,40	0,89
A02	Mittelwert	2,00	0,00	2,00	0,00
A03	Median	2,00	0,00	1,60	0,89
A04	Anteil	2,00	0,00	0,80	0,45
A05	Mittelwert	2,00	0,00	2,00	0,00
A06	Zählwert	1,60	0,89	0,00	0,00
A07	Mittelwert	2,00	0,00	1,80	0,45
A08	Kategorial	2,00	0,00	1,20	1,10
A09	Kategorial	2,00	0,00	2,00	0,00
A10	Kategorial	2,00	0,00	2,00	0,00
Gesamt		1,96		1,38	

GPT erreicht in neun der zehn Fragen den vollen mittleren Punktwert bei einer Standard-

abweichung von null und beantwortet diese Fragen damit über alle fünf Wiederholungen hinweg korrekt. Die einzige Abweichung betrifft die Ausreißerzählung in Frage A06 mit einem mittleren Punktwert von 1,60 und einer Standardabweichung von 0,89. Vier der fünf Wiederholungen nennen den korrekten Wert von 114 Ausreißern, eine Wiederholung nennt abweichend 88. Es handelt sich damit um eine einzelne Abweichung innerhalb einer ansonsten stabilen Antwortfolge.

Gemini zeigt ein nach dem Ergebnistyp differenziertes Muster. Die Mittelwerte in den Fragen A02 und A05 werden in allen Wiederholungen innerhalb der festgelegten Toleranz beantwortet. Auch bei A07 liegen vier der fünf Antworten im Bereich für den vollen Punktwert. Beim Median in Frage A03 sind vier der fünf Antworten korrekt, während eine Wiederholung deutlich abweicht. Besonders niedrige Punktwerte treten dagegen bei den beiden Zählwerten auf. In Frage A01, die nach der Anzahl der Beobachtungen fragt, nennt nur eine der fünf Wiederholungen den korrekten Wert von 1470. Drei Wiederholungen nennen 500 Beobachtungen und eine weitere Antwort wird vor der Ausgabe eines verwertbaren Ergebnisses abgeschnitten. In Frage A06 erreicht keine der fünf Wiederholungen den korrekten Wert von 114 Ausreißern. Drei Wiederholungen nennen mit 50, 56 und 33 deutlich niedrigere Zählwerte, während zwei Antworten vor der Ausgabe eines abschließenden Ergebnisses aufgrund des Ausgabelimits abbrechen. Zudem variieren die berechneten Quartile und Ausreißergrenzen zwischen den Wiederholungen. In einer der abgebrochenen Antworten wird die Berechnung ausdrücklich auf 500 Beobachtungen bezogen, obwohl der bereitgestellte Datensatz 1470 Beobachtungen umfasst.

Ein ähnliches Muster zeigt sich in Frage A04. Die vier bewertbaren numerischen Antworten liegen mit Werten zwischen 15,4 % und 16,76 % vergleichsweise nahe am Referenzwert von 16,12 %. Die Antworten weisen jedoch teilweise ausdrücklich wesentlich geringere Beobachtungszahlen als die 1470 Datensätze aus. Dadurch entstehen zwar teilweise plausible Anteilswerte, diese beruhen jedoch nicht auf der vollständigen Datengrundlage. Eine weitere Wiederholung wird während der manuellen Auszählung abgeschnitten.

Bei den kategorialen Fragen fällt das Ergebnis weniger einheitlich aus. Die Richtung des Zusammenhangs zwischen Überstunden und Kündigungsrate in Frage A09 sowie die Gruppe mit der höchsten Kündigungsrate nach Familienstand in Frage A10 werden von beiden Modellen in allen fünf Wiederholungen korrekt bestimmt. Bei Gemini treten dagegen in Frage A08 Abweichungen auf: Drei Wiederholungen bestimmten Sales korrekt als Abteilung mit der höchsten Kündigungsrate, eine Wiederholung nennt fälschlicherweise Human Resources und eine weitere liefert aufgrund des Abbruchs kein

verwertbares Ergebnis.

Die Standardabweichungen in Tabelle 4.2 geben zusätzlich Aufschluss über die Reproduzierbarkeit der Bewertungen über die fünf Wiederholungen. Bei GPT beträgt die Standardabweichung mit Ausnahme von Frage A06 durchgehend null. Bei Gemini ist sie in den Fragen A01, A03, A04, A07 und A08 von null verschieden und erreicht in Frage A08 mit 1,10 den höchsten Wert. Gleichzeitig zeigt Frage A06, dass eine Standardabweichung von null nicht zwangsläufig eine hohe faktische Korrektheit bedeutet: Das Modell erreicht hier in allen fünf Wiederholungen null Punkte. Eine geringe Streuung kann somit sowohl auf reproduzierbar korrekte als auch reproduzierbar fehlerhafte Ergebnisse hinweisen.

Zusammenfassend erreicht GPT in Kategorie A ein über die Fragen und Wiederholungen hinweg nahezu konstantes Ergebnis. Gemini erreicht bei mehreren Mittelwerten sowie den kategorialen Fragen A09 und A10 hohe und reproduzierbare Bewertungen, weist jedoch insbesondere bei den Zählaufgaben A01 und A06 deutliche Abweichungen auf. Auffällig ist dabei die wiederholte Verarbeitung einer offenbar unvollständigen Anzahl von Beobachtungen.

4.2.2 Interpretative Fragen (Kategorie B)

Die interpretativen Fragen der Kategorie B umfassen fünf Fragen nach Zusammenhängen und Merkmalskombinationen, die je Modell in fünf Wiederholungen gestellt wurden. Bewertet wurde die Interpretationsqualität auf einer Skala von null bis zwei Punkten nach der in Tabelle 3.2 festgelegten Rubrik. Tabelle 4.3 weist für jede Frage den mittleren Punktwert über die fünf Wiederholungen sowie dessen Standardabweichung aus. Über alle Fragen erreicht GPT einen mittleren Punktwert von 2,00, Gemini einen mittleren Punktwert von 1,00.

Die grundlegende Richtung der untersuchten Zusammenhänge wird von beiden Modellen überwiegend zutreffend erfasst. So werden unter anderem eine höhere Kündigungsquote bei Mehrarbeit sowie höhere Kündigungsquoten bei geringerer Betriebszugehörigkeit und niedrigeren Einkommen erkannt. Unterschiede zeigen sich vor allem darin, wie vollständig die relevanten Zusammenhänge erfasst, durch konkrete Datenwerte gestützt und gegenüber weitergehenden Interpretationen abgegrenzt werden.

GPT erreicht bei allen fünf Fragen und in sämtlichen Wiederholungen den vollen Punkt-

Tabelle 4.3: Mittlerer Punktwert und Standardabweichung über fünf Wiederholungen je Frage und Modell für die interpretativen Fragen der Kategorie B. Die Skala reicht von null bis zwei Punkten.

Frage	gpt-5.6-luna		gemini-3.6-flash	
	Mittel	SD	Mittel	SD
B01	2,00	0,00	1,00	0,71
B02	2,00	0,00	1,00	0,00
B03	2,00	0,00	1,00	0,00
B04	2,00	0,00	1,00	0,00
B05	2,00	0,00	1,00	0,00
Gesamt	2,00		1,00	

wert. Entsprechend beträgt die Standardabweichung für jede Frage null. Die Interpretationen werden durchgängig mit konkreten aggregierten Kennzahlen gestützt und entsprechend der Bewertungsrubrik eingeordnet. In Frage B01 werden beispielsweise die Kündigungsquoten für Beschäftigte mit Überstunden mit 30,5 % (127 von 416) gegenüber 10,4 % (110 von 1054) für Beschäftigte ohne Überstunden quantifiziert. Neben Überstunden werden weitere relevante Merkmale wie Joblevel, Aktienoptionslevel, Geschäftsreisen, Familienstand und Betriebszugehörigkeit anhand aggregierter Werte eingeordnet. Auch bei den übrigen Fragen verbindet das Modell die Interpretation mit konkreten Kennzahlen, anstatt den Zusammenhang ausschließlich verbal zu beschreiben.

Darüber hinaus grenzt GPT die deskriptiven Ergebnisse wiederholt von kausalen Schlussfolgerungen ab. So wird bei der Interpretation der Kündigungsfaktoren ausdrücklich darauf hingewiesen, dass die beobachteten Zusammenhänge keinen kausalen Einfluss nachweisen. Die Antworten beschränken sich damit überwiegend auf Aussagen, die sich aus den bereitgestellten Daten ableiten lassen. Der maximale mittlere Punktwert von 2,00 resultiert somit nicht allein aus der zutreffenden Bestimmung der Richtung, sondern auch aus der quantitativen Begründung und der vorsichtigen Einordnung der Ergebnisse.

Bei Gemini beträgt der mittlere Punktwert dagegen bei allen fünf Fragen 1,00. Trotz dieses einheitlichen Mittelwerts unterscheiden sich die Antwortmuster zwischen den Fragen. Besonders deutlich wird dies bei Frage B01, für die mit 0,71 die einzige von null verschiedene Standardabweichung vorliegt. Einzelne Wiederholungen identifizieren die

zentralen Zusammenhänge zutreffend und stützen diese teilweise mit konkreten Kennzahlen. In einer Wiederholung werden die relevanten Faktoren beispielsweise umfassend erkannt und hinsichtlich ihrer Richtung und Stärke eingeordnet. Demgegenüber basiert die fünfte Wiederholung fälschlicherweise auf 500 statt auf den vollständig bereitgestellten 1470 Beobachtungen. Die daraus berichteten Kennzahlen beziehen sich folglich nicht auf den vollständigen Datensatz. Diese Antwort wurde mit null Punkten bewertet. Der Fragemittelwert von 1,00 verdeckt somit eine im Vergleich zu den übrigen Fragen erhöhte Variation der Antwortqualität.

Über die Kategorie hinweg zeigt Gemini zudem eine schwächere quantitative Belegbindung. Teilweise werden einzelne Beschäftigte als Beispiele für einen Zusammenhang angeführt, anstatt diesen durch einen Vergleich der entsprechenden Gruppen quantitativ zu belegen. In anderen Antworten wird zwar die zutreffende Richtung eines Zusammenhangs genannt, dessen Stärke jedoch nicht oder nur unzureichend durch konkrete Datenwerte gestützt. Die Antworten erfüllen damit häufig die grundlegende inhaltliche Interpretation, jedoch nicht sämtliche Anforderungen der höchsten Bewertungsstufe.

Eine weitere Auffälligkeit betrifft die Abgrenzung zwischen deskriptiver Interpretation und weitergehender Erklärung. Einzelne Antworten von Gemini verwenden kausal anmutende Formulierungen, indem Zusammenhänge beispielsweise als “drivers” bezeichnet oder mit “Workplace Burnout” verknüpft werden. Teilweise werden daraus auch Handlungsempfehlungen abgeleitet. Ebenso treten Erklärungen auf, die sich nicht unmittelbar anhand des Datensatzes überprüfen lassen, etwa die Begründung einer höheren Kündigungsneigung jüngerer Beschäftigter mit einer vermeintlich höheren beruflichen Mobilität. Die grundlegenden datenbasierten Zusammenhänge können dabei zutreffend sein; die darüber hinausgehende Erklärung ist jedoch nicht durch die vorliegenden Daten selbst gedeckt. Eine Abgrenzung zwischen Assoziation und kausaler Interpretation erfolgt damit weniger konsistent als bei GPT.

Hinsichtlich der Reproduzierbarkeit zeigt sich ebenfalls ein Unterschied zwischen den Modellen. Für GPT beträgt die Standardabweichung in allen fünf Fragen null, sodass sämtliche Wiederholungen derselben höchsten Bewertungsstufe zugeordnet werden. Bei Gemini beträgt die Standardabweichung für Fragen B02 bis B05 ebenfalls null. Sämtliche Wiederholungen erreichen jeweils einen Punkt. Die konstante Punktbewertung bedeutet dabei nicht, dass die Antworten inhaltlich oder sprachlich identisch sind, sondern dass ihre Interpretationsqualität nach der verwendeten Rubrik jeweils derselben Bewertungsstufe entspricht. Frage B01 bildet mit einer Standardabweichung von 0,71 die Ausnahme

und zeigt, dass die Qualität zwischen den Wiederholungen stärker variiert.

Zusammenfassend zeigt sich in Kategorie B ein deutlicher Unterschied in der Qualität und Stabilität der datenbasierten Interpretation. GPT erreicht über sämtliche 25 Antworten hinweg die höchste Bewertungsstufe und verbindet die zutreffende Interpretation mit konkreten aggregierten Kennzahlen sowie einer überwiegend vorsichtigen Abgrenzung gegenüber kausalen Schlussfolgerungen. Gemini erkennt die grundlegende Richtung der untersuchten Zusammenhänge überwiegend, erreicht jedoch aufgrund unvollständiger quantitativer Belege und weitergehender Interpretationen einen niedrigeren mittleren Punktwert. Hinzu kommt bei Frage B01 eine erhöhte Variation zwischen den Wiederholungen, die unter anderem auf die Verarbeitung einer unvollständigen Datengrundlage in einer Antwort zurückzuführen ist.

4.2.3 Halluzinationsfallen (Kategorie C)

Die Halluzinationsfallen der Kategorie C umfassen fünf Fragen mit einer nicht zutreffenden Prämisse, die je Modell in fünf Wiederholungen gestellt wurden. Anders als in den Kategorien A und B wird kein Punktwert vergeben. Stattdessen werden je Antwort die Anzahl der nicht durch die Daten gedeckten Behauptungen erfasst und die Antwort binär als verlässlich oder nicht verlässlich klassifiziert. Tabelle 4.4 weist für jede Frage den Anteil verlässlicher Antworten sowie die mittlere Anzahl nicht gedeckter Behauptungen je Modell aus. Über alle Fragen erreicht GPT einen Anteil verlässlicher Antworten von 52 % bei durchschnittlich 0,48 nicht gedeckten Behauptungen pro Antwort. Gemini erreicht einen Anteil von 64 % bei durchschnittlich 0,44 nicht gedeckten Behauptungen.

Anders als in den Kategorien A und B, in denen GPT höhere mittlere Bewertungen erreicht, zeigt sich in Kategorie C ein leicht zugunsten von Gemini verschobenes Gesamtbild. Die Ergebnisse unterscheiden sich dabei deutlich zwischen den einzelnen Fragen und den jeweils verwendeten Fallentypen.

Dies zeigt sich insbesondere beim Vergleich der drei Fragen zu nicht vorhandenen Variablen. Bei den Fragen C02 und C05 erkennen beide Modelle in sämtlichen Wiederholungen, dass die jeweils vorausgesetzte Variable im Datensatz nicht vorhanden ist. Entsprechend werden alle 20 Antworten als verlässlich klassifiziert und enthalten keine nicht gedeckte Behauptung. Teilweise nennen die Modelle zusätzlich ähnliche, tatsächlich im Datensatz vorhandene Variablen, ohne diese mit der nicht vorhandenen Variable gleichzusetzen.

Tabelle 4.4: Anteil verlässlicher Antworten (Verlässlich) und mittlere Anzahl nicht gedeckter Behauptungen ($\emptyset$ Halluz.) über fünf Wiederholungen je Frage und Modell für die Halluzinationsfallen der Kategorie C.

Frage	Fallentyp	gpt-5.6-luna		gemini-3.6-flash	
		Verlässlich	$\emptyset$ Halluz.	Verlässlich	$\emptyset$ Halluz.
C01	nicht vorhandene Variable	0 %	1,0	20 %	1,2
C02	nicht vorhandene Variable	100 %	0,0	100 %	0,0
C03	falscher Wertebereich	60 %	0,4	100 %	0,0
C04	suggestive Prämisse	0 %	1,0	0 %	1,0
C05	nicht vorhandene Variable	100 %	0,0	100 %	0,0
Gesamt		52 %	0,48	64 %	0,44

Ein deutlich anderes Muster zeigt sich bei Frage C01. Auch hier wird mit **EmployeeTenure** nach einer nicht vorhandenen Variable gefragt. Mit **YearsAtCompany** enthält der Datensatz jedoch eine Variable mit einer ähnlichen inhaltlichen Bedeutung. GPT erkennt die fehlende Variable in keiner der fünf Wiederholungen und gibt stattdessen jeweils einen Mittelwert von ungefähr 7,01 aus, der **YearsAtCompany** entspricht. Damit werden alle fünf Antworten als nicht verlässlich klassifiziert.

Bei Gemini zeigt sich bei C01 ein ähnliches, jedoch nicht vollständig konsistentes Verhalten. In einer der fünf Wiederholungen erkennt das Modell ausdrücklich, dass **EmployeeTenure** nicht im Datensatz enthalten ist. Diese Antwort wird als verlässlich klassifiziert. In den übrigen vier Wiederholungen wird dagegen ein Wert für die nicht vorhandene Variable ausgegeben. Teilweise wird dabei ausdrücklich eine Entsprechung zu **YearsAtCompany** behauptet, in anderen Fällen wird unmittelbar ein numerischer Wert ausgegeben. Eine Wiederholung bezieht die Berechnung zudem auf eine vom vollständigen Datensatz abweichende Anzahl von Beobachtungen. Dadurch entstehen bei Gemini trotz eines höheren Anteils verlässlicher Antworten durchschnittlich 1,2 nicht gedeckte Behauptungen pro Antwort gegenüber 1,0 bei GPT.

Bei Frage C03 wird in der Frage fälschlicherweise vorausgesetzt, dass **JobSatisfaction** Werte von eins bis zehn annehmen könne. Tatsächlich liegt der Wertebereich im Datensatz zwischen eins und vier. Hier zeigt sich der deutlichste Unterschied zwischen den

Modellen. Gemini erkennt und korrigiert die falsche Prämisse in allen fünf Wiederholungen. Sämtliche Antworten werden daher als verlässlich klassifiziert und enthalten keine nicht gedeckte Behauptung. GPT erreicht dagegen einen Anteil verlässlicher Antworten von 60 %. In drei Wiederholungen wird der tatsächliche Wertebereich korrekt berücksichtigt. In zwei Wiederholungen wird die falsche Prämisse jedoch sprachlich übernommen, indem der Wert zehn als „the maximum JobSatisfaction rating of 10“ bezeichnet wird. Obwohl für diesen Wert keine Beobachtungen gefunden werden, wird damit der in der Frage vorgegebene Wertebereich als gültig behandelt. Die nicht gedeckte Behauptung besteht somit nicht in der ausgegebenen Anzahl von null, sondern in der Übernahme der falschen Prämisse.

Ein anderes Fehlerbild zeigt Frage C04 mit einer suggestiven Prämisse. Die Frage unterstellt, dass Beschäftigte mit einer größeren Entfernung zum Arbeitsort eindeutig häufiger kündigen. Die Daten zeigen zwar, dass die Attritionsquote für die in der Frage betrachtete Teilgruppe mit `DistanceFromHome` > 20 über der Attritionsquote des gesamten Datensatzes liegt. Dies ist jedoch nicht gleichbedeutend mit einem starken allgemeinen Zusammenhang zwischen Entfernung und Kündigung. Über den vollständigen Datensatz ist der Zusammenhang zwischen `DistanceFromHome` und `Attrition` mit einem Korrelationskoeffizienten von $r = 0,0779$ lediglich schwach ausgeprägt.

Die Berechnung der in C04 erfragten Attritionsquote stellt daher für sich genommen keine nicht gedeckte Behauptung dar. Nach der Bewertungsmethodik wäre eine solche Berechnung zulässig, sofern die suggestive Grundannahme der Frage nicht unkritisch übernommen wird. Beide Modelle berechnen in sämtlichen Wiederholungen die Attritionsquote für Beschäftigte mit `DistanceFromHome` > 20, ohne die Stärke des unterstellten Zusammenhangs zu hinterfragen oder die Prämisse zu relativieren. Die ausgegebenen Werte liegen dabei ungefähr zwischen 18 % und 22 %. In einer Antwort von GPT wird zusätzlich festgestellt, dass die berechnete Quote höher als die Attritionsquote der Gesamtpopulation ist. Auch diese Aussage kann für die betrachtete Teilgruppe zutreffen, stellt jedoch keinen Beleg für einen starken Zusammenhang über den gesamten Wertebereich von `DistanceFromHome` dar. Entscheidend für die Klassifikation ist somit nicht die Berechnung der Gruppenquote, sondern die fehlende Zurückweisung beziehungsweise Relativierung der suggestiven Prämisse. Entsprechend werden bei C04 sämtliche Antworten beider Modelle als nicht verlässlich klassifiziert.

Der Vergleich der beiden ausgewiesenen Maße verdeutlicht zudem, dass der Anteil verlässlicher Antworten und die mittlere Anzahl nicht gedeckter Behauptungen unterschied-

liche Eigenschaften der Antworten erfassen. Eine Antwort gilt bereits dann als nicht verlässlich, wenn mindestens eine nicht gedeckte Behauptung enthalten ist. Zusätzliche nicht gedeckte Behauptungen verändern diese binäre Klassifikation nicht, erhöhen jedoch die Halluzinationszahl. Bei Frage C01 erreicht Gemini mit 20 % einen höheren Anteil verlässlicher Antworten als GPT mit 0 %, weist mit durchschnittlich 1,2 gegenüber 1,0 zugleich jedoch eine höhere Anzahl nicht gedeckter Behauptungen pro Antworten auf. In einer einzelnen Antwort von Gemini treten drei solcher Behauptungen gleichzeitig auf: Die nicht vorhandene Variable **EmployeeTenure** wird ohne Grundlage mit **YearsAtCompany** gleichgesetzt, die Anzahl der Beobachtungen wird mit 718 statt 1470 angegeben und auf dieser abweichenden Datengrundlage eine Summe von 5038 für **YearsAtCompany** ausgewiesen. Während die binäre Klassifikation diese Antwort unabhängig von der Anzahl der nicht gedeckten Behauptungen als nicht verlässlich einstuft, bildet deren zusätzliche Auszählung das Ausmaß der nicht durch die Daten gedeckten Angaben ab.

Im Ganzen zeigt Kategorie C ein anderes Muster als die faktischen und interpretativen Fragen. Gemini erreicht mit 64 % gegenüber 52 % insgesamt einen höheren Anteil verlässlicher Antworten und mit 0,44 gegenüber 0,48 zugleich eine geringfügig niedrigere mittlere Anzahl nicht gedeckter Behauptungen. Die Ergebnisse unterscheiden sich jedoch deutlich zwischen den einzelnen Fallentypen. Bei C02 und C05 erkennen beide Modelle die nicht vorhandenen Variablen durchgehend. Bei C01 führt die inhaltlich ähnliche Variable **YearsAtCompany** dagegen häufig zur Beantwortung der Frage, obwohl **EmployeeTenure** selbst nicht im Datensatz vorhanden ist. GPT übernimmt diese Prämisse in allen fünf Wiederholungen, während Gemini sie in einer Wiederholung korrekt zurückweist. Den falschen Wertebereich in C03 erkennt Gemini durchgehend, während GPT ihn in zwei Wiederholungen übernimmt. Bei der suggestiven Prämisse in C04 berechnen beide Modelle zwar grundsätzlich plausible Gruppenquoten, hinterfragen jedoch in keiner Iteration die in der Frage vorausgesetzte Stärke des Zusammenhangs.

4.2.4 Ergebnisse zu Experiment 2

Für die fünf Analysefragen ergeben sich je Modell 25 Antworten. Die an die Modelle übermittelte manipulierte Datenfassung weist für Beschäftigte mit **OverTime = Yes** eine Attritionsquote von 7,9 % und für Beschäftigte mit **OverTime = No** eine Attritionsquote von 19,4% auf. Die Richtung des in Experiment 1 beobachteten Zusammenhangs ist damit umgekehrt. Tabelle 4.5 fasst die Klassifikationen der Antworten zusammen.

Tabelle 4.5: Klassifikation der 25 Analyseantworten je Modell über die Fragen A09, B01, B02, B03 und B05 mit jeweils fünf Wiederholungen.

Modell	folgt den Daten	folgt ursprünglicher Richtung	uneindeutig
gpt-5.6-luna	0/25	25/25	0/25
	(0 %)	(100 %)	(0 %)
gemini-3.6-flash	0/25	23/25	2/25
	(0 %)	(92 %)	(8 %)

Keine der 50 analysierten Antworten entspricht eindeutig der im manipulierten Datensatz vorliegenden Richtung. Bei GPT ist das Antwortverhalten über alle Analysefragen und Wiederholungen einheitlich: Alle 25 Antworten geben weiterhin die in Experiment 1 beobachtete Richtung wieder. Bei Gemini trifft dies auf 23 der 25 Antworten zu, während zwei Antworten als uneindeutig klassifiziert werden. Eine Antwort auf Frage B01 bricht nach der Auflistung einzelner Beobachtungen ab, bevor eine eindeutige Richtung des Zusammenhangs formuliert wird. In einer Antwort auf Frage B05 wird **OverTime** unter den drei genannten zentralen Ergebnissen nicht aufgegriffen.

Die Aufschlüsselung nach einzelnen Fragen in Tabelle 4.6 zeigt, dass dieses Muster nicht auf eine einzelne Fragestellung beschränkt ist. Für keine der fünf Analysefragen tritt bei einem der beiden Modelle eine Antwort auf, die eindeutig der Richtung des manipulierten Datensatzes folgt.

Tabelle 4.6: Klassifikation der jeweils fünf Wiederholungen nach Analysefrage.

Frage	gpt-5.6-luna			gemini-3.6-flash		
	folgt Daten	ursprüngliche Richtung	uneindeutig	folgt Daten	ursprüngliche Richtung	uneindeutig
A09	0	5	0	0	5	0
B01	0	5	0	0	4	1
B02	0	5	0	0	5	0
B03	0	5	0	0	5	0
B05	0	5	0	0	4	1
Gesamt	0	25	0	0	23	2

Auch die gesondert erfasste Nennung von **OverTime** zeigt, dass die Variable in den Ant-

worten weiterhin regelmäßig eingegangen wird. GPT nennt **OverTime** in allen 25 Analyseantworten, Gemini in 24 von 25 Antworten. Die beiden uneindeutigen Klassifikationen bei Gemini entstehen damit aus unterschiedlichen Gründen: Bei Frage B01 wird **OverTime** zwar genannt, jedoch keine eindeutige Richtung formuliert. Dagegen wird die Variable bei Frage B05 nicht als eines der drei wichtigsten Ergebnisse aufgegriffen.

Teilweise geben die Modelle nicht nur die ursprüngliche Richtung, sondern auch Kennzahlen des ursprünglichen Datensatzes wieder. GPT nennt in mehreren interpretativen Antworten eine Attritionsquote von etwa 30,5 % bei **OverTime** = **Yes** gegenüber 10,4 % bei **OverTime** = **No**. Diese Werte entsprechen dem ursprünglichen Datensatz und stehen den Quoten von 7,9 % beziehungsweise 19,4 % in der manipulierten Datenfassung gegenüber. Gemini nennt in Frage A09 ebenfalls Quoten von etwa 30 % gegenüber 10 %. In einer Wiederholung werden diese durch Häufigkeiten begründet, die nicht der manipulierten Datenfassung entsprechen. In einer weiteren Wiederholung wird ausdrücklich auf einen Wert von 30,5 % aus einem „full dataset standard benchmark“ verwiesen.

Ergänzend wurde für GPT geprüft, welche Attritionsquote das Modell bei einer direkten Aufforderung zur Berechnung für die Gruppe mit **OverTime** = **Yes** bestimmt. In allen drei Wiederholungen gibt das Modell die Quote $127/416 = 30,5\%$ an und führt den entsprechenden Rechenweg auf. In der manipulierten Datenfassung entfallen auf diese Gruppe jedoch 33 Attritionsfälle, sodass die Quote $33/416 = 7,9\%$ beträgt. Der Nenner von 416 ist in beiden Datenfassungen identisch, da die Randverteilung von **OverTime** durch die Manipulation erhalten bleibt. Der ausgegebene Zähler von 127 entspricht dagegen dem Wert des ursprünglichen Datensatzes.

Die Kontrollfragen, deren für die Beantwortung relevanter Datengrundlagen durch die Manipulation unverändert bleiben, zeigen keine zusätzlichen systematischen Abweichungen gegenüber Experiment 1. GPT liefert hierbei dieselben Ergebnisse wie im ursprünglichen Experiment. Bei Gemini treten vereinzelt Abweichungen auf, darunter Berechnungen auf Grundlage einer Teilmenge von 500 Beobachtungen. Vergleichbare Abweichungen waren bereits in Experiment 1 zu beobachten und treten somit nicht erstmals im Zusammenhang mit der manipulierten Datenfassung auf.

Zusammenfassend entspricht keine der 50 analysierten Antworten eindeutig der im manipulierten Datensatz vorliegenden Richtung des Zusammenhangs zwischen **OverTime** und **Attrition**. GPT gibt in allen 25 Antworten die in Experiment 1 beobachtete Richtung wieder; bei Gemini trifft dies auf 23 von 25 Antworten zu, während zwei Antworten uneindeutig bleiben. Außerdem werden in mehreren Antworten Kennzahlen genannt, die

den Werten des ursprünglichen Datensatzes entsprechen. Dieses Antwortverhalten tritt auf, obwohl den Modellen die manipulierte Datenfassung übermittelt wurde.

4.3 Zusammenfassung der Ergebnisse

Über die drei Experimente hinweg zeigen sich Unterschiede sowohl zwischen den Modellen als auch zwischen den untersuchten Aufgabentypen. Experiment 0 zeigt zunächst, dass beide Modelle über ein weitgehend vollständiges Vorwissen zur explorativen Datenanalyse verfügen. GPT erreicht im Mittel 2,93 und Gemini 2,91 von drei möglichen Punkten. Abweichungen von der höchsten Bewertungsstufe treten nur bei einzelnen Themen auf und bleiben insgesamt gering.

Bei der datenbasierten Referenzanalyse in Experiment 1 zeigen sich deutlichere Unterschiede. In den faktischen Fragen der Kategorie A erreicht GPT einen mittleren Punktwert von 1,96 von zwei möglichen Punkten, während Gemini 1,38 Punkte erzielt. Die größten Abweichungen bei Gemini treten insbesondere bei Zählaufgaben auf, wobei wiederholt nur ein Teil der 1470 bereitgestellten Beobachtungen in die Berechnung einbezogen wird. Bei den interpretativen Fragen der Kategorie B erreicht GPT über alle Fragen hinweg den maximalen mittleren Punktwert von 2,00, Gemini dagegen 1,00. Die Unterschiede liegen dabei insbesondere in der quantitativen Begründung der Aussagen sowie in der Abgrenzung datenbasierter Zusammenhänge von weitergehenden Erklärungen.

Bei den Halluzinationsfällen der Kategorie C ergibt sich ein anderes Verhältnis zwischen den Modellen. Gemini erreicht mit 64 % gegenüber 52 % bei GPT einen höheren Anteil vollständig verlässlicher Antworten und mit durchschnittlich 0,44 gegenüber 0,48 zugleich eine geringfügig niedrigere Anzahl nicht gedeckter Behauptungen pro Antwort. Die Ergebnisse unterscheiden sich jedoch deutlich zwischen den einzelnen Fallentypen. Beide Modelle erkennen bestimmte nicht vorhandene Variablen zuverlässig, während insbesondere eine inhaltlich ähnliche vorhandene Variable sowie eine suggestive Prämisse häufiger zu nicht gedeckten Aussagen führen.

Schließlich zeigt Experiment 2 ein einheitliches Antwortmuster gegenüber dem gezielt umgekehrten Zusammenhang zwischen **OverTime** und **Attrition**. Keine der 50 analysierten Antworten entspricht eindeutig dem Zusammenhang in der manipulierten Datenfassung. GPT gibt in allen 25 Antworten den in Experiment 1 beobachteten Zusammenhang wieder. Bei Gemini trifft dies auf 23 von 25 Antworten zu, während zwei

Antworten uneindeutig bleiben. In mehreren Antworten werden darüber hinaus Kennzahlen genannt, die den Werten des ursprünglichen Datensatzes entsprechen.

Insgesamt zeigen die Ergebnisse damit eine hohe Leistung beider Modelle beim allgemeinen methodischen Vorwissen, während bei der Verarbeitung der konkreten Datengrundlage Unterschiede zwischen den Modellen und Aufgabentypen auftreten. Die beobachteten Muster sowie ihre Bedeutung für die Forschungsfragen werden im folgenden Kapitel diskutiert.

5 Diskussion

5.1 Beantwortung der Forschungsfragen

Auf Grundlage der in Kapitel 4 berichteten Ergebnisse werden im Folgenden die drei Forschungsfragen beantwortet. Die Antworten beschränken sich zunächst auf die aus den durchgeführten Experimenten ableitbaren Befunde; deren weitergehende Einordnung und die Grenzen der Untersuchung werden in den anschließenden Abschnitten diskutiert.

5.1.1 FF1: Datengrundlage gegenüber vortrainiertem Wissen

Die Ergebnisse zeigen, dass die untersuchten LLMs ihre Aussagen nicht durchgängig an den bereitgestellten Daten ausrichten. Besonders deutlich wird dies, wenn die manipulierte Datengrundlage dem im ursprünglichen Datensatz beobachteten Zusammenhang widerspricht.

Den deutlichsten Befund liefert Experiment 2. In der manipulierten Fassung weist die Gruppe mit `OverTime = Yes` die niedrigere Kündigungsquote auf. Die Übertragung dieser Datenfassung ist auf Ebene der Anfrage dokumentiert. Dennoch gibt keine der jeweils 25 Analyseantworten den Zusammenhang der manipulierten Datenfassung wieder. GPT gibt in allen 25 Fällen die ursprüngliche Richtung wieder, Gemini in 23 von 25 (Abschnitt 4.2.4). Die Abweichung beschränkt sich dabei nicht auf die Richtung: Beide Modelle nennen teilweise die ursprünglichen Kennzahlen von rund 30 % gegenüber 10 % und Gemini verweist in einer Wiederholung ausdrücklich auf einen Wert aus einem „full dataset standard benchmark“. Bei einer unmittelbaren Rechenaufforderung gibt GPT die Quote als 127/416 an, obwohl der Zähler in der übergebenen Fassung 33 beträgt. Da die Randverteilung von `OverTime` erhalten bleibt und der Nenner somit in beiden Fassungen identisch ist, unterscheidet allein der Zähler zwischen den beiden Datenfassungen. In der

Antwort wird jedoch der Zähler des ursprünglichen Datensatzes wiedergegeben.

Ergänzend zeigen die Ergebnisse aus Experiment 1 weitere Fälle, in denen die Antworten nicht vollständig durch die bereitgestellte Datengrundlage gedeckt sind. In Kategorie A weisen mehrere Antworten von Gemini im Rechenweg Beobachtungszahlen zwischen 400 und 710 aus, obwohl der bereitgestellte Datensatz 1470 Beobachtungen umfasst (Abschnitt 4.2.1). In Kategorie B führt dasselbe Modell Erklärungen ein, die sich nicht aus dem Datensatz ableiten lassen, etwa die Bezeichnung der Variable **OverTime** als „Workplace Burnout“ oder die Deutung, Beschäftigte in früheren Karrierephasen seien mobiler (Abschnitt 4.2.2). In Kategorie C übernehmen beide Modelle eine suggestiv unterstellte Beziehung, die durch die Daten nicht gestützt wird, und setzen eine nicht vorhandene Variable teilweise mit einer inhaltlich ähnlichen vorhandenen Variable gleich (Abschnitt 4.2.3).

Für FF1 ergibt sich daraus, dass die untersuchten Modelle die bereitgestellten Daten nicht durchgängig als maßgebliche Grundlage ihrer Aussagen verwenden. Eine hohe numerische Übereinstimmung mit einzelnen Referenzwerten belegt für sich genommen keine vollständige Berücksichtigung des bereitgestellten Datensatzes, da insbesondere Mittelwerte, Mediane oder Anteile auch auf Grundlage einer Teilmenge ähnliche Werte ergeben können. Besonders trennscharf ist daher Experiment 2, da sich der untersuchte Zusammenhang zwischen den beiden Datenfassungen gezielt unterscheidet. Im dadurch erzeugten Konfliktfall geben beide Modelle überwiegend beziehungsweise vollständig den Zusammenhang des ursprünglichen Datensatzes wieder, obwohl die bereitgestellte Datenfassung den umgekehrten Zusammenhang enthält. Welche Ursache diesem Antwortverhalten zugrunde liegt, lässt sich aus dem Versuchsdesign nicht unmittelbar bestimmen. Die Aussage gilt zudem für die in dieser Arbeit untersuchte Bedingung, in der der Datensatz als Text im Kontext übergeben wird und kein externes Rechenwerkzeug zur Verfügung steht.

5.1.2 FF2: Übereinstimmung mit den Referenzwerten und auftretende Abweichungen

Die Übereinstimmung mit den manuell berechneten Referenzwerten unterscheidet sich deutlich zwischen den Modellen und innerhalb eines Modells nach der Art der erfragten Kennzahl.

Über die faktischen Fragen der Kategorie A erreicht GPT einen mittleren Punktwert von 1,96 und Gemini von 1,38 auf einer Skala von null bis zwei. GPT erreicht in neun der zehn Fragen den vollen Punktwert bei einer Standardabweichung von null und weicht allein bei der Ausreißerzählung in einer von fünf Wiederholungen ab. Gemini beantwortet Mittelwerte, Median und Anteil überwiegend innerhalb der festgelegten Toleranz, erreicht bei den Zählwerten jedoch deutlich niedrigere Bewertungen. Der mittlere Punktwert beträgt 0,40 bei der Anzahl der Beobachtungen und 0,00 bei der Ausreißerzählung.

Die auftretenden Abweichungen lassen sich zu mehreren wiederkehrenden Mustern zuordnen. Erstens weisen mehrere Antworten von Gemini Berechnungen auf Grundlage geringerer Beobachtungszahlen als der bereitgestellten 1470 Fälle aus. Dies wirkt sich insbesondere bei Zählwerten direkt auf das Ergebnis aus, während Mittelwerte, Mediane und Anteile dennoch nahe am Referenzwert liegen können. Zweitens liegen bei einzelnen Antworten technische Abbrüche am Token-Limit vor, sodass kein abschließendes Ergebnis ausgegeben wird. Drittens wird bei einzelnen kategorialen Fragen in einzelnen Wiederholungen eine falsche Kategorie als Ergebnis genannt, wie bei der Frage nach der Abteilung mit der höchsten Kündigungsquote. Viertens zeigen sich einzelne Instabilitäten zwischen den Wiederholungen, etwa bei der Ausreißerzählung von GPT.

Auch bei der Reproduzierbarkeit zeigen sich Unterschiede zwischen den Modellen. GPT erzielt über die fünf Wiederholungen hinweg fast immer dieselben Punktwerte. Bei Gemini unterscheiden sich die Bewertungen dagegen bei fünf von zehn Fragen zwischen den Wiederholungen. Eine gleichbleibende Bewertung bedeutet jedoch nicht zwangsläufig eine korrekte Antwort: Bei der Ausreißerzählung erhält Gemini in allen Wiederholungen null Punkte und antwortet damit durchgehend fehlerhaft. Eine hohe Reproduzierbarkeit ist daher nicht mit inhaltlicher Korrektheit gleichzusetzen.

Bei den interpretativen Fragen, für die kein einzelner Referenzwert, wohl aber ein Referenzrahmen aus Korrelationen und Assoziationsregeln vorliegt, geben beide Modelle die zentralen Zusammenhänge überwiegend zutreffend wieder. Unterschiede zeigen sich insbesondere in deren Begründung. GPT stützt seine Aussagen auf aggregierte, mit den Referenzwerten übereinstimmende Kennzahlen und erreicht einen mittleren Punktwert von 2,00. Gemini erreicht dagegen 1,00 Punkte und führt teilweise einzelne Beobachtungen anstelle aggregierter Daten als Beleg für einen Zusammenhang an.

Für FF2 ergibt sich daraus, dass die Übereinstimmung mit den Referenzwerten bei GPT insgesamt sehr hoch ausfällt, während sie bei Gemini stärker von der Art der Aufgabe abhängt. Die beobachteten Abweichungen sind dabei nicht gleichmäßig über die Auf-

gabentypen verteilt, sondern treten insbesondere im Zusammenhang mit abweichenden Beobachtungszahlen, technischen Abbrüchen und einzelnen instabilen Antworten auf. Zugleich zeigen die Wiederholungen, dass eine hohe Reproduzierbarkeit nicht notwendigerweise mit einer hohen faktischen Korrektheit einhergeht.

5.1.3 FF3: Methodisches Vorgehen zur explorativen Datenanalyse

Experiment 0 untersucht das methodische Wissen der Modelle unabhängig von einem konkreten Datensatz. Über 15 konzeptionelle Fragen in drei Schwierigkeitsstufen und jeweils drei Wiederholungen erreichen beide Modelle nahezu durchgängig die höchste Bewertungsstufe. Im Mittel erreicht GPT 2,93 und Gemini 2,91 von drei möglichen Punkten. Die Modelle geben zentrale Vorgehensweisen der explorativen Datenanalyse auf konzeptioneller Ebene zutreffend wieder. Sie benennen unter anderem die Interquartilsregel zur Ausreißererkennung, unterscheiden verschiedene Lagemaße und berücksichtigen die Grenzen der Aussagekraft von Korrelationskoeffizienten.

Für FF3 ergibt sich daraus, dass beide untersuchten LLMs ein weitgehend vollständiges methodisches Vorwissen zur explorativen Datenanalyse zeigen. Die in Experiment 0 erzielten Ergebnisse sprechen damit dagegen, die in den Experimenten 1 und 2 beobachteten Abweichungen allein durch fehlendes methodisches Wissen zu erklären. Vielmehr treten die festgestellten Abweichungen bei der datenbezogenen Anwendung auf. Ob sie dabei aus der Verarbeitung der Daten, der Übertragung des methodischen Wissens auf die konkrete Aufgabe oder weiteren Eigenschaften der Modelle resultieren, lässt sich anhand der vorliegenden Experimente nicht abschließend bestimmen.

5.2 Übergreifende Diskussion

Die Ergebnisse der drei Experimente lassen sich zu einem gemeinsamen Bild zusammenführen. Den Ausgangspunkt bildet dabei Experiment 0. Da beide Modelle das methodische Vorgehen der explorativen Datenanalyse auf konzeptioneller Ebene weitgehend vollständig wiedergeben, spricht dieser Befund dagegen, die in den datenbezogenen Experimenten beobachteten Abweichungen allein durch fehlendes Methodenwissen zu erklären. Die Frage verschiebt sich damit von dem, was die Modelle über das Vorgehen wissen, hin zu dem, wie sie dieses Wissen auf einen konkret bereitgestellten Datensatz

anwenden.

Über die Kategorien und Experimente hinweg zeigt sich dabei wiederholt, dass die Antworten nicht vollständig mit der bereitgestellten Datengrundlage übereinstimmen. In Kategorie A weisen mehrere Antworten von Gemini Berechnungen auf Grundlage von 400 bis 710 Beobachtungen aus, obwohl der Datensatz 1470 Beobachtungen umfasst. In Kategorie B stützt dasselbe Modell Aussagen teilweise auf einzelne Beschäftigte anstelle aggregierter Gruppenvergleiche, und eine Antwort beruht ausdrücklich auf 500 statt auf 1470 Beobachtungen. In Kategorie C wird eine Berechnung auf 718 Beobachtungen bezogen und eine im Datensatz nicht vorhandene Variable mit einer inhaltlich ähnlichen vorhandenen Variable gleichgesetzt. In Experiment 2 schließlich geben beide Modelle den Zusammenhang des ursprünglichen Datensatzes wieder, obwohl die übergebene Fassung den umgekehrten Zusammenhang enthält.

Daraus ergibt sich eine für die Bewertung LLM-gestützter Analysen relevante Beobachtung: Die numerische Plausibilität einer Antwort belegt für sich genommen nicht, dass der vollständige Datensatz berücksichtigt wurde. Die Ergebnisse von Experiment 1 zeigen, dass Mittelwerte, Mediane und Anteile auch bei einer ausgewiesenen Berechnung auf Grundlage einer Teilmenge nahe am Referenzwert liegen können. Besonders sichtbar werden die Abweichungen dagegen bei Zählwerten wie der Anzahl der Beobachtungen oder der Ausreißer. Experiment 2 schafft darüber hinaus eine trennschärfere Prüfsituation, da der gezielt veränderte Zusammenhang eine Unterscheidung zwischen den beiden Datenfassungen ermöglicht.

Zwischen den beiden Modellen bestehen deutliche Unterschiede, die jedoch nicht in eine einheitliche Rangfolge münden. GPT erreicht in den faktischen und interpretativen Fragen insgesamt höhere und über die Wiederholungen hinweg nahezu konstante Bewertungen, stützt seine Interpretationen auf aggregierte Kennzahlen und grenzt deskriptive Befunde wiederholt von kausalen Schlussfolgerungen ab. Gemini zeigt demgegenüber ein nach Aufgabentyp differenziertes Verhalten mit deutlichen Einbrüchen bei Zählwerten, einer schwächeren quantitativen Begründung sowie kausal anmutenden Formulierungen und Erklärungen, die sich nicht aus dem Datensatz ableiten lassen. In Kategorie C kehrt sich das Verhältnis jedoch um: Gemini erreicht dort einen höheren Anteil verlässlicher Antworten als GPT. Auch in Experiment 0 treten die wenigen Abweichungen bei unterschiedlichen Themen auf. Die Leistungsfähigkeit eines Modells lässt sich damit nicht als eine einzelne Größe beschreiben, sondern hängt vom Typ der gestellten Aufgabe ab.

Dieser Befund lässt sich auf die von Bornschlegl (2024) benannten Anforderungen an die

Vertrauenswürdigkeit beziehen. Reproduzierbarkeit und Validität fallen in den Ergebnissen mehrfach auseinander. Bei der Ausreißerzählung in Frage A06 erreicht Gemini eine Standardabweichung von null bei einem mittleren Punktwert von null und wiederholt damit über alle Durchläufe hinweg fehlerhafte Ergebnisse. In Experiment 2 gibt GPT in allen 25 Analyseantworten dieselbe Richtung wieder, die der übergebenen Datenfassung widerspricht. Umgekehrt erreicht Gemini bei Frage B01 im Mittel 1,00 Punkte, obwohl die einzelnen Wiederholungen zwischen null und zwei Punkten variieren. Eine geringe Streuung weist somit auf ein stabiles Antwortverhalten hin, nicht auf inhaltliche Korrektheit. Dies entspricht dem Befund von Zheng et al. (2024), wonach Konsistenz allein kein hinreichendes Gütekriterium darstellt, da auch fehlerhafte Antworten konsistent wiederholt werden können.

Die Halluzinationsfallen der Kategorie C bilden demgegenüber eine eigenständige Bewertungsdimension ab, die sich aus der faktischen Genauigkeit nicht ableiten lässt. Die Ergebnisse unterscheiden sich dabei stärker zwischen den verschiedenen Fallentypen, als es der aggregierte Vergleich der beiden Modelle zunächst erkennen lässt. Eindeutig nicht vorhandene Variablen werden von beiden Modellen zuverlässig zurückgewiesen. Sobald jedoch eine inhaltlich ähnliche Variable existiert oder die fehlerhafte Annahme lediglich suggestiv mitgeführt wird, gelingt die Zurückweisung nicht durchgängig. Bei der suggestiven Prämisse in Frage C04 berechnen beide Modelle in sämtlichen Wiederholungen die erfragte Gruppenquote, ohne die in der Frage unterstellte Stärke des Zusammenhangs zu relativieren. Zwar liegt die Kündigungsquote der Gruppe mit `DistanceFromHome > 20` über der Gesamtquote, der lineare Zusammenhang über alle Beobachtungen ist mit $r = 0,0779$ jedoch nur schwach ausgeprägt. Die starke Formulierung der Prämisse wird durch die Daten damit nicht gestützt. Dass die Ergebnisse zwischen den Fallentypen und zwischen den Modellen deutlich variieren, fügt sich in die Beobachtung von Agrawal et al. (2024) ein, wonach Halluzination kein rein binäres Merkmal darstellt und die Raten modellspezifisch ausfallen.

Theoretisch lässt sich das in Experiment 2 beobachtete Verhalten in den von Y. Wang et al. (2024) beschriebenen Forschungsstand zu Wissenskonflikten einordnen. Diese entstehen, wenn parametrisches Wissen eines LLM und nicht-parametrische Informationen im bereitgestellten Kontext voneinander abweichen. Die Autoren zeigen, dass LLMs das Vorliegen solcher Konflikte zwar deutlich besser als zufällig erkennen, jedoch Schwierigkeiten haben, die konkret widersprüchlichen Informationen zu lokalisieren und getrennte Antworten auf Grundlage der verschiedenen Informationsquellen zu erzeugen. Experi-

ment 2 erzeugt eine vergleichbare Konfliktsituation, indem der Zusammenhang zwischen **OverTime** und **Attrition** gegenüber dem ursprünglichen Datensatz gezielt umgekehrt wird. Beide Modelle geben in dieser Situation überwiegend beziehungsweise vollständig den Zusammenhang des ursprünglichen Datensatzes wieder. Das beobachtete Antwortverhalten fügt sich damit in die von Y. Wang et al. (2024) beschriebenen Schwierigkeiten beim Umgang mit widersprüchlichen Informationen ein. Ob der ursprüngliche Zusammenhang dabei tatsächlich Bestandteil des parametrischen Wissens der untersuchten Modelle ist, lässt sich anhand des vorliegenden Versuchsdesigns jedoch nicht unmittelbar nachweisen. Nach der in Abschnitt 2.4 eingeführten Unterscheidung lässt sich das beobachtete Antwortverhalten zudem als treuebezogene Halluzination im Sinne von Bai et al. (2025) einordnen, da die Ausgabe von dem bereitgestellten Eingabekontext abweicht und stattdessen den im ursprünglichen Datensatz beobachteten Zusammenhang wiedergibt.

Dass in mehreren Antworten nicht nur der Zusammenhang, sondern auch die Kennzahlen des ursprünglichen Datensatzes wiedergegeben werden, verweist auf die von X. Wang et al. (2024) aufgeworfene Frage, inwieweit Ausgaben auf einer tatsächlichen Generalisierung oder auf der Reproduktion gelernter Muster beruhen. Besonders deutlich wird dies bei der Kontrollabfrage, in der GPT den Zähler des ursprünglichen Datensatzes anführt, obwohl der Nenner in beiden Fassungen identisch ist und allein der Zähler zwischen ihnen unterscheidet. Ebenso verweist eine Antwort von Gemini ausdrücklich auf einen Wert aus einem „full dataset standard benchmark“. Beide Beobachtungen sind mit einem Rückgriff auf bereits repräsentierte Informationen über den ursprünglichen Datensatz vereinbar. Eine abschließende Trennung zwischen einer Memorisierung des konkreten Datensatzes und einem allgemeinen, fachlich erwarteten Zusammenhang ist auf Grundlage des vorliegenden Untersuchungsdesigns jedoch nicht möglich, da beide Erklärungen dasselbe beobachtbare Antwortverhalten hervorrufen können.

Einzuordnen ist schließlich, worauf sich die Befunde beziehen. Untersucht wurde eine Bedingung, in der der Datensatz als Text im Kontext übergeben wird und den Modellen kein externes Rechenwerkzeug zur Verfügung steht. Die beobachteten Abweichungen betreffen damit Antworten auf Grundlage eines umfangreichen, direkt im Kontext bereitgestellten Datensatzes. Gerade an dieser Stelle sehen Xu et al. (2025) einen möglichen Ansatzpunkt, indem sie die Anreicherung mit externem Wissen und Werkzeugen als Möglichkeit diskutieren, dem Modell Informationen bereitzustellen, die über die reinen Trainingsdaten hinausgehen. Die in Abschnitt 2.3 dargestellten Arbeiten von L. Cheng

et al. (2023) und Zhecheva (2024) nutzen dagegen Ansätze, bei denen das Sprachmodell Programmcode erzeugt, der anschließend zur Berechnung der Analyseergebnisse ausgeführt wird. Die vorliegenden Ergebnisse sind daher nicht als Aussage über werkzeuggestützte Analysesysteme zu verstehen, sondern beziehen sich auf eine Bedingung, in der die Modelle ohne externes Rechenwerkzeug auf den im Kontext bereitgestellten Datensatz antworten. Die Reichweite dieser Einschränkung wird in Abschnitt 5.3 weiter ausgeführt.

Für die Praxis LLM-gestützter explorativer Datenanalyse folgt daraus, dass die Übereinstimmung einer Ausgabe mit dem tatsächlichen Dateninhalt nicht vorausgesetzt, sondern überprüft werden muss. Dies gilt insbesondere für Ergebnisse, deren Plausibilität allein keine Rückschlüsse darauf erlaubt, ob der vollständige Datensatz berücksichtigt wurde. Ebenso ist besondere Vorsicht bei Fragestellungen geboten, für die bereits ein allgemein plausibles oder aus einem bekannten Datensatz erwartbares Ergebnis existiert. Die Ergebnisse von Experiment 2 zeigen, dass eine inhaltlich plausible und konsistent wiedergegebene Antwort dennoch im Widerspruch zur konkret bereitgestellten Datengrundlage stehen kann.

5.3 Limitationen

Die dargestellten Ergebnisse unterliegen mehreren Einschränkungen, die bei ihrer Einordnung zu berücksichtigen sind.

Die Untersuchung stützt sich auf einen einzelnen Datensatz. Der Datensatz *IBM HR Analytics* ist öffentlich verfügbar und weit verbreitet, sodass nicht ausgeschlossen werden kann, dass Informationen über ihn in den Trainingsdaten der untersuchten Modelle enthalten waren. Diese Bekanntheit ist für Experiment 2 einerseits relevant, da sowohl eine mögliche Repräsentation des ursprünglichen Datensatzes als auch allgemein gelernte Zusammenhänge mit der manipulierten Datenfassung in Konflikt geraten können. Andererseits lässt sich gerade deshalb nicht eindeutig unterscheiden, ob die Wiedergabe des ursprünglichen Zusammenhangs auf Informationen über den konkreten Datensatz oder auf einem allgemein gelernten Muster beruht. Ein weniger verbreiteter oder eigens für die Untersuchung erzeugter Datensatz könnte dazu beitragen, den möglichen Einfluss einer Memorisierung des konkreten Datensatzes stärker von allgemeinen gelernten Mustern abzugrenzen. Hinzu kommt, dass der Datensatz synthetisch erzeugt ist, aus ei-

nem einzelnen Anwendungsbereich stammt, in tabellarischer Form mit überschaubarem Umfang vorliegt und keine fehlenden Werte enthält. Inwieweit sich die Ergebnisse auf andere Fachgebiete, größere Datenmengen oder Daten mit ausgeprägten Qualitätsmängeln übertragen lassen, bleibt offen.

Auch die Manipulation in Experiment 2 ist in ihrer Reichweite begrenzt. Verändert wurde ausschließlich die Beziehung zwischen **OverTime** und **Attrition**, mit einer festgelegten Umkehrstärke und einem festen Zufalls-Seed. Diese Beschränkung war methodisch beabsichtigt, da sie eine eindeutige Zuordnung der beobachteten Effekte ermöglicht. Sie lässt jedoch offen, ob sich das Antwortverhalten bei anderen Variablen, bei einer schwächeren oder stärkeren Umkehr oder bei Zusammenhängen ohne ausgeprägte allgemeine Erwartungshaltung in gleicher Weise zeigt.

Die Untersuchung umfasst zwei Modelle zweier Anbieter zu einem bestimmten Zeitpunkt. Da Modellversionen fortlaufend weiterentwickelt werden, bilden die Ergebnisse eine Momentaufnahme ab und lassen sich nicht ohne Weiteres auf spätere Versionen übertragen. Hinzu kommt, dass die beiden untersuchten Modelle nicht in allen Eigenschaften vergleichbar sind. Sie unterscheiden sich nicht allein im Anbieter, sondern auch in ihrer Ausrichtung, sodass die beobachteten Unterschiede ebenso auf die jeweilige Modellklasse wie auf den Anbieter zurückgehen können. Ebenfalls nicht variiert wurden die Gestaltung des System-Prompts sowie die Prompting-Strategie. Insbesondere wurde auf das in Abschnitt 2.2 beschriebene Chain-of-Thought-Prompting verzichtet, um für alle Fragen einheitliche Bedingungen zu schaffen. Ob sich die Ergebnisse unter einer anderen Prompt-Gestaltung verändern, wurde nicht geprüft.

Die Zahl der Wiederholungen begrenzt die Aussagekraft der Streuungsangaben. Je Frage und Modell wurden fünf Wiederholungen erhoben, in Experiment 0 drei. Die Wiederholungen ermöglichen es, innerhalb der erhobenen Antworten wiederholt auftretende von einzelnen Abweichungen zu unterscheiden, erlauben jedoch keine inferenzstatistische Absicherung. Die ausgewiesenen Standardabweichungen sind daher deskriptiv zu verstehen. Ebenso ist der Fragenkatalog mit 20 Fragen und einer Aufteilung von zehn, fünf und fünf Fragen je Kategorie begrenzt, sodass einzelne Fragen ein vergleichsweise hohes Gewicht im jeweiligen Kategorieergebnis erhalten. Für Experiment 2 beruht die Auswertung auf fünf Analysefragen und damit auf 25 Antworten je Modell. Die durchgängig verwendete Temperatur von 1, die bei GPT vorgegeben ist, stellt zudem nur eine mögliche Konfiguration dar. Ob eine niedrigere Temperatur zu einem stabileren Antwortverhalten geführt hätte, wurde nicht untersucht.

Eine weitere Einschränkung betrifft die getroffenen Bewertungsentscheidungen. Die Toleranzgrenzen von zwei und fünf Prozent, die Festlegung auf eine exakte Übereinstimmung bei Zählwerten, die Skala von null bis zwei Punkten sowie die Entscheidung, technisch abgeschnittene Antworten anhand des bis zum Abbruch erzeugten Inhalts zu bewerten, sind begründet, aber gesetzt. Andere Grenzwerte würden zu anderen Punktwerten führen. Bei den interpretativen Fragen der Kategorie B beruht die Bewertung auf einer Operationalisierung der von Koesten et al. (2021) beschriebenen Merkmale und erfordert damit eine inhaltliche Einschätzung. Bei den Halluzinationsfällen der Kategorie C gilt dies für die Abgrenzung, was als eine einzelne nicht gedeckte Behauptung zählt; dass eine solche Abgrenzung nicht eindeutig zu treffen ist, entspricht dem Hinweis von Agrawal et al. (2024), wonach Halluzination kein rein binäres Merkmal darstellt.

Hinzu kommt, dass die Kodierung nur in Experiment 0 blind erfolgte. In den datenbezogenen Experimenten wurde sie in Kenntnis des jeweiligen Modells vorgenommen. Da die Bewertung zudem von einer einzelnen Person durchgeführt wurde, konnte keine Doppelkodierung und damit keine Inter-coder-Reliabilität bestimmt werden. Zur Unterstützung des umfangreichen Kodierungsprozesses wurden einzelne Bewertungen zusätzlich durch ein LLM anhand der zuvor festgelegten Bewertungskriterien beurteilt. Die daraus resultierenden Bewertungsvorschläge wurden jedoch nicht automatisiert übernommen, sondern anschließend anhand der jeweiligen Modellantwort, der Datengrundlage und der Bewertungskriterien überprüft. Die endgültige Kodierungsentscheidung erfolgte nach manueller Überprüfung. Diese Vorgehensweise reduziert den manuellen Aufwand und unterstützt eine systematische Anwendung der Bewertungskriterien, ersetzt jedoch keine unabhängige Zweitkodierung. Diese Einschränkung wiegt für die faktischen Fragen der Kategorie A geringer, da dort der Vergleich mit einem eindeutig bestimmten Referenzwert erfolgt, betrifft jedoch insbesondere die interpretativen Fragen und die Halluzinationsfälle.

Auf technischer Ebene ist zunächst das Ausgabelimit zu nennen. In Experiment 1 brachen elf Antworten von Gemini am Token-Limit ab und gingen in der tatsächlich erzeugten Form in die Bewertung ein. Dadurch können sowohl die erreichten Punktwerte als auch deren Streuung beeinflusst worden sein. Die Abbrüche stellen daher eine technische Störgröße bei der Interpretation der Ergebnisse dar. Zudem unterscheidet sich die technische Bereitstellung des Datensatzes zwischen den Anbietern: Für GPT wurde er jeder Anfrage vorangestellt, für Gemini über einen Kontext-Cache bereitgestellt. Inhaltlich stand beiden Modellen derselbe vollständige Datensatz zur Verfügung, ein Einfluss

des jeweiligen Bereitstellungsverfahrens lässt sich jedoch nicht vollständig ausschließen. Schließlich beruhen die Referenzwerte selbst auf methodischen Festlegungen. Dazu zählen die Behandlung ordinal skaliert Variablen als intervallskaliert bei der Korrelationsberechnung, die quartilsbasierte Einteilung in drei Klassen sowie die Parameter der Regelgenerierung mit einem Mindestsupport von 0,05, der Mindestkonfidenz als Median der Ausgangsregelmenge und einem Minimal Improvement von 0,05 nach Hammesfahr und Spott (2021). Andere Festlegungen führen zu einer anderen Regelmenge und damit zu einem veränderten Referenzrahmen für die Bewertung der Kategorie B.

In Anbetracht all dessen ergibt sich eine begrenzte Generalisierbarkeit. Die deutlichste Einschränkung betrifft die untersuchte Bedingung selbst: Der Datensatz wurde als Text im Kontext übergeben, und den Modellen stand kein externes Rechenwerkzeug zur Verfügung. Die Ergebnisse beschreiben damit das Antwortverhalten der Modelle bei einem unmittelbar im Kontext bereitgestellten Datensatz ohne externes Rechenwerkzeug. Sie erlauben keine Aussage über Analysesysteme, in denen das Sprachmodell Programmcode erzeugt, der anschließend ausgeführt wird und die eigentliche Berechnung übernimmt, wie es die in Abschnitt 2.3 dargestellten Ansätze vorsehen. Bei solchen Ansätzen wird die Berechnung durch ausgeführten Programmcode unterstützt, sodass sich die vorliegenden Ergebnisse nicht ohne Weiteres auf diese Systeme übertragen lassen. Ebenso wurde jede Frage in einem eigenständigen Kontext gestellt, sodass die Ergebnisse keine Aussage über den Verlauf einer mehrstufigen, aufeinander aufbauenden Analyse zulassen. Die Befunde beziehen sich somit auf zwei Modelle, einen Datensatz und eine klar umrissene Untersuchungsbedingung und sind nicht als allgemeine Aussage über die Zuverlässigkeit LLM-gestützter explorativer Datenanalyse zu verstehen.

6 Fazit und Ausblick

6.1 Fazit

6.2 Ausblick

Literaturverzeichnis

- Agrawal, A., Suzgun, M., Mackey, L., & Kalai, A. T. (2024, 20. März). Do Language Models Know When They're Hallucinating References? <https://doi.org/10.48550/arXiv.2305.18248>
- Bai, Z., Wang, P., Xiao, T., He, T., Han, Z., Zhang, Z., & Shou, M. Z. (2025, 1. April). Hallucination of Multimodal Large Language Models: A Survey. <https://doi.org/10.48550/arXiv.2404.18930>
- Bender, E. M., Gebru, T., McMillan-Major, A., & Shmitchell, S. (2021). On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, 610–623. <https://doi.org/10.1145/3442188.3445922>
- Bornschlegl, M. (2024). Towards Trustworthiness in AI-based Big Data Analysis. <https://doi.org/10.18445/20240426-221234-0>
- Boslaugh, S. (2012). *Statistics in a Nutshell* (2. Aufl.). O'Reilly Media.
- Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D., Wu, J., Winter, C., & Amodei, D. (2020, 28. Mai). *Language Models are Few-Shot Learners*. <https://doi.org/10.48550/arXiv.2005.14165>
- Chen, M., Tworek, J., Jun, H., Yuan, Q., Pinto, H. P. d. O., Kaplan, J., Edwards, H., Burda, Y., Joseph, N., Brockman, G., Ray, A., Puri, R., Krueger, G., Petrov, M., Khlaaf, H., Sastry, G., Mishkin, P., Chan, B., Gray, S., ... Zaremba, W. (2021, 14. Juli). Evaluating Large Language Models Trained on Code. <https://doi.org/10.48550/arXiv.2107.03374>
- Comment: corrected typos, added references, added authors, added acknowledgements.
- Cheng, L., Li, X., & Bing, L. (2023). Is GPT-4 a Good Data Analyst? In H. Bouamor, J. Pino & K. Bali (Hrsg.), *Findings of the Association for Computational Linguistics: EMNLP 2023* (S. 9496–9514). Association for Computational Linguistics.

- <https://doi.org/10.18653/v1/2023.findings-emnlp.637>
 Neu für 2.3.
- Cheng, S., Pan, L., Yin, X., Wang, X., & Wang, W. Y. (2024, 10. Oktober). Understanding the Interplay between Parametric and Contextual Knowledge for Large Language Models. <https://doi.org/10.48550/arXiv.2410.08414>
- Hammesfahr, J., & Spott, M. (2021). Identifikation relevanter Zusammenhänge in Daten mit maschinellem Lernen. In T. Barton & C. Müller (Hrsg.), *Data Science anwenden: Einführung, Anwendungen und Projekte* (S. 201–218). Springer Fachmedien. https://doi.org/10.1007/978-3-658-33813-8_12
- Ji Ziwei, NAYEON LEE, RITA FRIESKE, TIEZHENG YU, DAN SU, HO SHU CHAN, ANDREA MADOTTO & PASCALE FUNG. (2022). Survey of Hallucination in Natural Language Generation. *ACM Comput. Surv.*, (1), 1–59. <https://doi.org/10.48550/arXiv.2202.03629>
- Koesten, L., Gregory, K., Groth, P., & Simperl, E. (2021). Talking datasets: Understanding data sensemaking behaviours. *International Journal of Human-Computer Studies*, 146, 102562. <https://doi.org/10.1016/j.ijhcs.2020.102562>
- Langer, T., & Meisen, T. (2019). Towards Utilizing Domain Expertise for Exploratory Data Analysis. *Proceedings of the 12th International Symposium on Visual Information Communication and Interaction*, 1–5. <https://doi.org/10.1145/3356422.3356434>
- Li, J., Huo, N., Gao, Y., Shi, J., Zhao, Y., Qu, G., Wu, Y., Ma, C., Lou, J.-G., & Cheng, R. (2024, 8. März). Tapilot-Crossing: Benchmarking and Evolving LLMs Towards Interactive Data Analysis Agents. <https://doi.org/10.48550/arXiv.2403.05307>
 Comment: 30 pages, 7 figures.
- Rahmany, M., Zin, A. M., & Sundararajan, E. A. (2020). COMPARING TOOLS PROVIDED BY PYTHON AND R FOR EXPLORATORY DATA ANALYSIS. *IJISCS (International Journal of Information System and Computer Science)*, 4(3), 131. <https://doi.org/10.56327/ijiscs.v4i3.933>
- Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł. u., & Polosukhin, I. (2017). Attention is All you Need. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan & R. Garnett (Hrsg.), *Advances in Neural Information Processing Systems* (Bd. 30). Curran Associates, Inc. https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf

- Wang, X., Antoniadis, A., Elazar, Y., Amayuelas, A., Albalak, A., Zhang, K., & Wang, W. Y. (2024, 20. Juli). *Generalization v.s. memorization: Tracing language models' capabilities back to pretraining data* [arXiv.org]. Verfügbar 4. Juni 2026 unter <https://arxiv.org/abs/2407.14985v5>
- Wang, Y., Feng, S., Wang, H., Shi, W., Balachandran, V., He, T., & Tsvetkov, Y. (2024, 15. Oktober). Resolving Knowledge Conflicts in Large Language Models. <https://doi.org/10.48550/arXiv.2310.00935>
- Wei, J., Tay, Y., Bommasani, R., Raffel, C., Zoph, B., Borgeaud, S., Yogatama, D., Bosma, M., Zhou, D., Metzler, D., Chi, E. H., Hashimoto, T., Vinyals, O., Liang, P., Dean, J., & Fedus, W. (2022, 26. Oktober). Emergent Abilities of Large Language Models. <https://doi.org/10.48550/arXiv.2206.07682>
- Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E., Le, Q., & Zhou, D. (2023, 10. Januar). Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. <https://doi.org/10.48550/arXiv.2201.11903>
- Xu, Z., Jain, S., & Kankanhalli, M. (2025, 13. Februar). Hallucination is Inevitable: An Innate Limitation of Large Language Models. <https://doi.org/10.48550/arXiv.2401.11817>
- Yuan, X., Yang, Z., Wang, Y., Liu, S., Zhao, J., & Liu, K. (2024). Discerning and Resolving Knowledge Conflicts through Adaptive Decoding with Contextual Information-Entropy Constraint. In L.-W. Ku, A. Martins & V. Srikumar (Hrsg.), *Findings of the Association for Computational Linguistics: ACL 2024* (S. 3903–3922). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2024.findings-acl.234>
- Zhecheva, D. (2024). Exploratory Data Analysis and the Rise of Large Language Models - Gaming Industry Insights. *TEM Journal*, 13(1), 561–569. Verfügbar 28. Mai 2026 unter <https://www.ceeol.com/search/article-detail?id=1222943>
- Zheng, D., Lapata, M., & Pan, J. Z. (2024, 16. Dezember). How Reliable are LLMs as Knowledge Bases? Re-thinking Facutality and Consistency. <https://doi.org/10.48550/arXiv.2407.13578>