

Exposé

Thema:

Interaktive Explorative Datenanalyse durch die Zusammenarbeit von Mensch und Sprachmodellen

Arbeitstitel:

Untersuchung der Datenkonsistenz und Zuverlässigkeit in interaktiver LLM-gestützter explorativer Datenanalyse

HTW Berlin

Wirtschaftsinformatik [M.Sc.](#)

Giao Thien Nguyen

573654

04.02.2026

1. Motivation

Large Language Models (LLMs) werden zunehmend zur Unterstützung datenanalytischer Aufgaben eingesetzt (z. B. Lyashkevych et al., 2024; Rasheed et al., 2025). Studien zeigen, dass LLMs in der Lage sind, Datenformate zu interpretieren, analytische Operationen zu strukturieren und Code zur Umsetzung zu generieren (Lyashkevych et al., 2024). Explorative Datenanalyse (EDA) stellt dabei einen zentralen Bestandteil des Data-Science-Prozesses dar, da sie der Identifikation von Mustern, Anomalien und Hypothesenbildung dient (Langer & Meisen, 2019). Die Zuverlässigkeit und Vertrauenswürdigkeit der EDA wird durch die Qualität der zugrundeliegenden Daten bestimmt (Behringer et al., 2024). Gleichzeitig basieren LLMs auf umfangreichen vortrainierten Textkorpora und internalisieren dabei statistische Zusammenhänge und Weltwissen (Brown et al., 2020; Bender et al., 2021). Es wird argumentiert, dass LLMs primär Wahrscheinlichkeitsverteilungen über Text modellieren und kein explizites Datenverständnis besitzen (Bender et al., 2021).

Als Student der Wirtschaftsinformatik und angehender Data Scientist betrachte ich die explorative Datenanalyse als einen zentralen Schritt im Analyseprozess. Es interessiert mich besonders, ob LLMs dabei tatsächlich datenbasiert arbeiten oder ob ihre Ergebnisse teilweise auf vortrainiertem Wissen beruhen.

2. Problemstellung

Bestehende Arbeiten untersuchen primär das Potenzial von LLMs zur Automatisierung oder Unterstützung analytischer Prozesse (Lyashkevych et al., 2024; Rasheed et al., 2025). Dabei wird gezeigt, dass LLMs analytische Schritte zerlegen und strukturieren können, jedoch komplexe Operationen häufig in einfachere Teilschritte dekomponiert werden müssen oder zusätzliche Werkzeuge erforderlich sind (Lyashkevych et al., 2024). Unzureichend untersucht ist jedoch die Grundlage der generierten Analyseergebnisse. Insbesondere bei bekannten Datensätzen oder typischen statistischen Mustern haben Sprachmodelle eine Debatte darüber ausgelöst, ob diese Modelle wirklich auf unbekannte Aufgaben verallgemeinert werden können oder vorwiegend auf das Auswendiglernen des internalisierten Trainingswissen zurückgreifen (Wang et al., 2025). Forschungsarbeiten weisen zudem darauf hin, dass LLMs anfällig für Halluzinationen und faktische Inkonsistenzen sind (Ji et al., 2023). Darüber hinaus bleibt offen, inwieweit eine interaktive Mensch-LLM-Zusammenarbeit potenzielle Verzerrungen reduzieren oder Fehlinterpretationen korrigieren kann.

3. Zielsetzung

Ziel der Arbeit ist die Bewertung LLM-gestützter explorativer Datenanalyse. Untersucht wird, in welchem Umfang generierte Interpretationen und Ergebnisse kausal oder statistisch aus den zugrundeliegenden Daten herleitbar sind und in welchem Maße sich Anzeichen für vorwissensbasierte Generalisierungen oder Halluzinationen zeigen. Neben der Bewertung der Datenbindung wird analysiert, inwiefern LLMs über impliziertes Methodenwissen zur EDA verfügen und dieses in interaktiven Analysesituationen korrekt anwenden.

4. Erwartete Ergebnisse

Es wird erwartet, dass LLMs in der Lage sind, explorative Analyseschritte strukturiert zu unterstützen und plausible Ergebnisse zu generieren. Gleichzeitig ist anzunehmen, dass die generierten Analysen nicht ausschließlich auf den bereitgestellten Daten basieren, sondern teilweise durch vortrainiertes Wissen und statistische Muster beeinflusst werden. Außerdem wird davon ausgegangen, dass Abweichungen durch Halluzinationen und fehlerhafte Berechnungen nicht zufällig auftreten, sondern ein strukturelles Problem sind.

Mögliche Unterschiede in der Faktentreue, Konsistenz oder Interpretierbarkeit der Ergebnisse könnten auf diesen Einfluss zurückzuführen sein. Darüber hinaus wird erwartet, dass bestimmte Formen der Interaktion zwischen Mensch und Modell die Qualität und Nachvollziehbarkeit der Analyse beeinflussen.

5. Vorgehen

Die Arbeit basiert zunächst auf einer systematischen Aufarbeitung des aktuellen Forschungsstands zu LLM-gestützten Datenanalyse sowie möglicher Verzerrung durch vortrainiertes Wissen. Auf dieser Grundlage wird ein prototypisches Analyse-Setup in Python implementiert, um eine kontrollierte Untersuchung von LLM-gestützter explorativer Datenanalyse zu ermöglichen. Zur Realisierung bieten sich folgende Ansätze an:

- Eine Referenzanalyse, um zu prüfen welche Aussagen exakt datenbasiert sind, welche Aussage nicht statistisch belegbar sind, überinterpretiert
- Ein bekannter oder strukturierter Datensatz wird gezielt verändert – eine Stufe durch Anonymisierung wodurch das Anwendungsproblem nicht mehr erkennbar ist aber die statistischen Eigenschaften erhalten bleiben (z. B. Umkehrung von Zusammenhängen oder Anpassung zentraler Variablen).
Das LLM analysiert sowohl die Original- als auch die modifizierte Version.
- Es wird untersucht, ob eine mehrstufige Mensch–LLM-Interaktion zu konsistenteren oder präziseren Analyseergebnissen führt als eine einmalige Anfrage.

6. Wissenschaftliche Fragestellungen

Hauptfrage:

Inwieweit basieren LLM-gestützte Ergebnisse der explorativen Datenanalyse auf den bereitgestellten Daten und nicht auf vortrainiertem Allgemeinwissen?

Nebenfragen:

In welchem Umfang stimmen die vom LLM generierten Analyseergebnisse mit den tatsächlich aus den Daten berechneten Kennzahlen und Zusammenhängen überein?

Welchen Einfluss hat eine iterative Mensch–LLM-Interaktion auf die Konsistenz und Nachvollziehbarkeit der Analyseergebnisse?

Wie viel Wissen haben LLMs über explorative Datenanalyse?

7. Grobgliederung

1. Einleitung
 - 1.1. Problemstellung
 - 1.2. Zielsetzung
 - 1.3. Forschungsfragen
 - 1.4. Aufbau der Arbeit
2. Theoretische Grundlagen und Stand der Technik
 - 2.1. Explorative Datenanalyse (EDA)
 - 2.2. Large Language Models (LLMs)
 - 2.3. LLMs im Kontext der Datenanalyse
 - 2.4. Qualität und Verzerrung von LLM-Ergebnissen
3. Methodik
 - 3.1. Forschungsdesign
 - 3.2. Untersuchungsansatz
 - 3.3. Beschreibung des Analyse-Setups
 - 3.4. Evaluationskriterien
 - 3.5. Datengrundlage
4. Durchführung
 - 4.1. Implementierung des Prototyps
 - 4.2. Durchführung der Analyse
 - 4.3. Dokumentation der Modellinteraktion

5. Ergebnisse
 - 5.1. Darstellung der Analyseergebnisse
 - 5.2. Vergleich mit Referenzwerten
 - 5.3. Identifizierte Abweichung und Muster
6. Diskussion
 - 6.1. Interpretation der Ergebnisse
 - 6.2. Einordnung im Kontext bestehender Forschung
 - 6.3. Limitation der Untersuchung
7. Fazit und Ausblick
 - 7.1. Zusammenfassung
 - 7.2. Implikationen für Forschung und Praxis

8. Literatur

- Tristan Langer and Tobias Meisen. (2019). Towards Utilizing Domain Expertise for Exploratory Data Analysis. In Proceedings of the 12th International Symposium on Visual Information Communication and Interaction (VINCI '19). Association for Computing Machinery, New York, NY, USA, Article 19, 1–5. <https://doi.org/10.1145/3356422.3356434>
- Rasheed, Z., Waseem, M., Ahmad, A., Kemell, K.-K., Xiaofeng, W., Duc, A. N., & Abrahamsson, P. (2025). *Can large language models serve as data analysts? A multi-agent assisted approach for qualitative data analysis* (Version 2). arXiv. <https://doi.org/10.48550/arXiv.2402.01386>
- Lyashkevych, L. & Lyashkevych, Vasyly & Shuvar, R.. (2024). EXPLORATORY DATA ANALYSIS POSSIBILITY IN THE MEANING SPACE USING LARGE LANGUAGE MODELS. Electronics and Information Technologies. 25. 10.30970/eli.25.9. <https://doi.org/10.30970/eli.25.9>
- Behringer, Michael & Hirmer, Pascal & Villanueva, Alejandro & Rapp, Jannis & Mitschang, Bernhard. (2024). Enhancing Data Trustworthiness in Explorative Analysis: An Interactive Approach for Data Quality Monitoring. SN Computer Science. 5. 10.1007/s42979-024-02781-w. <https://doi.org/10.1007/s42979-024-02781-w>
- Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., ... & Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems (NeurIPS 33)*. <https://doi.org/10.48550/arXiv.2005.14165>

- Bender, E. M., Gebru, T., McMillan-Major, A., & Shmitchell, S. (2021). On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?
Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency (FAccT '21).
- Wang, X., Antoniadou, A., Elazar, Y., Amayuelas, A., Albalak, A., Zhang, K., & Wang, W. Y. (2025). *Generalization vs. memorization: Tracing language models' capabilities back to pretraining data*. Proceedings of the International Conference on Learning Representations (ICLR 2025). <https://arxiv.org/abs/2407.14985>
- Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., ... & Fung, P. (2023). Survey of hallucination in natural language generation. *ACM computing surveys*, 55(12), 1-38.